

Optimización de viajes compartidos en taxis utilizando algoritmos evolutivos

Gabriel Fagúndez de los Reyes Renzo Massobrio

Facultad de Ingeniería,
Universidad de la República,
Montevideo, Uruguay



- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

Los viajes compartidos (*Car Pooling*)

- Beneficios ecológicos y económicos, individuales y colectivos.
- Iniciativas:
 - carriles exclusivos
 - campañas para compartir los viajes al trabajo
 - aplicaciones para encontrar compañeros de viaje

Los viajes compartidos en taxis (*Taxi Pooling*)

- Medio de transporte rápido y confiable.
- Raramente viajan a capacidad completa.
- Tarifas altas desalientan a los usuarios.
- Impactan en la congestión del tráfico y en la contaminación.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

Descripción del problema

Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Hallar la cantidad de taxis y la asignación de pasajeros para minimizar el **costo total**.

Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- El número máximo de taxis para N pasajeros es N .
- Costo de un taxi = **costo inicial** + **costo por trayectos**.
- No se consideran otros costos (e.g. esperas, propinas, peajes).

Formulación del problema

- Un conjunto de pasajeros P que viajan desde un origen O a un conjunto de destinos D .
- Un conjunto de taxis T y una función $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$ con C_{MAX} máxima capacidad de un taxi.
- Una constante B : costo inicial del taxi (“bajada de bandera”).
- Una función de distancia, $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$.
- Una función de costo asociado a la distancia, $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$.

Se busca una planificación $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$ que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \underbrace{cost \left(dist \left(dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right]$$

Formulación del problema

- Un conjunto de pasajeros P que viajan desde un origen O a un conjunto de destinos D .
- Un conjunto de taxis T y una función $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$ con C_{MAX} máxima capacidad de un taxi.
- Una constante B : costo inicial del taxi (“bajada de bandera”).
- Una función de distancia, $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$.
- Una función de costo asociado a la distancia, $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$.

Se busca una planificación $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$ que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} cost \left(\underbrace{dist \left(dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

Variante multiobjetivo del PVCT: formulación matemática

- Se busca minimizar el **costo total** y la **demora total**.
- Cada pasajero tiene un **nivel de apuro** asociado.
- Se consideran vehículos con **diferentes capacidades**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \text{cost} \left(\overbrace{\text{dist} \left(\text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[\sum_{j=1}^{C(t_i)} \left[\underbrace{\sum_{h=1}^j \text{time} \left(\text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}_{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} - \underbrace{\left(\text{tol}(f^{-1}(t_i, j)) + \text{time} \left(O, \text{dest}(f^{-1}(t_i, j)) \right) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

Variante multiobjetivo del PVCT: formulación matemática

- Se busca minimizar el **costo total** y la **demora total**.
- Cada pasajero tiene un **nivel de apuro** asociado.
- Se consideran vehículos con **diferentes capacidades**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \text{cost} \left(\overbrace{\text{dist} \left(\text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[\sum_{j=1}^{C(t_i)} \left[\underbrace{\sum_{h=1}^j \text{time} \left(\text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}_{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} \right] \right. \\ \left. - \left(\underbrace{\text{tol}(f^{-1}(t_i, j)) + \text{time} \left(O, \text{dest}(f^{-1}(t_i, j)) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right) \right]$$

Variante multiobjetivo del PVCT: formulación matemática

- Se busca minimizar el **costo total** y la **demora total**.
- Cada pasajero tiene un **nivel de apuro** asociado.
- Se consideran vehículos con **diferentes capacidades**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \text{cost} \left(\overbrace{\text{dist} \left(\text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

tiempo efectivo de traslado del pasajero en la posición j del taxi t_i

$$DT = \sum_{t_i} \left[\sum_{j=1}^{C(t_i)} \left[\sum_{h=1}^j \text{time} \left(\text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right) \right. \right. \\ \left. \left. - \underbrace{\left(\text{tol}(f^{-1}(t_i, j)) + \text{time} \left(O, \text{dest}(f^{-1}(t_i, j)) \right) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

Variante multiobjetivo del PVCT: formulación matemática

- Se busca minimizar el **costo total** y la **demora total**.
- Cada pasajero tiene un **nivel de apuro** asociado.
- Se consideran vehículos con **diferentes capacidades**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \text{cost} \left(\overbrace{\text{dist} \left(\text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[\sum_{j=1}^{C(t_i)} \left[\underbrace{\sum_{h=1}^j \text{time} \left(\text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}_{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} \right] \right. \\ \left. - \underbrace{\left(\text{tol}(f^{-1}(t_i, j)) + \text{time} \left(O, \text{dest}(f^{-1}(t_i, j)) \right) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right]$$

Complejidad

- Baldacci et al. (2004):
 - Variante del *Car Pooling Problem (CPP)*.
 - Solución al problema de compartir vehículos en el trabajo.
- Caso especial del *Vehicle Routing Problem (VRP)* con demanda unitaria: \mathcal{NP} -difícil [Letchford et al. (2002)].
- El PVCT tiene grandes similitudes con el CPP.

Estrategias de resolución

- Con instancias de tamaños realistas los algoritmos exactos tradicionales no resultan útiles para una planificación eficiente.
- **Heurísticas** y **metaheurísticas** son necesarias para calcular soluciones de calidad aceptable en tiempos razonables.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados**
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

Trabajos relacionados

Car pooling problem (CPP)

Yan et al. (2011): **CPP con histórico de viajes** (relajación lagrangeana).

Dial-a-ride problem (DARP)

Cordeau et al. (2003): **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

Taxi pooling problem (TPP)

Tao et al. (2007): heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013): TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

Trabajos relacionados

Car pooling problem (CPP)

Yan et al. (2011): **CPP con histórico de viajes** (relajación lagrangeana).

Dial-a-ride problem (DARP)

Cordeau et al. (2003): **DARP estático con ventanas de tiempo.**

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

Taxi pooling problem (TPP)

Tao et al. (2007): heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013): TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas.**

Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo.**

Trabajos relacionados

Car pooling problem (CPP)

Yan et al. (2011): **CPP con histórico de viajes** (relajación lagrangeana).

Dial-a-ride problem (DARP)

Cordeau et al. (2003): **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

Taxi pooling problem (TPP)

Tao et al. (2007): heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013): TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

Trabajos relacionados

Car pooling problem (CPP)

Yan et al. (2011): **CPP con histórico de viajes** (relajación lagrangeana).

Dial-a-ride problem (DARP)

Cordeau et al. (2003): **DARP estático con ventanas de tiempo.**

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

Taxi pooling problem (TPP)

Tao et al. (2007): heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013): TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas.**

Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo.**

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación**
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

Definición

- Técnicas estocásticas que emulan el proceso de evolución natural de las especies.
- Aplicadas a problemas de **optimización**, búsqueda y aprendizaje.
- Técnica iterativa (**generación**) que aplica operadores estocásticos sobre un conjunto de individuos (**población**).
- Cada individuo codifica una solución tentativa al problema y tiene un valor de **fitness**.
- El propósito es mejorar el fitness de los individuos en la población mediante la aplicación de **operadores evolutivos**.
- Los operadores guían al algoritmo evolutivo hacia soluciones tentativas de mayor calidad.

Definición

- Técnicas estocásticas que emulan el proceso de evolución natural de las especies.
- Aplicadas a problemas de **optimización**, búsqueda y aprendizaje.
- Técnica iterativa (**generación**) que aplica operadores estocásticos sobre un conjunto de individuos (**población**).
- Cada individuo codifica una solución tentativa al problema y tiene un valor de **fitness**.
- El propósito es mejorar el fitness de los individuos en la población mediante la aplicación de **operadores evolutivos**.
- Los operadores guían al algoritmo evolutivo hacia soluciones tentativas de mayor calidad.

Definición

- Técnicas estocásticas que emulan el proceso de evolución natural de las especies.
- Aplicadas a problemas de **optimización**, búsqueda y aprendizaje.
- Técnica iterativa (**generación**) que aplica operadores estocásticos sobre un conjunto de individuos (**población**).
- Cada individuo codifica una solución tentativa al problema y tiene un valor de **fitness**.
- El propósito es mejorar el fitness de los individuos en la población mediante la aplicación de **operadores evolutivos**.
- Los operadores guían al algoritmo evolutivo hacia soluciones tentativas de mayor calidad.

Definición

- Técnicas estocásticas que emulan el proceso de evolución natural de las especies.
- Aplicadas a problemas de **optimización**, búsqueda y aprendizaje.
- Técnica iterativa (**generación**) que aplica operadores estocásticos sobre un conjunto de individuos (**población**).
- Cada individuo codifica una solución tentativa al problema y tiene un valor de **fitness**.
- El propósito es mejorar el fitness de los individuos en la población mediante la aplicación de **operadores evolutivos**.
- Los operadores guían al algoritmo evolutivo hacia soluciones tentativas de mayor calidad.

Definición

- Técnicas estocásticas que emulan el proceso de evolución natural de las especies.
- Aplicadas a problemas de **optimización**, búsqueda y aprendizaje.
- Técnica iterativa (**generación**) que aplica operadores estocásticos sobre un conjunto de individuos (**población**).
- Cada individuo codifica una solución tentativa al problema y tiene un valor de **fitness**.
- El propósito es mejorar el fitness de los individuos en la población mediante la aplicación de **operadores evolutivos**.
- Los operadores guían al algoritmo evolutivo hacia soluciones tentativas de mayor calidad.


Definición

- Técnicas estocásticas que emulan el proceso de evolución natural de las especies.
- Aplicadas a problemas de **optimización**, búsqueda y aprendizaje.
- Técnica iterativa (**generación**) que aplica operadores estocásticos sobre un conjunto de individuos (**población**).
- Cada individuo codifica una solución tentativa al problema y tiene un valor de **fitness**.
- El propósito es mejorar el fitness de los individuos en la población mediante la aplicación de **operadores evolutivos**.
- Los operadores guían al algoritmo evolutivo hacia soluciones tentativas de mayor calidad.

AE para el PVCT monoobjetivo

Aspectos comunes


- Individuos de largo $2N - 1$
 $N = \# \text{pasajeros}$.
- Inicialización:
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



AE para el PVCT monoobjetivo

Aspectos comunes

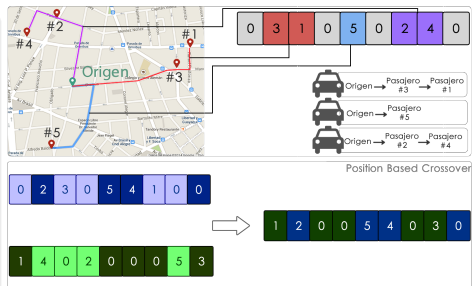
- Individuos de largo $2N - 1$
 $N = \text{\#pasajeros}$.
- Inicialización:
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



AE para el PVCT monoobjetivo

Aspectos comunes


- Individuos de largo $2N - 1$
 $N = \text{\#pasajeros}$.
- Inicialización:
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



AE para el PVCT monoobjetivo

Aspectos comunes

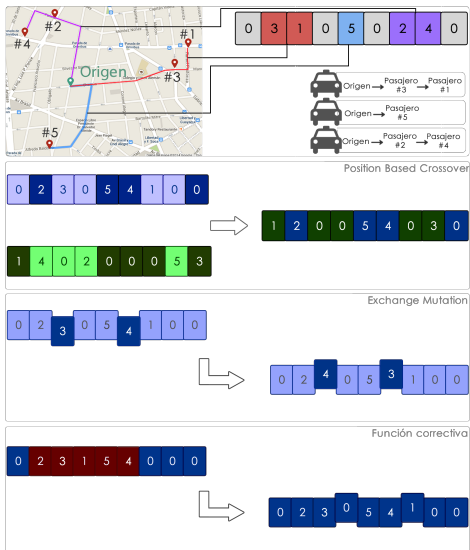
- Individuos de largo $2N - 1$
 $N = \# \text{pasajeros}$.
- Inicialización:
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



AE para el PVCT monoobjetivo

Aspectos comunes


- Individuos de largo $2N - 1$
 $N = \# \text{pasajeros}$.
- Inicialización:
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



AE para el PVCT monoobjetivo

Aspectos comunes

- Individuos de largo $2N - 1$
 $N = \# \text{pasajeros}$.
- Inicialización:
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



AE para el PVCT monoobjetivo

AE secuencial (*seqEA*)

- Selección proporcional.

Micro AE paralelo (*pμEA*)

- Se busca **mejorar el desempeño** mediante el paralelismo.
- **Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.
- Poblaciones pequeñas.
- Selección por torneo (m, k).
- Migración asíncrona, con topología de anillo unidireccional.

AE para el PVCT monoobjetivo

AE secuencial ($seqEA$)

- Selección proporcional.

Micro AE paralelo ($p\mu EA$)

- Se busca **mejorar el desempeño** mediante el paralelismo.
- **Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.
- Poblaciones pequeñas.
- Selección por torneo (m, k).
- Migración asíncrona, con topología de anillo unidireccional.


AE para el PVCT monoobjetivo

AE secuencial (*seqEA*)

- Selección proporcional.

Micro AE paralelo (*pμEA*)

- Se busca **mejorar el desempeño** mediante el paralelismo.
- **Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.



- Poblaciones pequeñas.
- Selección por torneo (m, k).
- Migración asíncrona, con topología de anillo unidireccional.


AE para el PVCT monoobjetivo

AE secuencial (*seqEA*)

- Selección proporcional.

Micro AE paralelo (*pμEA*)

- Se busca **mejorar el desempeño** mediante el paralelismo.
- **Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.



- Poblaciones pequeñas.
- Selección por torneo (m, k).
- Migración asíncrona, con topología de anillo unidireccional.


AE para el PVCT monoobjetivo

AE secuencial (*seqEA*)

- Selección proporcional.

Micro AE paralelo (*pμEA*)

- Se busca **mejorar el desempeño** mediante el paralelismo.
- **Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.



- Poblaciones pequeñas.
- Selección por torneo (m, k).
- Migración asíncrona, con topología de anillo unidireccional.


AE para el PVCT monoobjetivo

AE secuencial (*seqEA*)

- Selección proporcional.

Micro AE paralelo (*pμEA*)

- Se busca **mejorar el desempeño** mediante el paralelismo.
- **Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.



- Poblaciones pequeñas.
- Selección por torneo (m, k).
- Migración asíncrona, con topología de anillo unidireccional.

AE para el PVCT multiobjetivo

Aspectos comunes

- MOEA: acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).
- Función correctiva considera vehículos de distintas capacidades.
- Inicialización ávida y selección por torneo.

Micro MOEA paralelo con descomposición de dominio ($p\mu$ MOEA/D)

Agregación lineal de los objetivos:

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$

MOEA explícito (NSGA-II)

Ordenamiento no-dominado (elitista), *crowding* para preservar diversidad.

AE para el PVCT multiobjetivo

Aspectos comunes

- MOEA: acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).
- Función correctiva considera vehículos de distintas capacidades.
- Inicialización ávida y selección por torneo.

Micro MOEA paralelo con descomposición de dominio ($p\mu$ MOEA/D)

Agregación lineal de los objetivos:

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$

MOEA explícito (NSGA-II)

Ordenamiento no-dominado (elitista), *crowding* para preservar diversidad.

AE para el PVCT multiobjetivo

Aspectos comunes

- MOEA: acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).
- Función correctiva considera vehículos de distintas capacidades.
- Inicialización ávida y selección por torneo.

Micro MOEA paralelo con descomposición de dominio ($p\mu$ MOEA/D)

Agregación lineal de los objetivos:

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\# \text{islas}} : 1], w_D = 1 - w_C.$$

MOEA explícito (NSGA-II)

Ordenamiento no-dominado (elitista), *crowding* para preservar diversidad.

AE para el PVCT multiobjetivo

Aspectos comunes


- MOEA: acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).
- Función correctiva considera vehículos de distintas capacidades.
- Inicialización ávida y selección por torneo.

Micro MOEA paralelo con descomposición de dominio ($p\mu$ MOEA/D)

Agregación lineal de los objetivos:

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$



MOEA explícito (*NSGA-II*)

Ordenamiento no-dominado (elitista), *crowding* para preservar diversidad.

AE para el PVCT multiobjetivo

Aspectos comunes


- MOEA: acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).
- Función correctiva considera vehículos de distintas capacidades.
- Inicialización ávida y selección por torneo.

Micro MOEA paralelo con descomposición de dominio ($p\mu$ MOEA/D)

Agregación lineal de los objetivos:

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$



MOEA explícito (NSGA-II)

Ordenamiento no-dominado (elitista), *crowding* para preservar diversidad.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación
- 5 Evaluación experimental**
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

Generación de instancias

Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- API para obtener tarifas TaxiFareFinder (TFF).
- Instancias en Montevideo generadas manualmente.

Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 instancias para el PVCT multiobjetivo, variando capacidades y tolerancias.

Generación de instancias

Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- API para obtener tarifas TaxiFareFinder (TFF).
- Instancias en Montevideo generadas manualmente.

Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 instancias para el PVCT multiobjetivo, variando capacidades y tolerancias.

Generación de instancias

Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- API para obtener tarifas TaxiFareFinder (TFF).
- Instancias en Montevideo generadas manualmente.

Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 instancias para el PVCT multiobjetivo, variando capacidades y tolerancias.

Generación de instancias

Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- API para obtener tarifas TaxiFareFinder (TFF).
- Instancias en Montevideo generadas manualmente.

Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 instancias para el PVCT multiobjetivo, variando capacidades y tolerancias.

Generación de instancias

Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- API para obtener tarifas TaxiFareFinder (TFF).
- Instancias en Montevideo generadas manualmente.

Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 instancias para el PVCT multiobjetivo, variando capacidades y tolerancias.

Entorno de ejecución

- Evaluación experimental realizada en el Cluster FING.
- Sin compartir recursos para evitar interferencias.



Ejecuciones

- 30 ejecuciones independientes de cada algoritmo sobre cada instancia.
- Criterio de parada: 10.000 generaciones (planificación en línea).

Comparación de resultados

- Tests estadísticos sobre las distribuciones de resultados:
 - Shapiro–Wilk sobre cada muestra para contrastar normalidad.
 - Kruskal–Wallis para comparar las muestras entre sí.
- En ambos tests se utiliza un nivel de confianza del 95 % ($\alpha = 0,05$).

Entorno de ejecución

- Evaluación experimental realizada en el Cluster FING.
- Sin compartir recursos para evitar interferencias.



Ejecuciones

- **30 ejecuciones independientes** de cada algoritmo sobre cada instancia.
- Criterio de parada: **10.000 generaciones** (planificación en línea).

Comparación de resultados

- Tests estadísticos sobre las distribuciones de resultados:
 - Shapiro–Wilk sobre cada muestra para contrastar normalidad.
 - Kruskal–Wallis para comparar las muestras entre sí.
- En ambos tests se utiliza un nivel de confianza del 95 % ($\alpha = 0,05$).

Entorno de ejecución

- Evaluación experimental realizada en el Cluster FING.
- Sin compartir recursos para evitar interferencias.



Ejecuciones

- **30 ejecuciones independientes** de cada algoritmo sobre cada instancia.
- Criterio de parada: **10.000 generaciones** (planificación en línea).

Comparación de resultados

- Tests estadísticos sobre las distribuciones de resultados:
 - Shapiro–Wilk sobre cada muestra para contrastar normalidad.
 - Kruskal–Wallis para comparar las muestras entre sí.
- En ambos tests se utiliza un nivel de confianza del 95 % ($\alpha = 0,05$).

Configuración paramétrica

- **seqEA**: $\#P \in \{150; 200; 250\}$; $p_C \in \{0,6; 0,75; 0,95\}$;
 $p_M \in \{0,001; 0,01; 0,1\}$.
- **p μ EA**: micro-población de 15 individuos, torneo ($m = 2$, $k = 1$),
migración cada 500 generaciones.
 $p_C \in \{0,6; 0,75; 0,95\}$; $p_M \in \{0,001; 0,01; 0,1\}$.

Configuración paramétrica

- **seqEA**: $\#P \in \{150; 200; 250\}$; $p_C \in \{0,6; 0,75; 0,95\}$;
 $p_M \in \{0,001; 0,01; 0,1\}$.
- **p μ EA**: micro-población de 15 individuos, torneo ($m = 2$, $k = 1$),
migración cada 500 generaciones.
 $p_C \in \{0,6; 0,75; 0,95\}$; $p_M \in \{0,001; 0,01; 0,1\}$.


Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.




Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.




Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.




Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.




Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.



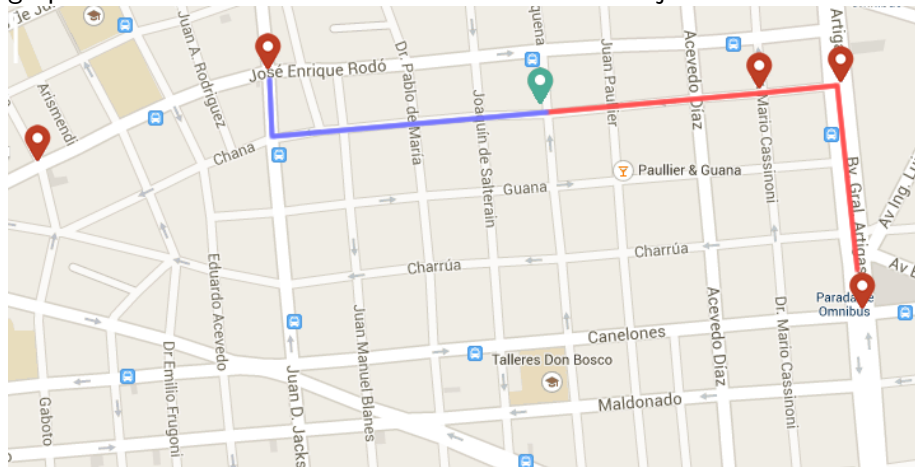
Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.




Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.



Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.



Comparativa de métodos de inicialización

Resultados *seqEA*

- Inicialización ávida supera a inicialización aleatoria en 10 instancias.
- Inicialización aleatoria supera a inicialización ávida en 2 instancias.
- No hay diferencias estadísticamente significativas en 10 instancias.

Resultados *pμEA*

- Inicialización ávida supera a inicialización aleatoria en 11 instancias.
- No hay instancias en las que la inicialización aleatoria supere a la inicialización ávida.
- No hay diferencias estadísticamente significativas en 11 instancias.

Conclusión

Se utiliza la **inicialización ávida** para el resto de la evaluación experimental.

Comparativa de métodos de inicialización

Resultados *seqEA*

- Inicialización ávida supera a inicialización aleatoria en 10 instancias.
- Inicialización aleatoria supera a inicialización ávida en 2 instancias.
- No hay diferencias estadísticamente significativas en 10 instancias.

Resultados *pμEA*

- Inicialización ávida supera a inicialización aleatoria en 11 instancias.
- No hay instancias en las que la inicialización aleatoria supere a la inicialización ávida.
- No hay diferencias estadísticamente significativas en 11 instancias.

Conclusión

Se utiliza la **inicialización ávida** para el resto de la evaluación experimental.

Comparativa de métodos de inicialización

Resultados *seqEA*

- Inicialización ávida supera a inicialización aleatoria en 10 instancias.
- Inicialización aleatoria supera a inicialización ávida en 2 instancias.
- No hay diferencias estadísticamente significativas en 10 instancias.





Resultados *pμEA*

- Inicialización ávida supera a inicialización aleatoria en 11 instancias.
- No hay instancias en las que la inicialización aleatoria supere a la inicialización ávida.
- No hay diferencias estadísticamente significativas en 11 instancias.

Conclusión





Se utiliza la **inicialización ávida** para el resto de la evaluación experimental.

Mejoras *seqEA* sobre algoritmo ávido



Mejoras en **todas** las instancias sobre el algoritmo ávido (hasta 35.9%).
“Online taxi sharing optimization using evolutionary algorithms” (CLEI)

Mejoras $p\mu EA$ sobre algoritmo ávido







Mejoras en **todas** las instancias sobre el algoritmo ávido (hasta 41.0%).
“A parallel micro evolutionary algorithm for taxi sharing optimization” (ALIO)

Comparativa $seqEA$ vs. $p\mu EA$

instancia		$seqEA$		$p\mu EA$		$pvK-W$
		$min(c)$	$\bar{c} \pm std$	$min(c)$	$\bar{c} \pm std$	
chicas	#1	164.4	165.6 \pm 2.0	164.4	164.4 \pm 0.0	0.2 $\times 10^{-3}$
	#2	220.7	225.7 \pm 5.0	220.7	220.7 \pm 0.0	9.7 $\times 10^{-6}$
	#3	160.4	160.4 \pm 0.0	160.4	160.4 \pm 0.0	1.0
	#4	181.3	181.3 \pm 0.1	181.3	182.4 \pm 1.9	0.5 $\times 10^{-1}$
	#5	152.1	155.6 \pm 4.5	152.1	152.1 \pm 0.0	5.1 $\times 10^{-6}$
	#6	118.4	119.6 \pm 2.5	118.4	118.4 \pm 0.0	0.1 $\times 10^{-1}$
medianas	#1	211.9	216.0 \pm 4.2	211.9	211.9 \pm 0.0	5.2 $\times 10^{-11}$
	#2	428.6	444.1 \pm 11.7	427.9	429.4 \pm 1.6	7.0 $\times 10^{-10}$
	#3	361.7	378.7 \pm 6.5	364.5	370.4 \pm 4.5	1.6 $\times 10^{-6}$
	#4	267.5	279.8 \pm 5.5	266.8	266.8 \pm 0.0	7.6 $\times 10^{-12}$
	#5	479.3	487.1 \pm 6.5	479.6	479.8 \pm 0.2	5.1 $\times 10^{-7}$
	#6	306.0	321.2 \pm 7.7	306.0	307.7 \pm 3.4	2.0 $\times 10^{-9}$
grandes	#1	421.9	435.1 \pm 5.0	425.9	437.7 \pm 3.2	0.1 $\times 10^{-1}$
	#2	479.3	489.9 \pm 4.3	477.0	481.1 \pm 2.3	1.9 $\times 10^{-9}$
	#3	332.8	349.7 \pm 7.7	326.3	331.7 \pm 4.0	2.6 $\times 10^{-10}$
	#4	351.1	390.7 \pm 26.3	338.4	344.8 \pm 6.1	5.1 $\times 10^{-11}$
	#5	395.9	429.6 \pm 16.2	370.2	380.0 \pm 4.4	2.7 $\times 10^{-11}$
	#6	360.8	382.4 \pm 8.1	343.8	350.6 \pm 3.8	2.6 $\times 10^{-11}$
Montevideo	#1	168.4	168.4 \pm 0.0	168.4	168.4 \pm 0.0	1.0
	#2	319.3	331.2 \pm 3.8	324.9	328.6 \pm 3.2	5.6 $\times 10^{-6}$
	#3	266.7	269.1 \pm 2.3	266.7	266.7 \pm 0.0	3.1 $\times 10^{-7}$
	#4	303.2	304.7 \pm 0.5	304.1	304.5 \pm 0.4	0.1

$p\mu EA$ supera a $seqEA$ en 17 de 22 instancias.
Únicamente en 1 instancia $seqEA$ supera a $p\mu EA$.

Evolución del costo a lo largo de una ejecución



$p\mu EA$ alcanza mejores soluciones que $seqEA$ en menos tiempo.
En el mejor caso alcanza una **aceleración de 7,5x** (4,6x en promedio).

Configuración paramétrica

- **p μ MOEA/D**: $\#P = 15$; selección por torneo ($m = 2, k = 1$); migración cada 1000 generaciones reemplazando a los peores individuos
 $p_C \in \{0,6; 0,75; 0,95\}$; $p_M \in \{0,001; 0,01; 0,1\}$
- **NSGA-II**: $\#P = 80$; selección por torneo ($m = 2, k = 1$);
 $p_C \in \{0,6; 0,75; 0,95\}$; $p_M \in \{0,001; 0,01; 0,1\}$.

Configuración paramétrica

- **p μ MOEA/D**: $\#P = 15$; selección por torneo ($m = 2, k = 1$); migración cada 1000 generaciones reemplazando a los peores individuos
 $p_C \in \{0,6; 0,75; 0,95\}$; $p_M \in \{0,001; 0,01; 0,1\}$
- **NSGA-II**: $\#P = 80$; selección por torneo ($m = 2, k = 1$);
 $p_C \in \{0,6; 0,75; 0,95\}$; $p_M \in \{0,001; 0,01; 0,1\}$.

Algoritmo ávido para minimizar el costo

Similar al de la variante monoobjetivo pero considerando las distintas capacidades de los vehículos.

Algoritmo ávido para minimizar la demora

- Se crea un taxi vacío para cada pasajero con nivel máximo de apuro y se los ubica en la primera posición.
- Luego, se recorre la lista de pasajeros no asignados en orden de apuro, colocándolos en el taxi que minimice su demora.
- Si el taxi alcanza la máxima capacidad disponible, se lo considera *completo* y no acepta más pasajeros.

Algoritmo ávido para minimizar el costo

Similar al de la variante monoobjetivo pero considerando las distintas capacidades de los vehículos.

Algoritmo ávido para minimizar la demora

- Se crea un taxi vacío para cada pasajero con nivel máximo de apuro y se los ubica en la primera posición.
- Luego, se recorre la lista de pasajeros no asignados en orden de apuro, colocándolos en el taxi que minimice su demora.
- Si el taxi alcanza la máxima capacidad disponible, se lo considera *completo* y no acepta más pasajeros.

Resultados numéricos

μ MOEA/D: "Planificación multiobjetivo de viajes compartidos en taxis utilizando un micro algoritmo evolutivo paralelo" (MAEB)

Hasta **101.2 %** de mejora en demora y **72.8 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	8.5±2.1 (16.0)	3.1±2.5 (0.0)	740.2±746.3 (58.1)	0.6±0.2 (0.1)	0.9±0.1 (1.0)
medianas	9.1±2.2 (19.0)	5.7±2.5 (0.0)	1448.5±1064.1 (141.6)	0.6±0.1 (0.1)	0.9±0.1 (1.0)
grandes	8.5±2.2 (17.0)	7.9±3.4 (2.0)	2917.2±2041.5 (175.3)	0.6±0.1 (0.0)	0.8±0.1 (1.0)
Montevideo	8.0±2.1 (14.0)	3.0±2.0 (0.0)	663.5±542.4 (61.5)	0.6±0.2 (0.0)	0.9±0.0 (1.0)

Buena convergencia y diversidad. Pocas soluciones no dominadas.

NSGA-II: "Multiobjective taxi sharing optimization using the NSGA-II evolutionary algorithm" (MIC)

Hasta **105.2 %** de mejora en demora y **75.1 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	32.6±9.5 (55.0)	0.3±0.6 (0.0)	236.2±222.7 (43.2)	0.9±0.1 (0.7)	1.0±0.0 (1.0)
medianas	54.5±4.2 (67.0)	1.0±0.7 (0.0)	193.6±202.4 (26.2)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
grandes	55.2±3.5 (67.0)	1.8±1.1 (0.4)	243.6±229.8 (26.4)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
Montevideo	43.9±16.4 (61.0)	0.4±0.5 (0.0)	142.3±143.2 (20.8)	0.8±0.1 (0.5)	1.0±0.0 (1.0)

Mayor cantidad de puntos no dominados (hasta 67/80).

Buena convergencia y diversidad en las soluciones encontradas.

Resultados numéricos

μ MOEA/D: "Planificación multiobjetivo de viajes compartidos en taxis utilizando un micro algoritmo evolutivo paralelo" (MAEB)

Hasta **101.2 %** de mejora en demora y **72.8 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	8.5±2.1 (16.0)	3.1±2.5 (0.0)	740.2±746.3 (58.1)	0.6±0.2 (0.1)	0.9±0.1 (1.0)
medianas	9.1±2.2 (19.0)	5.7±2.5 (0.0)	1448.5±1064.1 (141.6)	0.6±0.1 (0.1)	0.9±0.1 (1.0)
grandes	8.5±2.2 (17.0)	7.9±3.4 (2.0)	2917.2±2041.5 (175.3)	0.6±0.1 (0.0)	0.8±0.1 (1.0)
Montevideo	8.0±2.1 (14.0)	3.0±2.0 (0.0)	663.5±542.4 (61.5)	0.6±0.2 (0.0)	0.9±0.0 (1.0)

Buena convergencia y diversidad. Pocas soluciones no dominadas.

NSGA-II: "Multiobjective taxi sharing optimization using the NSGA-II evolutionary algorithm" (MIC)

Hasta **105.2 %** de mejora en demora y **75.1 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	32.6±9.5 (55.0)	0.3±0.6 (0.0)	236.2±222.7 (43.2)	0.9±0.1 (0.7)	1.0±0.0 (1.0)
medianas	54.5±4.2 (67.0)	1.0±0.7 (0.0)	193.6±202.4 (26.2)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
grandes	55.2±3.5 (67.0)	1.8±1.1 (0.4)	243.6±229.8 (26.4)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
Montevideo	43.9±16.4 (61.0)	0.4±0.5 (0.0)	142.3±143.2 (20.8)	0.8±0.1 (0.5)	1.0±0.0 (1.0)

Mayor cantidad de puntos no dominados (hasta 67/80).

Buena convergencia y diversidad en las soluciones encontradas.

Resultados numéricos

$\rho\mu$ MOEA/D: "Planificación multiobjetivo de viajes compartidos en taxis utilizando un micro algoritmo evolutivo paralelo" (MAEB)

Hasta **101.2 %** de mejora en demora y **72.8 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	8.5±2.1 (16.0)	3.1±2.5 (0.0)	740.2±746.3 (58.1)	0.6±0.2 (0.1)	0.9±0.1 (1.0)
medianas	9.1±2.2 (19.0)	5.7±2.5 (0.0)	1448.5±1064.1 (141.6)	0.6±0.1 (0.1)	0.9±0.1 (1.0)
grandes	8.5±2.2 (17.0)	7.9±3.4 (2.0)	2917.2±2041.5 (175.3)	0.6±0.1 (0.0)	0.8±0.1 (1.0)
Montevideo	8.0±2.1 (14.0)	3.0±2.0 (0.0)	663.5±542.4 (61.5)	0.6±0.2 (0.0)	0.9±0.0 (1.0)

Buena convergencia y diversidad. Pocas soluciones no dominadas.

NSGA-II: "Multiobjective taxi sharing optimization using the NSGA-II evolutionary algorithm" (MIC)

Hasta **105.2 %** de mejora en demora y **75.1 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	32.6±9.5 (55.0)	0.3±0.6 (0.0)	236.2±222.7 (43.2)	0.9±0.1 (0.7)	1.0±0.0 (1.0)
medianas	54.5±4.2 (67.0)	1.0±0.7 (0.0)	193.6±202.4 (26.2)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
grandes	55.2±3.5 (67.0)	1.8±1.1 (0.4)	243.6±229.8 (26.4)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
Montevideo	43.9±16.4 (61.0)	0.4±0.5 (0.0)	142.3±143.2 (20.8)	0.8±0.1 (0.5)	1.0±0.0 (1.0)

Mayor cantidad de puntos no dominados (hasta 67/80).

Buena convergencia y diversidad en las soluciones encontradas.

Resultados numéricos

μ MOEA/D: "Planificación multiobjetivo de viajes compartidos en taxis utilizando un micro algoritmo evolutivo paralelo" (MAEB)

Hasta **101.2 %** de mejora en demora y **72.8 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	8.5±2.1 (16.0)	3.1±2.5 (0.0)	740.2±746.3 (58.1)	0.6±0.2 (0.1)	0.9±0.1 (1.0)
medianas	9.1±2.2 (19.0)	5.7±2.5 (0.0)	1448.5±1064.1 (141.6)	0.6±0.1 (0.1)	0.9±0.1 (1.0)
grandes	8.5±2.2 (17.0)	7.9±3.4 (2.0)	2917.2±2041.5 (175.3)	0.6±0.1 (0.0)	0.8±0.1 (1.0)
Montevideo	8.0±2.1 (14.0)	3.0±2.0 (0.0)	663.5±542.4 (61.5)	0.6±0.2 (0.0)	0.9±0.0 (1.0)

Buena convergencia y diversidad. Pocas soluciones no dominadas.

NSGA-II: "Multiobjective taxi sharing optimization using the NSGA-II evolutionary algorithm" (MIC)





Hasta **105.2 %** de mejora en demora y **75.1 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	32.6±9.5 (55.0)	0.3±0.6 (0.0)	236.2±222.7 (43.2)	0.9±0.1 (0.7)	1.0±0.0 (1.0)
medianas	54.5±4.2 (67.0)	1.0±0.7 (0.0)	193.6±202.4 (26.2)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
grandes	55.2±3.5 (67.0)	1.8±1.1 (0.4)	243.6±229.8 (26.4)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
Montevideo	43.9±16.4 (61.0)	0.4±0.5 (0.0)	142.3±143.2 (20.8)	0.8±0.1 (0.5)	1.0±0.0 (1.0)

Mayor cantidad de puntos no dominados (hasta 67/80).


Buena convergencia y diversidad en las soluciones encontradas.

Frentes de Pareto: $p\mu$ MOEA/D vs. NSGA-II




NSGA-II alcanza mejores soluciones: mayor cantidad de puntos no dominados distribuidos homogéneamente a lo largo del frente.

Mejora frente a algoritmos ávidos vs. tiempo de ejecución



costo



demora


NSGA-II alcanza mejores soluciones pero requiere de un mayor tiempo de ejecución que *pμMOEA/D*.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea**
- 7 Conclusiones y trabajo futuro

Planificador de viajes compartidos en línea


- Se ingresa el origen, los destinos y la tarifa (diurna/nocturna).

- Se ejecuta el AE y se muestra la planificación calculada.




Planificador de viajes compartidos en línea


- Se ingresa el origen, los destinos y la tarifa (diurna/nocturna).



- Se ejecuta el AE y se muestra la planificación calculada.



Arquitectura del planificador de viajes compartidos en línea



- Servidor implementado en Ruby on Rails siguiendo MVC.
- Las aplicaciones móviles consumen la API del servidor.
- Aplicaciones móviles: desarrollo híbrido vs. desarrollo nativo.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

Conclusiones

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** ($p\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** ($p\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis (www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p μ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p μ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis (www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** ($p\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** ($p\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis (www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p μ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p μ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis (www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p μ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p μ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis (www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p μ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p μ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis (www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p μ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p μ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis (www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico**.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de usuario.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

Problemas relacionados

- Estudiar otras variantes del problema (many-to-one, many-to-many).
- Estudiar la aplicabilidad de los AE a otros escenarios.

Trabajo futuro

Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico**.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de usuario.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

Problemas relacionados

- Estudiar otras variantes del problema (many-to-one, many-to-many).
- Estudiar la aplicabilidad de los AE a otros escenarios.

Trabajo futuro

Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico**.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de usuario.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

Problemas relacionados

- Estudiar otras variantes del problema (many-to-one, many-to-many).
- Estudiar la aplicabilidad de los AE a otros escenarios.

Gracias

Sitio web del proyecto:

www.fing.edu.uy/inco/grupos/cecal/hpc/AG-Taxi/