

# Optimización de viajes compartidos en taxis utilizando algoritmos evolutivos

Gabriel Fagúndez de los Reyes    Renzo Massobrio

Facultad de Ingeniería,  
Universidad de la República,  
Montevideo, Uruguay



# Contenido

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

## Car pooling

- Beneficios en el plano ecológico y económico, individuales y colectivos.
- Iniciativas para atender el interés del público: carriles exclusivos, campañas para compartir los viajes al trabajo y aplicaciones para encontrar compañeros de viaje.

## Taxi pooling

- Los taxis son un medio de transporte rápido y confiable, especialmente en ciudades donde el transporte público es poco eficiente.
- Los taxis raramente viajan a capacidad completa, impactando en la congestión del tráfico y en la contaminación de las ciudades.
- Tarifas altas desalientan a los usuarios.
- 15 % de los accidentes fatales en Uruguay involucran a un conductor alcoholizado (UNASEV).

## Car pooling

- Beneficios en el plano ecológico y económico, individuales y colectivos.
- Iniciativas para atender el interés del público: carriles exclusivos, campañas para compartir los viajes al trabajo y aplicaciones para encontrar compañeros de viaje.

## Taxi pooling

- Los taxis son un medio de transporte rápido y confiable, especialmente en ciudades donde el transporte público es poco eficiente.
- Los taxis raramente viajan a capacidad completa, impactando en la congestión del tráfico y en la contaminación de las ciudades.
- Tarifas altas desalientan a los usuarios.
- **15 %** de los accidentes fatales en Uruguay involucran a un conductor alcoholizado (UNASEV).

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

# Descripción del problema

## Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas ubicadas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Se busca determinar la cantidad de taxis, la asignación de pasajeros y las rutas a seguir, de forma de **minimizar el costo total del grupo de pasajeros**.

## Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- el número máximo de taxis para  $N$  pasajeros es  $N$ .
- Costo de un taxi = **costo inicial** (“bajada de bandera”) + **costo determinado por la distancia**.
- No se consideran otros posibles costos (e.g. esperas, propinas, peajes).

# Descripción del problema

## Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas ubicadas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Se busca determinar la cantidad de taxis, la asignación de pasajeros y las rutas a seguir, de forma de **minimizar el costo total del grupo de pasajeros**.

## Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- el número máximo de taxis para  $N$  pasajeros es  $N$ .
- Costo de un taxi = **costo inicial** ("bajada de bandera") + **costo determinado por la distancia**.
- No se consideran otros posibles costos (e.g. esperas, propinas, peajes).



# Descripción del problema

## Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas ubicadas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Se busca determinar la cantidad de taxis, la asignación de pasajeros y las rutas a seguir, de forma de **minimizar el costo total del grupo de pasajeros**.

## Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- el número máximo de taxis para  $N$  pasajeros es  $N$ .
- Costo de un taxi = **costo inicial** (“bajada de bandera”) + **costo determinado por la distancia**.
- No se consideran otros posibles costos (e.g. esperas, propinas, peajes).

# Descripción del problema

## Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas ubicadas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Se busca determinar la cantidad de taxis, la asignación de pasajeros y las rutas a seguir, de forma de **minimizar el costo total del grupo de pasajeros**.

## Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- el número máximo de taxis para  $N$  pasajeros es  $N$ .
- Costo de un taxi = **costo inicial** (“bajada de bandera”) + **costo determinado por la distancia**.
- No se consideran otros posibles costos (e.g. esperas, propinas, peajes).

# Descripción del problema

## Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas ubicadas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Se busca determinar la cantidad de taxis, la asignación de pasajeros y las rutas a seguir, de forma de **minimizar el costo total del grupo de pasajeros**.

## Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- el número máximo de taxis para  $N$  pasajeros es  $N$ .
- Costo de un taxi = **costo inicial** (“bajada de bandera”) + **costo determinado por la distancia**.
- No se consideran otros posibles costos (e.g. esperas, propinas, peajes).

# Formulación del problema

- un conjunto de pasajeros  $P = \{p_1, p_2, \dots, p_N\}$  que viajan desde un origen común  $O$  a un conjunto de destinos  $D = \{d_1, d_2, \dots, d_N\}$ .
- un conjunto de taxis  $T = \{t_1, t_2, \dots, t_M\}$ ; con  $M \leq N$ ; y una función  $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$  que indica la cantidad de pasajeros en un taxi.  $C_{MAX}$  es la capacidad máxima permitida en un mismo taxi.
- una constante  $B$  indica el costo inicial del taxi (“bajada de bandera”).
- una función de distancia,  $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$ .
- una función de costo asociado a la distancia recorrida por cada taxi,  $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$ .

Se desea hallar la planificación  $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$  que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} cost \left( dist \left( \underbrace{dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j))}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right) \right]$$

# Formulación del problema

- un conjunto de pasajeros  $P = \{p_1, p_2, \dots, p_N\}$  que viajan desde un origen común  $O$  a un conjunto de destinos  $D = \{d_1, d_2, \dots, d_N\}$ .
- un conjunto de taxis  $T = \{t_1, t_2, \dots, t_M\}$ ; con  $M \leq N$ ; y una función  $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$  que indica la cantidad de pasajeros en un taxi.  $C_{MAX}$  es la capacidad máxima permitida en un mismo taxi.
- una constante  $B$  indica el costo inicial del taxi (“bajada de bandera”).
- una función de distancia,  $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$ .
- una función de costo asociado a la distancia recorrida por cada taxi,  $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$ .

Se desea hallar la planificación  $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$  que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \underbrace{cost \left( dist \left( dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right]$$

# Formulación del problema

- un conjunto de pasajeros  $P = \{p_1, p_2, \dots, p_N\}$  que viajan desde un origen común  $O$  a un conjunto de destinos  $D = \{d_1, d_2, \dots, d_N\}$ .
- un conjunto de taxis  $T = \{t_1, t_2, \dots, t_M\}$ ; con  $M \leq N$ ; y una función  $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$  que indica la cantidad de pasajeros en un taxi.  $C_{MAX}$  es la capacidad máxima permitida en un mismo taxi.
- una constante  $B$  indica el costo inicial del taxi (“bajada de bandera”).
- una función de distancia,  $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$ .
- una función de costo asociado a la distancia recorrida por cada taxi,  $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$ .

Se desea hallar la planificación  $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$  que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \underbrace{cost \left( dist \left( dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right]$$

# Formulación del problema

- un conjunto de pasajeros  $P = \{p_1, p_2, \dots, p_N\}$  que viajan desde un origen común  $O$  a un conjunto de destinos  $D = \{d_1, d_2, \dots, d_N\}$ .
- un conjunto de taxis  $T = \{t_1, t_2, \dots, t_M\}$ ; con  $M \leq N$ ; y una función  $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$  que indica la cantidad de pasajeros en un taxi.  $C_{MAX}$  es la capacidad máxima permitida en un mismo taxi.
- una constante  $B$  indica el costo inicial del taxi (“bajada de bandera”).
- una función de distancia,  $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$ .
- una función de costo asociado a la distancia recorrida por cada taxi,  $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$ .

Se desea hallar la planificación  $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$  que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \underbrace{cost \left( dist \left( dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right]$$

# Formulación del problema

- un conjunto de pasajeros  $P = \{p_1, p_2, \dots, p_N\}$  que viajan desde un origen común  $O$  a un conjunto de destinos  $D = \{d_1, d_2, \dots, d_N\}$ .
- un conjunto de taxis  $T = \{t_1, t_2, \dots, t_M\}$ ; con  $M \leq N$ ; y una función  $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$  que indica la cantidad de pasajeros en un taxi.  $C_{MAX}$  es la capacidad máxima permitida en un mismo taxi.
- una constante  $B$  indica el costo inicial del taxi (“bajada de bandera”).
- una función de distancia,  $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$ .
- una función de costo asociado a la distancia recorrida por cada taxi,  $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$ .

Se desea hallar la planificación  $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$  que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} cost \left( dist \left( \underbrace{dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j))}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right) \right]$$



# Formulación del problema

- un conjunto de pasajeros  $P = \{p_1, p_2, \dots, p_N\}$  que viajan desde un origen común  $O$  a un conjunto de destinos  $D = \{d_1, d_2, \dots, d_N\}$ .
- un conjunto de taxis  $T = \{t_1, t_2, \dots, t_M\}$ ; con  $M \leq N$ ; y una función  $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$  que indica la cantidad de pasajeros en un taxi.  $C_{MAX}$  es la capacidad máxima permitida en un mismo taxi.
- una constante  $B$  indica el costo inicial del taxi (“bajada de bandera”).
- una función de distancia,  $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$ .
- una función de costo asociado a la distancia recorrida por cada taxi,  $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$ .

Se desea hallar la planificación  $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$  que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} cost \left( dist \left( \underbrace{dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j))}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right) \right]$$

# Variante multiobjetivo del PVCT: formulación matemática

Se busca minimizar simultáneamente el **costo total** y la **demora total**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \text{cost} \left( \overbrace{\text{dist} \left( \text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[ \sum_{j=1}^{C(t_i)} \left[ \overbrace{\sum_{h=1}^j \text{time} \left( \text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}^{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} \right. \right. \\ \left. \left. - \underbrace{\text{tol}(f^{-1}(t_i, j)) + \text{time} \left( O, \text{dest}(f^{-1}(t_i, j)) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

- $\text{time} : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$  indica el tiempo de recorrido.
- $\text{tol} : P \rightarrow \mathbb{R}_0^+$  indica el tiempo adicional tolerado por cada pasajero.

# Variante multiobjetivo del PVCT: formulación matemática

Se busca minimizar simultáneamente el **costo total** y la **demora total**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \text{cost} \left( \overbrace{\text{dist} \left( \text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[ \sum_{j=1}^{C(t_i)} \left[ \overbrace{\sum_{h=1}^j \text{time} \left( \text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}^{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} \right. \right. \\ \left. \left. - \underbrace{\text{tol}(f^{-1}(t_i, j)) + \text{time} \left( O, \text{dest}(f^{-1}(t_i, j)) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

- $\text{time} : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$  indica el tiempo de recorrido.
- $\text{tol} : P \rightarrow \mathbb{R}_0^+$  indica el tiempo adicional tolerado por cada pasajero.

# Variante multiobjetivo del PVCT: formulación matemática

Se busca minimizar simultáneamente el **costo total** y la **demora total**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \text{cost} \left( \overbrace{\text{dist} \left( \text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[ \sum_{j=1}^{C(t_i)} \left[ \overbrace{\sum_{h=1}^j \text{time} \left( \text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}^{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} \right. \right. \\ \left. \left. - \underbrace{\text{tol}(f^{-1}(t_i, j)) + \text{time} \left( O, \text{dest}(f^{-1}(t_i, j)) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

- $\text{time} : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$  indica el tiempo de recorrido.
- $\text{tol} : P \rightarrow \mathbb{R}_0^+$  indica el tiempo adicional tolerado por cada pasajero.

## Complejidad

Baldacci et al. (2004) estudiaron una variante del *Car Pooling Problem* (CPP) donde trabajadores desean compartir vehículos hacia y desde el lugar de trabajo.

Esta variante es un caso particular del *Vehicle Routing Problem* (VRP) con demanda unitaria, el cual es  $\mathcal{NP}$ -difícil [Letchford et al. (2002)].

## Estrategias de resolución

Cuando se utilizan instancias de tamaños realistas, los algoritmos exactos tradicionales no resultan útiles para una planificación eficiente.

Heurísticas y metaheurísticas permiten calcular soluciones de calidad aceptable en tiempos razonables.

## Complejidad

Baldacci et al. (2004) estudiaron una variante del *Car Pooling Problem* (CPP) donde trabajadores desean compartir vehículos hacia y desde el lugar de trabajo.

Esta variante es un caso particular del *Vehicle Routing Problem* (VRP) con demanda unitaria, el cual es  $\mathcal{NP}$ -difícil [Letchford et al. (2002)].

## Estrategias de resolución

Cuando se utilizan instancias de tamaños realistas, los algoritmos exactos tradicionales no resultan útiles para una planificación eficiente.

**Heurísticas** y **metaheurísticas** permiten calcular soluciones de calidad aceptable en tiempos razonables.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado**
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

# Trabajo relacionado

## Car pooling problem (CPP)

Yan et al. (2011) **CPP con histórico de viajes** (relajación lagrangeana).

## Dial-a-ride problem (DARP)

Cordeau et al. (2003) **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

## Taxi pooling problem (TPP)

Tao et al. (2007) Heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013) TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

## Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.



# Trabajo relacionado

## Car pooling problem (CPP)

Yan et al. (2011) **CPP con histórico de viajes** (relajación lagrangeana).

## Dial-a-ride problem (DARP)

Cordeau et al. (2003) **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

## Taxi pooling problem (TPP)

Tao et al. (2007) Heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013) TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

## Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

# Trabajo relacionado

## Car pooling problem (CPP)

Yan et al. (2011) **CPP con histórico de viajes** (relajación lagrangeana).

## Dial-a-ride problem (DARP)

Cordeau et al. (2003) **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

## Taxi pooling problem (TPP)

Tao et al. (2007) Heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013) TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

## Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

# Trabajo relacionado

## Car pooling problem (CPP)

Yan et al. (2011) **CPP con histórico de viajes** (relajación lagrangeana).

## Dial-a-ride problem (DARP)

Cordeau et al. (2003) **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

## Taxi pooling problem (TPP)

Tao et al. (2007) Heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013) TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

## Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

# Trabajo relacionado

## Car pooling problem (CPP)

Yan et al. (2011) **CPP con histórico de viajes** (relajación lagrangeana).

## Dial-a-ride problem (DARP)

Cordeau et al. (2003) **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

## Taxi pooling problem (TPP)

Tao et al. (2007) Heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013) TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

## Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación**
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

## Definición

- Los *algoritmos evolutivos* (AE) son técnicas estocásticas que emulan el proceso de evolución natural de las especies para resolver problemas de optimización, búsqueda y aprendizaje.
- Un AE es una técnica iterativa (cada iteración se denomina **generación**) que aplica operadores estocásticos sobre un conjunto de individuos (la **población**).
- Cada individuo en la población codifica una solución tentativa al problema y tiene un valor de **fitness**, dado por una función de evaluación que determina su adecuación para resolver el problema.
- El propósito del AE es mejorar el fitness de los individuos en la población mediante la aplicación iterativa de **operadores evolutivos** a individuos seleccionados según su fitness, guiando al AE hacia soluciones tentativas de mayor calidad.

# AE para el PVCT monoobjetivo

## Aspectos comunes

- Tuplas de largo  $2N - 1$   
 $N = \text{\#pasajeros}$ .
- Inicialización:  
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:  
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



# AE para el PVCT monoobjetivo

## Aspectos comunes

- Tuplas de largo  $2N - 1$   
 $N = \text{\#pasajeros}$ .
- Inicialización:  
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:  
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.






# AE para el PVCT monoobjetivo


## Aspectos comunes

- Tuplas de largo  $2N - 1$   
 $N = \text{\#pasajeros}$ .
- Inicialización:  
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:  
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



## Aspectos comunes


- Tuplas de largo  $2N - 1$   
 $N = \text{\#pasajeros}$ .
- Inicialización:  
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:  
desplaza ceros para  
romper secuencias de  
dígitos inválidas.
- Implementados en Malva.



# AE para el PVCT monoobjetivo

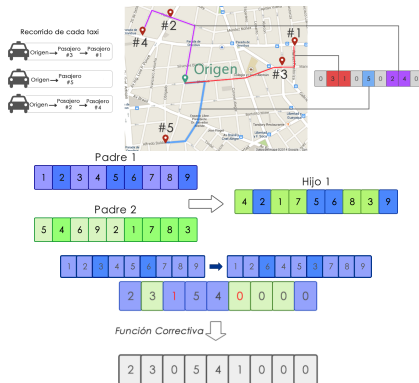
## Aspectos comunes

- Tuplas de largo  $2N - 1$   
 $N = \# \text{pasajeros}$ .
- Inicialización:  
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:  
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



## Aspectos comunes

- Tuplas de largo  $2N - 1$   
 $N = \text{\#pasajeros}$ .
- Inicialización:  
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:  
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



# AE para el PVCT monoobjetivo

## *seqEA*

AE **secuencial**. Utiliza selección proporcional.

## Modelos paralelos en AE

Buscan **mejorar el desempeño** de los AE.

**Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.

## AE paralelo con micro-población ( $p\mu EA$ )

- Poblaciones pequeñas.
- Selección por torneo  $(m, k)$ .
- Migración asíncrona.
- Topología de anillo unidireccional.

# AE para el PVCT monoobjetivo

## *seqEA*

AE **secuencial**. Utiliza selección proporcional.

## Modelos paralelos en AE

Buscan **mejorar el desempeño** de los AE.

**Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.

## AE paralelo con micro-población ( $p\mu EA$ )

- Poblaciones pequeñas.
- Selección por torneo ( $m, k$ ).
- Migración asíncrona.
- Topología de anillo unidireccional.

# AE para el PVCT monoobjetivo

## *seqEA*

AE **secuencial**. Utiliza selección proporcional.


## Modelos paralelos en AE

Buscan **mejorar el desempeño** de los AE.

**Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.

## AE paralelo con micro-población ( $p\mu EA$ )

- Poblaciones pequeñas.
- Selección por torneo ( $m, k$ ).
- Migración asíncrona.
- Topología de anillo unidireccional.



# AE para el PVCT multiobjetivo

## Propósitos en AE multiobjetivos (MOEA)

Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).

### $p\mu$ MOEA/D

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$

### NSGA-II

Ordenamiento no-dominado (elitista) y *crowding* para preservar diversidad.

### Aspectos comunes

Función correctiva considera vehículos de distintas capacidades.

Inicialización de la población ávida y selección por torneo.



# AE para el PVCT multiobjetivo


## Propósitos en AE multiobjetivos (MOEA)

Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).

### $p\mu$ MOEA/D

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$



## NSGA-II

Ordenamiento no-dominado (elitista) y *crowding* para preservar diversidad.

## Aspectos comunes

Función correctiva considera vehículos de distintas capacidades.

Inicialización de la población ávida y selección por torneo.

# AE para el PVCT multiobjetivo


## Propósitos en AE multiobjetivos (MOEA)

Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).

### $p\mu$ MOEA/D

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$



## NSGA-II

Ordenamiento no-dominado (elitista) y *crowding* para preservar diversidad.

## Aspectos comunes

Función correctiva considera vehículos de distintas capacidades.

Inicialización de la población ávida y selección por torneo.

# AE para el PVCT multiobjetivo

## Propósitos en AE multiobjetivos (MOEA)

Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).

### $p\mu$ MOEA/D

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$



## NSGA-II

Ordenamiento no-dominado (elitista) y *crowding* para preservar diversidad.

## Aspectos comunes

Función correctiva considera vehículos de distintas capacidades.  
Inicialización de la población ávida y selección por torneo.

# AE para el PVCT multiobjetivo

## Propósitos en AE multiobjetivos (MOEA)

Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).

### $p\mu$ MOEA/D

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$



## NSGA-II

Ordenamiento no-dominado (elitista) y *crowding* para preservar diversidad.

## Aspectos comunes

Función correctiva considera vehículos de distintas capacidades.  
Inicialización de la población ávida y selección por torneo.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación
- 5 Evaluación experimental**
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

# Generación de instancias

## Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- Instancias en Montevideo generadas manualmente.
- API para obtener tarifas TaxiFareFinder (TFF).

## Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

Cuatro variantes de cada instancias para el PVCT multiobjetivo considerando distintas capacidades y tolerancias.

# Generación de instancias

## Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- Instancias en Montevideo generadas manualmente.
- API para obtener tarifas TaxiFareFinder (TFF).

## Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

Cuatro variantes de cada instancias para el PVCT multiobjetivo considerando distintas capacidades y tolerancias.

## Entorno de ejecución

- La evaluación experimental fue realizada en el Cluster FING.
- **seqEA**: Dell Power Edge 2950, **1 núcleo** de Intel Xeon E5430 2.66GHz, 8GB RAM.
- **p $\mu$ EA**: HP Proliant DL585, **24 núcleos** de AMD Opteron 2.09GHz, 48GB RAM.

## Configuración paramétrica

- **seqEA**: 20 ejecuciones de 2000 generaciones sobre 3 instancias.  
 $\#P \in \{150, 200, 250\}$ ;  $p_C \in \{0,6, 0,75, 0,95\}$ ;  $p_M \in \{0,001, 0,01, 0,1\}$ .
- **p $\mu$ EA**: micro-población de 15 individuos, torneo ( $m = 2$ ,  $k = 1$ ), migración cada 500 generaciones.  
20 ejecuciones de 100.000 generaciones sobre 5 instancias.  
 $p_C \in \{0,6, 0,75, 0,95\}$ ;  $p_M \in \{0,001, 0,01, 0,1\}$ .



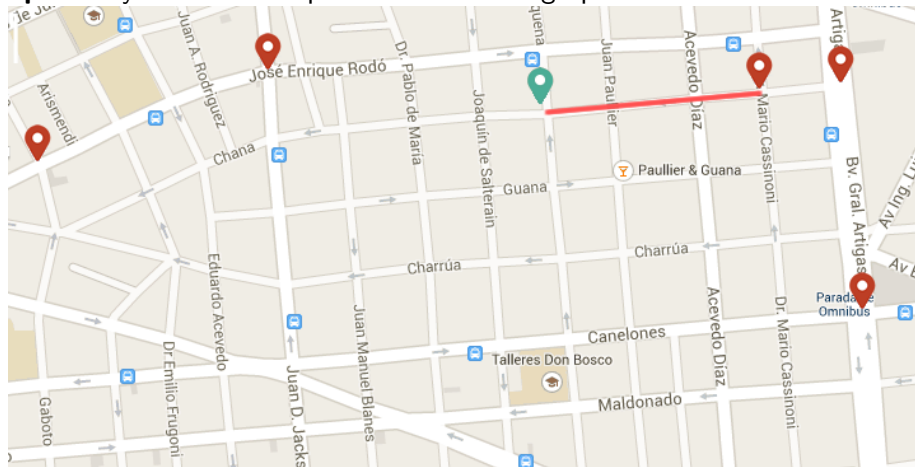
# Algoritmo ávido

Utiliza ideas de los trabajos relacionados. Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos.




# Algoritmo ávido

Utiliza ideas de los trabajos relacionados. Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos.



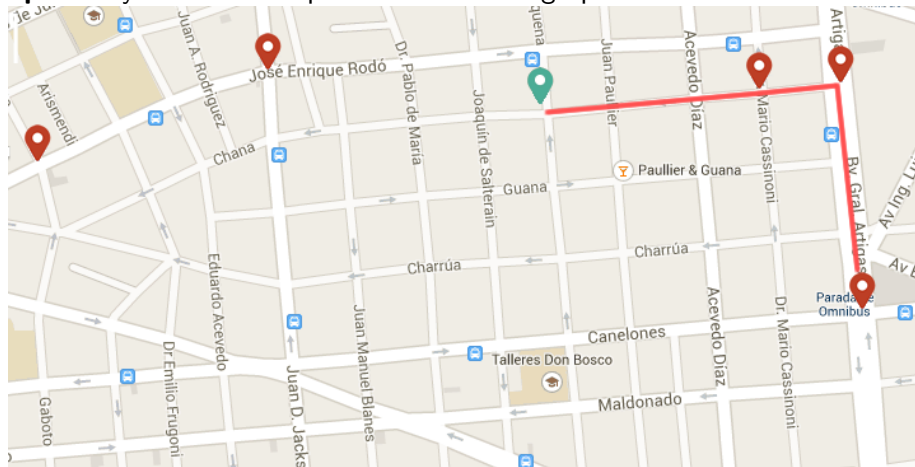
# Algoritmo ávido

Utiliza ideas de los trabajos relacionados. Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos.



# Algoritmo ávido


Utiliza ideas de los trabajos relacionados. Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos.





# Algoritmo ávido


Utiliza ideas de los trabajos relacionados. Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos.





# Algoritmo ávido

Utiliza ideas de los trabajos relacionados. Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos.





# Comparativa de métodos de inicialización

## Metodología

- Shapiro–Wilk afirma que los resultados no siguen una distribución normal.
- Se utilizó Kruskal–Wallis para comparar ambas inicializaciones.
- Kruskal–Wallis permite afirmar con un nivel de confianza del 95 % que una de las inicializaciones obtuvo mejores resultados que la otra.

## *seqEA* con inicialización aleatoria vs. inicialización ávida





La inicialización ávida supera a la inicialización aleatoria en **10** instancias de prueba, mientras que la inicialización aleatoria lo hace en tan solo **2**.

## *pμEA* con inicialización aleatoria vs. inicialización ávida

La inicialización ávida super a la inicialización aleatoria en **11** instancias de prueba, mientras que no hubo instancias en las que se pueda afirmar que la inicialización aleatoria haya alcanzado mejores soluciones.





# Mejora *seqEA* sobre algoritmo ávido

Se alcanzaron mejores valores en **todas** las instancias. En el mejor caso se superó el costo del algoritmo ávido en un **35.9 %**.



# Mejora $p\mu EA$ sobre algoritmo ávido

Se alcanzaron mejores valores en **todas** las instancias. En el mejor caso se superó el costo del algoritmo ávido en un **41.0 %**.







# Comparativa $seqEA$ vs. $p\mu EA$

Sobre un total de 22 instancias,  $p\mu EA$  es capaz de encontrar mejores resultados que  $seqEA$  en **17**. Únicamente en una instancia de prueba  $seqEA$  alcanzó mejores soluciones que  $p\mu EA$ .

instancia		$seqEA$		$p\mu EA$		$p\mu K-W$
		$min(c)$	$\bar{c} \pm std$	$min(c)$	$\bar{c} \pm std$	
chicas	#1	164.4	165.6 $\pm$ 2.0	164.4	<b>164.4<math>\pm</math>0.0</b>	$0.2 \times 10^{-3}$
	#2	220.7	225.7 $\pm$ 5.0	220.7	<b>220.7<math>\pm</math>0.0</b>	$9.7 \times 10^{-6}$
	#3	160.4	160.4 $\pm$ 0.0	160.4	160.4 $\pm$ 0.0	1.0
	#4	181.3	181.3 $\pm$ 0.1	181.3	182.4 $\pm$ 1.9	$0.5 \times 10^{-1}$
	#5	152.1	155.6 $\pm$ 4.5	152.1	<b>152.1<math>\pm</math>0.0</b>	$5.1 \times 10^{-6}$
	#6	118.4	119.6 $\pm$ 2.5	118.4	<b>118.4<math>\pm</math>0.0</b>	$0.1 \times 10^{-1}$
medianas	#1	211.9	216.0 $\pm$ 4.2	211.9	<b>211.9<math>\pm</math>0.0</b>	$5.2 \times 10^{-11}$
	#2	428.6	444.1 $\pm$ 11.7	427.9	<b>429.4<math>\pm</math>1.6</b>	$7.0 \times 10^{-10}$
	#3	361.7	378.7 $\pm$ 6.5	364.5	<b>370.4<math>\pm</math>4.5</b>	$1.6 \times 10^{-6}$
	#4	267.5	279.8 $\pm$ 5.5	266.8	<b>266.8<math>\pm</math>0.0</b>	$7.6 \times 10^{-12}$
	#5	479.3	487.1 $\pm$ 6.5	479.6	<b>479.8<math>\pm</math>0.2</b>	$5.1 \times 10^{-7}$
	#6	306.0	321.2 $\pm$ 7.7	306.0	<b>307.7<math>\pm</math>3.4</b>	$2.0 \times 10^{-9}$
grandes	#1	421.9	<b>435.1<math>\pm</math>5.0</b>	425.9	437.7 $\pm$ 3.2	$0.1 \times 10^{-1}$
	#2	479.3	489.9 $\pm$ 4.3	477.0	<b>481.1<math>\pm</math>2.3</b>	$1.9 \times 10^{-9}$
	#3	332.8	349.7 $\pm$ 7.7	326.3	<b>331.7<math>\pm</math>4.0</b>	$2.6 \times 10^{-10}$
	#4	351.1	390.7 $\pm$ 26.3	338.4	<b>344.8<math>\pm</math>6.1</b>	$5.1 \times 10^{-11}$
	#5	395.9	429.6 $\pm$ 16.2	370.2	<b>380.0<math>\pm</math>4.4</b>	$2.7 \times 10^{-11}$
	#6	360.8	382.4 $\pm$ 8.1	343.8	<b>350.6<math>\pm</math>3.8</b>	$2.6 \times 10^{-11}$
Montevideo	#1	168.4	168.4 $\pm$ 0.0	168.4	168.4 $\pm$ 0.0	1.0
	#2	319.3	331.2 $\pm$ 3.8	324.9	<b>328.6<math>\pm</math>3.2</b>	$5.6 \times 10^{-6}$
	#3	266.7	269.1 $\pm$ 2.3	266.7	<b>266.7<math>\pm</math>0.0</b>	$3.1 \times 10^{-7}$
	#4	303.2	304.7 $\pm$ 0.5	304.1	304.5 $\pm$ 0.4	0.1

# Evolución del costo a lo largo de la ejecución

$p\mu EA$  alcanza mejores soluciones que  $seqEA$  en menos tiempo. En el mejor caso la aceleración es de 7,5x (4,6x en promedio).



## Entorno de ejecución

- La evaluación experimental fue realizada en el Cluster FING.
- **p $\mu$ MOEA/D**: HP Proliant DL585, **24 núcleos** de AMD Opteron 2.09GHz, 48GB RAM.
- **NSGA-II**: HP Proliant DL385 G7, **1 núcleo** de AMD Opteron 6172 2.10GHz, 72GB RAM.

## Configuración paramétrica

- **p $\mu$ MOEA/D**: 30 ejecuciones de 20000 generaciones sobre 4 instancias.  
 $P = 15$ ;  $p_C \in \{0,6, 0,75, 0,95\}$ ;  $p_M \in \{0,001, 0,01, 0,1\}$ ; operador de migración cada 1000 generaciones.
- **NSGA-II**: 30 ejecuciones de 5000 generaciones sobre 4 instancias.  
 $P = 80$ ;  $p_C \in \{0,6, 0,75, 0,95\}$ ;  $p_M \in \{0,001, 0,01, 0,1\}$ .

**FALTA**

# Métricas multiobjetivo

## $p\mu$ MOEA/D

Se logra una buena convergencia y diversidad. Sin embargo, la cantidad de soluciones no dominadas es baja, indicando que se puede mejorar.

	#ND	DG	spacing	spread	RHV
chicas	8.5±2.1 (16.0)	3.1±2.5 (0.0)	740.2±746.3 (58.1)	0.6±0.2 (0.1)	0.9±0.1 (1.0)
medianas	9.1±2.2 (19.0)	5.7±2.5 (0.0)	1448.5±1064.1 (141.6)	0.6±0.1 (0.1)	0.9±0.1 (1.0)
grandes	8.5±2.2 (17.0)	7.9±3.4 (2.0)	2917.2±2041.5 (175.3)	0.6±0.1 (0.0)	0.8±0.1 (1.0)
Montevideo	8.0±2.1 (14.0)	3.0±2.0 (0.0)	663.5±542.4 (61.5)	0.6±0.2 (0.0)	0.9±0.0 (1.0)

## NSGA-II

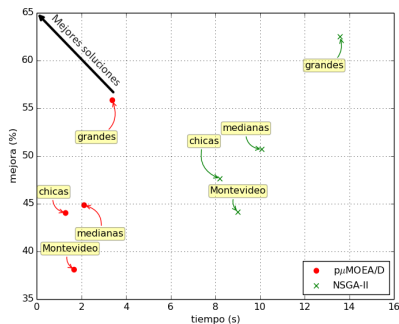
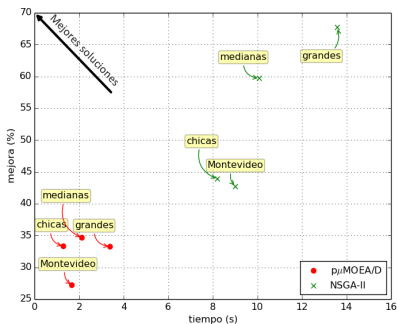
La cantidad de puntos no dominados es mayor. La distancia generacional indica una buena convergencia y se logra una mayor dispersión.

	#ND	DG	spacing	spread	RHV
chicas	32.6±9.5 (55.0)	0.3±0.6 (0.0)	236.2±222.7 (43.2)	0.9±0.1 (0.7)	1.0±0.0 (1.0)
medianas	54.5±4.2 (67.0)	1.0±0.7 (0.0)	193.6±202.4 (26.2)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
grandes	55.2±3.5 (67.0)	1.8±1.1 (0.4)	243.6±229.8 (26.4)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
Montevideo	43.9±16.4 (61.0)	0.4±0.5 (0.0)	142.3±143.2 (20.8)	0.8±0.1 (0.5)	1.0±0.0 (1.0)







# Mejora frente a algoritmos ávidos vs. tiempo de ejecución

El enfoque multiobjetivo explícito de *NSGA-II* permite alcanzar mejores resultados que el enfoque por descomposición de dominio aplicado en *p<sub>μ</sub>MOEA/D*. Sin embargo, los tiempos de ejecución son significativamente mayores.



# Frentes de Pareto: $p\mu$ MOEA/D vs. NSGA-II

*NSGA-II* alcanza mejores soluciones con una mayor cantidad de puntos no dominados distribuidos homogéneamente a lo largo del frente.



- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea**
- 7 Conclusiones y trabajo futuro

# Planificador de viajes compartidos en línea

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

# Conclusiones y trabajo futuro