

Optimización de viajes compartidos en taxis utilizando algoritmos evolutivos

Gabriel Fagúndez de los Reyes Renzo Massobrio

Facultad de Ingeniería,
Universidad de la República,
Montevideo, Uruguay



Contenido

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

Car pooling

- Beneficios en el plano ecológico y económico, individuales y colectivos.
- Iniciativas para atender el interés del público: carriles exclusivos, campañas para compartir los viajes al trabajo y aplicaciones para encontrar compañeros de viaje.

Taxi pooling

- Los taxis son un medio de transporte rápido y confiable, especialmente en ciudades donde el transporte público es poco eficiente.
- Los taxis raramente viajan a capacidad completa, impactando en la congestión del tráfico y en la contaminación de las ciudades.
- Tarifas altas desalientan a los usuarios.
- 15 % de los accidentes fatales en Uruguay involucran a un conductor alcoholizado (UNASEV).

Car pooling

- Beneficios en el plano ecológico y económico, individuales y colectivos.
- Iniciativas para atender el interés del público: carriles exclusivos, campañas para compartir los viajes al trabajo y aplicaciones para encontrar compañeros de viaje.

Taxi pooling

- Los taxis son un medio de transporte rápido y confiable, especialmente en ciudades donde el transporte público es poco eficiente.
- Los taxis raramente viajan a capacidad completa, impactando en la congestión del tráfico y en la contaminación de las ciudades.
- Tarifas altas desalientan a los usuarios.
- **15 %** de los accidentes fatales en Uruguay involucran a un conductor alcoholizado (UNASEV).

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

Descripción del problema

Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas ubicadas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Se busca determinar la cantidad de taxis, la asignación de pasajeros y las rutas a seguir, de forma de **minimizar el costo total del grupo de pasajeros**.

Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- el número máximo de taxis para N pasajeros es N .
- Costo de un taxi = **costo inicial** (“bajada de bandera”) + **costo determinado por la distancia**.
- No se consideran otros posibles costos (e.g. esperas, propinas, peajes).

Descripción del problema

Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas ubicadas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Se busca determinar la cantidad de taxis, la asignación de pasajeros y las rutas a seguir, de forma de **minimizar el costo total del grupo de pasajeros**.

Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- el número máximo de taxis para N pasajeros es N .
- Costo de un taxi = **costo inicial** (“bajada de bandera”) + **costo determinado por la distancia**.
- No se consideran otros posibles costos (e.g. esperas, propinas, peajes).

Descripción del problema

Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas ubicadas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Se busca determinar la cantidad de taxis, la asignación de pasajeros y las rutas a seguir, de forma de **minimizar el costo total del grupo de pasajeros**.

Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- el número máximo de taxis para N pasajeros es N .
- Costo de un taxi = **costo inicial** ("bajada de bandera") + **costo determinado por la distancia**.
- No se consideran otros posibles costos (e.g. esperas, propinas, peajes).

Descripción del problema

Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas ubicadas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Se busca determinar la cantidad de taxis, la asignación de pasajeros y las rutas a seguir, de forma de **minimizar el costo total del grupo de pasajeros**.

Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- el número máximo de taxis para N pasajeros es N .
- Costo de un taxi = **costo inicial** (“bajada de bandera”) + **costo determinado por la distancia**.
- No se consideran otros posibles costos (e.g. esperas, propinas, peajes).

Descripción del problema

Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas ubicadas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Se busca determinar la cantidad de taxis, la asignación de pasajeros y las rutas a seguir, de forma de **minimizar el costo total del grupo de pasajeros**.

Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- el número máximo de taxis para N pasajeros es N .
- Costo de un taxi = **costo inicial** (“bajada de bandera”) + **costo determinado por la distancia**.
- No se consideran otros posibles costos (e.g. esperas, propinas, peajes).

Formulación del problema

- un conjunto de pasajeros $P = \{p_1, p_2, \dots, p_N\}$ que viajan desde un origen común O a un conjunto de destinos $D = \{d_1, d_2, \dots, d_N\}$.
- un conjunto de taxis $T = \{t_1, t_2, \dots, t_M\}$; con $M \leq N$; y una función $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$ que indica la cantidad de pasajeros en un taxi. C_{MAX} es la capacidad máxima permitida en un mismo taxi.
- una constante B indica el costo inicial del taxi (“bajada de bandera”).
- una función de distancia, $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$.
- una función de costo asociado a la distancia recorrida por cada taxi, $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$.

Se desea hallar la planificación $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$ que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \underbrace{cost \left(dist \left(dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right]$$

Formulación del problema

- un conjunto de pasajeros $P = \{p_1, p_2, \dots, p_N\}$ que viajan desde un origen común O a un conjunto de destinos $D = \{d_1, d_2, \dots, d_N\}$.
- un conjunto de taxis $T = \{t_1, t_2, \dots, t_M\}$; con $M \leq N$; y una función $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$ que indica la cantidad de pasajeros en un taxi. C_{MAX} es la capacidad máxima permitida en un mismo taxi.
- una constante B indica el costo inicial del taxi (“bajada de bandera”).
- una función de distancia, $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$.
- una función de costo asociado a la distancia recorrida por cada taxi, $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$.

Se desea hallar la planificación $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$ que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \underbrace{cost \left(dist \left(dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right]$$

Formulación del problema

- un conjunto de pasajeros $P = \{p_1, p_2, \dots, p_N\}$ que viajan desde un origen común O a un conjunto de destinos $D = \{d_1, d_2, \dots, d_N\}$.
- un conjunto de taxis $T = \{t_1, t_2, \dots, t_M\}$; con $M \leq N$; y una función $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$ que indica la cantidad de pasajeros en un taxi. C_{MAX} es la capacidad máxima permitida en un mismo taxi.
- una constante B indica el costo inicial del taxi (“bajada de bandera”).
- una función de distancia, $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$.
- una función de costo asociado a la distancia recorrida por cada taxi, $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$.

Se desea hallar la planificación $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$ que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \underbrace{cost \left(dist \left(dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right]$$

Formulación del problema

- un conjunto de pasajeros $P = \{p_1, p_2, \dots, p_N\}$ que viajan desde un origen común O a un conjunto de destinos $D = \{d_1, d_2, \dots, d_N\}$.
- un conjunto de taxis $T = \{t_1, t_2, \dots, t_M\}$; con $M \leq N$; y una función $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$ que indica la cantidad de pasajeros en un taxi. C_{MAX} es la capacidad máxima permitida en un mismo taxi.
- una constante B indica el costo inicial del taxi (“bajada de bandera”).
- una función de distancia, $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$.
- una función de costo asociado a la distancia recorrida por cada taxi, $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$.

Se desea hallar la planificación $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$ que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \underbrace{cost \left(dist \left(dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right]$$

Formulación del problema

- un conjunto de pasajeros $P = \{p_1, p_2, \dots, p_N\}$ que viajan desde un origen común O a un conjunto de destinos $D = \{d_1, d_2, \dots, d_N\}$.
- un conjunto de taxis $T = \{t_1, t_2, \dots, t_M\}$; con $M \leq N$; y una función $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$ que indica la cantidad de pasajeros en un taxi. C_{MAX} es la capacidad máxima permitida en un mismo taxi.
- una constante B indica el costo inicial del taxi (“bajada de bandera”).
- una función de distancia, $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$.
- una función de costo asociado a la distancia recorrida por cada taxi, $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$.

Se desea hallar la planificación $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$ que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \underbrace{cost \left(dist \left(dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right]$$

Formulación del problema

- un conjunto de pasajeros $P = \{p_1, p_2, \dots, p_N\}$ que viajan desde un origen común O a un conjunto de destinos $D = \{d_1, d_2, \dots, d_N\}$.
- un conjunto de taxis $T = \{t_1, t_2, \dots, t_M\}$; con $M \leq N$; y una función $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$ que indica la cantidad de pasajeros en un taxi. C_{MAX} es la capacidad máxima permitida en un mismo taxi.
- una constante B indica el costo inicial del taxi (“bajada de bandera”).
- una función de distancia, $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$.
- una función de costo asociado a la distancia recorrida por cada taxi, $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$.

Se desea hallar la planificación $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$ que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} cost \left(dist \left(\underbrace{dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j))}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right) \right]$$

Variante multiobjetivo del PVCT: formulación matemática

Se busca minimizar simultáneamente el **costo total** y la **demora total**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \text{cost} \left(\overbrace{\text{dist} \left(\text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[\sum_{j=1}^{C(t_i)} \left[\overbrace{\sum_{h=1}^j \text{time} \left(\text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}^{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} \right. \right. \\ \left. \left. - \underbrace{\text{tol}(f^{-1}(t_i, j)) + \text{time} \left(O, \text{dest}(f^{-1}(t_i, j)) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

- $\text{time} : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$ indica el tiempo de recorrido.
- $\text{tol} : P \rightarrow \mathbb{R}_0^+$ indica el tiempo adicional tolerado por cada pasajero.

Variante multiobjetivo del PVCT: formulación matemática

Se busca minimizar simultáneamente el **costo total** y la **demora total**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \text{cost} \left(\overbrace{\text{dist} \left(\text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[\sum_{j=1}^{C(t_i)} \left[\overbrace{\sum_{h=1}^j \text{time} \left(\text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}^{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} \right. \right. \\ \left. \left. - \underbrace{\text{tol}(f^{-1}(t_i, j)) + \text{time} \left(O, \text{dest}(f^{-1}(t_i, j)) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

- $\text{time} : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$ indica el tiempo de recorrido.
- $\text{tol} : P \rightarrow \mathbb{R}_0^+$ indica el tiempo adicional tolerado por cada pasajero.

Variante multiobjetivo del PVCT: formulación matemática

Se busca minimizar simultáneamente el **costo total** y la **demora total**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \text{cost} \left(\overbrace{\text{dist} \left(\text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[\sum_{j=1}^{C(t_i)} \left[\overbrace{\sum_{h=1}^j \text{time} \left(\text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}^{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} \right. \right. \\ \left. \left. - \underbrace{\text{tol}(f^{-1}(t_i, j)) + \text{time} \left(O, \text{dest}(f^{-1}(t_i, j)) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

- $\text{time} : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$ indica el tiempo de recorrido.
- $\text{tol} : P \rightarrow \mathbb{R}_0^+$ indica el tiempo adicional tolerado por cada pasajero.

Complejidad

Baldacci et al. (2004) estudiaron una variante del *Car Pooling Problem* (CPP) donde trabajadores desean compartir vehículos hacia y desde el lugar de trabajo.

Esta variante es un caso particular del *Vehicle Routing Problem* (VRP) con demanda unitaria, el cual es \mathcal{NP} -difícil [Letchford et al. (2002)].

Estrategias de resolución

Cuando se utilizan instancias de tamaños realistas, los algoritmos exactos tradicionales no resultan útiles para una planificación eficiente.

Heurísticas y metaheurísticas permiten calcular soluciones de calidad aceptable en tiempos razonables.

Complejidad del PVCT

Complejidad

Baldacci et al. (2004) estudiaron una variante del *Car Pooling Problem* (CPP) donde trabajadores desean compartir vehículos hacia y desde el lugar de trabajo.

Esta variante es un caso particular del *Vehicle Routing Problem* (VRP) con demanda unitaria, el cual es \mathcal{NP} -difícil [Letchford et al. (2002)].

Estrategias de resolución

Cuando se utilizan instancias de tamaños realistas, los algoritmos exactos tradicionales no resultan útiles para una planificación eficiente.

Heurísticas y **metaheurísticas** permiten calcular soluciones de calidad aceptable en tiempos razonables.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado**
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

Trabajo relacionado

Car pooling problem (CPP)

Yan et al. (2011) **CPP con histórico de viajes** (relajación lagrangeana).

Dial-a-ride problem (DARP)

Cordeau et al. (2003) **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

Taxi pooling problem (TPP)

Tao et al. (2007) Heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013) TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

Trabajo relacionado

Car pooling problem (CPP)

Yan et al. (2011) **CPP con histórico de viajes** (relajación lagrangeana).

Dial-a-ride problem (DARP)

Cordeau et al. (2003) **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

Taxi pooling problem (TPP)

Tao et al. (2007) Heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013) TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

Trabajo relacionado

Car pooling problem (CPP)

Yan et al. (2011) **CPP con histórico de viajes** (relajación lagrangeana).

Dial-a-ride problem (DARP)

Cordeau et al. (2003) **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

Taxi pooling problem (TPP)

Tao et al. (2007) Heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013) TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

Trabajo relacionado

Car pooling problem (CPP)

Yan et al. (2011) **CPP con histórico de viajes** (relajación lagrangeana).

Dial-a-ride problem (DARP)

Cordeau et al. (2003) **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

Taxi pooling problem (TPP)

Tao et al. (2007) Heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013) TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

Trabajo relacionado

Car pooling problem (CPP)

Yan et al. (2011) **CPP con histórico de viajes** (relajación lagrangeana).

Dial-a-ride problem (DARP)

Cordeau et al. (2003) **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

Taxi pooling problem (TPP)

Tao et al. (2007) Heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013) TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación**
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

Definición

- Los *algoritmos evolutivos* (AE) son técnicas estocásticas que emulan el proceso de evolución natural de las especies para resolver problemas de optimización, búsqueda y aprendizaje.
- Un AE es una técnica iterativa (cada iteración se denomina **generación**) que aplica operadores estocásticos sobre un conjunto de individuos (la **población**).
- Cada individuo en la población codifica una solución tentativa al problema y tiene un valor de **fitness**, dado por una función de evaluación que determina su adecuación para resolver el problema.
- El propósito del AE es mejorar el fitness de los individuos en la población mediante la aplicación iterativa de **operadores evolutivos** a individuos seleccionados según su fitness, guiando al AE hacia soluciones tentativas de mayor calidad.

AE para el PVCT monoobjetivo

Aspectos comunes

- Tuplas de largo $2N - 1$
 $N = \text{\#pasajeros}$.
- Inicialización:
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



AE para el PVCT monoobjetivo

Aspectos comunes


- Tuplas de largo $2N - 1$
 $N = \text{\#pasajeros}$.
- Inicialización:
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



AE para el PVCT monoobjetivo

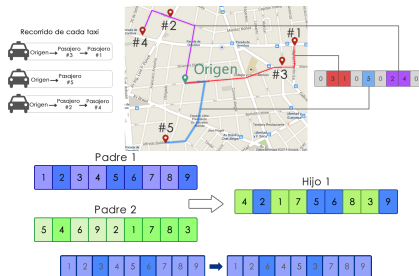
Aspectos comunes

- Tuplas de largo $2N - 1$
 $N = \text{\#pasajeros}$.
- Inicialización:
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



Aspectos comunes


- Tuplas de largo $2N - 1$
 $N = \text{\#pasajeros}$.
- Inicialización:
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:
desplaza ceros para
romper secuencias de
dígitos inválidas.
- Implementados en Malva.



AE para el PVCT monoobjetivo

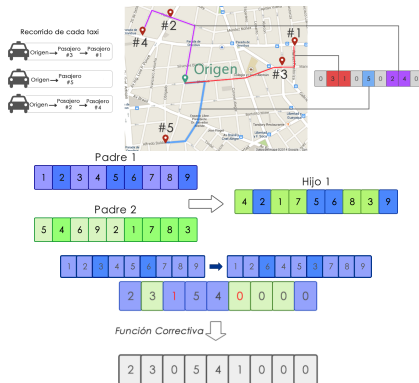
Aspectos comunes

- Tuplas de largo $2N - 1$
 $N = \# \text{pasajeros}$.
- Inicialización:
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



Aspectos comunes

- Tuplas de largo $2N - 1$
 $N = \# \text{pasajeros}$.
- Inicialización:
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



AE para el PVCT monoobjetivo

seqEA

AE **secuencial**. Utiliza selección proporcional.

Modelos paralelos en AE

Buscan **mejorar el desempeño** de los AE.

Modelo de subpoblaciones distribuidas: divide la población en **islas** que intercambian individuos mediante **migración**.

AE paralelo con micro-población ($p\mu EA$)

- Poblaciones pequeñas.
- Selección por torneo (m, k) .
- Migración asíncrona.
- Topología de anillo unidireccional.

AE para el PVCT monoobjetivo

seqEA

AE **secuencial**. Utiliza selección proporcional.

Modelos paralelos en AE

Buscan **mejorar el desempeño** de los AE.

Modelo de subpoblaciones distribuidas: divide la población en **islas** que intercambian individuos mediante **migración**.

AE paralelo con micro-población ($p\mu EA$)

- Poblaciones pequeñas.
- Selección por torneo (m, k).
- Migración asíncrona.
- Topología de anillo unidireccional.

AE para el PVCT monoobjetivo

seqEA

AE **secuencial**. Utiliza selección proporcional.


Modelos paralelos en AE

Buscan **mejorar el desempeño** de los AE.

Modelo de subpoblaciones distribuidas: divide la población en **islas** que intercambian individuos mediante **migración**.

AE paralelo con micro-población ($p\mu EA$)

- Poblaciones pequeñas.
- Selección por torneo (m, k).
- Migración asíncrona.
- Topología de anillo unidireccional.



AE para el PVCT multiobjetivo

Propósitos en AE multiobjetivos (MOEA)

Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).

$p\mu$ MOEA/D

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$

NSGA-II

Ordenamiento no-dominado (elitista) y *crowding* para preservar diversidad.

Aspectos comunes

Función correctiva considera vehículos de distintas capacidades.

Inicialización de la población ávida y selección por torneo.

AE para el PVCT multiobjetivo


Propósitos en AE multiobjetivos (MOEA)

Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).

$p\mu$ MOEA/D

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$



NSGA-II

Ordenamiento no-dominado (elitista) y *crowding* para preservar diversidad.

Aspectos comunes

Función correctiva considera vehículos de distintas capacidades.

Inicialización de la población ávida y selección por torneo.

AE para el PVCT multiobjetivo


Propósitos en AE multiobjetivos (MOEA)

Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).

$p\mu$ MOEA/D

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$



NSGA-II

Ordenamiento no-dominado (elitista) y *crowding* para preservar diversidad.

Aspectos comunes

Función correctiva considera vehículos de distintas capacidades.

Inicialización de la población ávida y selección por torneo.

AE para el PVCT multiobjetivo

Propósitos en AE multiobjetivos (MOEA)

Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).

$p\mu$ MOEA/D

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$



NSGA-II

Ordenamiento no-dominado (elitista) y *crowding* para preservar diversidad.

Aspectos comunes

Función correctiva considera vehículos de distintas capacidades.
Inicialización de la población ávida y selección por torneo.

AE para el PVCT multiobjetivo

Propósitos en AE multiobjetivos (MOEA)

Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).

$p\mu$ MOEA/D

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$



NSGA-II

Ordenamiento no-dominado (elitista) y *crowding* para preservar diversidad.

Aspectos comunes

Función correctiva considera vehículos de distintas capacidades.
Inicialización de la población ávida y selección por torneo.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación
- 5 Evaluación experimental**
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

Generación de instancias

Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- Instancias en Montevideo generadas manualmente.
- API para obtener tarifas TaxiFareFinder (TFF).

Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

Cuatro variantes de cada instancias para el PVCT multiobjetivo considerando distintas capacidades y tolerancias.

Generación de instancias

Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- Instancias en Montevideo generadas manualmente.
- API para obtener tarifas TaxiFareFinder (TFF).

Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

Cuatro variantes de cada instancias para el PVCT multiobjetivo considerando distintas capacidades y tolerancias.

Entorno de ejecución

- La evaluación experimental fue realizada en el Cluster FING.
- **seqEA**: Dell Power Edge 2950, **1 núcleo** de Intel Xeon E5430 2.66GHz, 8GB RAM.
- **p μ EA**: HP Proliant DL585, **24 núcleos** de AMD Opteron 2.09GHz, 48GB RAM.

Configuración paramétrica

- **seqEA**: 20 ejecuciones de 2000 generaciones sobre 3 instancias.
 $\#P \in \{150, 200, 250\}$; $p_C \in \{0,6, 0,75, 0,95\}$; $p_M \in \{0,001, 0,01, 0,1\}$.
- **p μ EA**: micro-población de 15 individuos, torneo ($m = 2$, $k = 1$), migración cada 500 generaciones.
20 ejecuciones de 100.000 generaciones sobre 5 instancias.
 $p_C \in \{0,6, 0,75, 0,95\}$; $p_M \in \{0,001, 0,01, 0,1\}$.


Algoritmo ávido

Utiliza ideas de los trabajos relacionados. Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos.




Algoritmo ávido

Utiliza ideas de los trabajos relacionados. Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos.



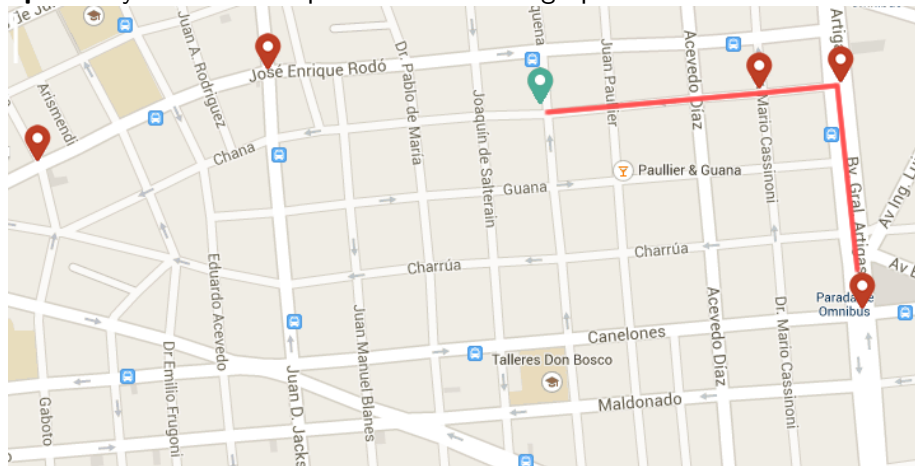
Algoritmo ávido

Utiliza ideas de los trabajos relacionados. Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos.



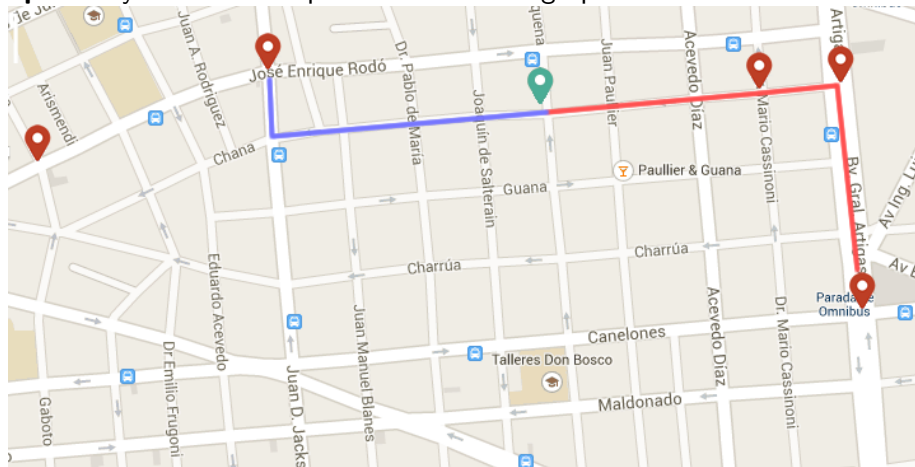
Algoritmo ávido

Utiliza ideas de los trabajos relacionados. Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos.




Algoritmo ávido

Utiliza ideas de los trabajos relacionados. Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos.



Algoritmo ávido

Utiliza ideas de los trabajos relacionados. Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos.



Comparativa de métodos de inicialización

Metodología

- Shapiro–Wilk afirma que los resultados no siguen una distribución normal.
- Se utilizó Kruskal–Wallis para comparar ambas inicializaciones.
- Kruskal–Wallis permite afirmar con un nivel de confianza del 95 % que una de las inicializaciones obtuvo mejores resultados que la otra.

seqEA con inicialización aleatoria vs. inicialización ávida





La inicialización ávida supera a la inicialización aleatoria en **10** instancias de prueba, mientras que la inicialización aleatoria lo hace en tan solo **2**.

pμEA con inicialización aleatoria vs. inicialización ávida

La inicialización ávida super a la inicialización aleatoria en **11** instancias de prueba, mientras que no hubo instancias en las que se pueda afirmar que la inicialización aleatoria haya alcanzado mejores soluciones.





Mejora *seqEA* sobre algoritmo ávido

Se alcanzaron mejores valores en **todas** las instancias. En el mejor caso se superó el costo del algoritmo ávido en un **35.9 %**.



Mejora $p\mu EA$ sobre algoritmo ávido

Se alcanzaron mejores valores en **todas** las instancias. En el mejor caso se superó el costo del algoritmo ávido en un **41.0 %**.







Comparativa $seqEA$ vs. $p\mu EA$

Sobre un total de 22 instancias, $p\mu EA$ es capaz de encontrar mejores resultados que $seqEA$ en **17**. Únicamente en una instancia de prueba $seqEA$ alcanzó mejores soluciones que $p\mu EA$.

| instancia | | $seqEA$ | | $p\mu EA$ | | $p\mu K-W$ |
|------------|----|----------|---------------------------------|-----------|---------------------------------|-----------------------|
| | | $min(c)$ | $\bar{c} \pm std$ | $min(c)$ | $\bar{c} \pm std$ | |
| chicas | #1 | 164.4 | 165.6 \pm 2.0 | 164.4 | 164.4\pm0.0 | 0.2×10^{-3} |
| | #2 | 220.7 | 225.7 \pm 5.0 | 220.7 | 220.7\pm0.0 | 9.7×10^{-6} |
| | #3 | 160.4 | 160.4 \pm 0.0 | 160.4 | 160.4 \pm 0.0 | 1.0 |
| | #4 | 181.3 | 181.3 \pm 0.1 | 181.3 | 182.4 \pm 1.9 | 0.5×10^{-1} |
| | #5 | 152.1 | 155.6 \pm 4.5 | 152.1 | 152.1\pm0.0 | 5.1×10^{-6} |
| | #6 | 118.4 | 119.6 \pm 2.5 | 118.4 | 118.4\pm0.0 | 0.1×10^{-1} |
| medianas | #1 | 211.9 | 216.0 \pm 4.2 | 211.9 | 211.9\pm0.0 | 5.2×10^{-11} |
| | #2 | 428.6 | 444.1 \pm 11.7 | 427.9 | 429.4\pm1.6 | 7.0×10^{-10} |
| | #3 | 361.7 | 378.7 \pm 6.5 | 364.5 | 370.4\pm4.5 | 1.6×10^{-6} |
| | #4 | 267.5 | 279.8 \pm 5.5 | 266.8 | 266.8\pm0.0 | 7.6×10^{-12} |
| | #5 | 479.3 | 487.1 \pm 6.5 | 479.6 | 479.8\pm0.2 | 5.1×10^{-7} |
| | #6 | 306.0 | 321.2 \pm 7.7 | 306.0 | 307.7\pm3.4 | 2.0×10^{-9} |
| grandes | #1 | 421.9 | 435.1\pm5.0 | 425.9 | 437.7 \pm 3.2 | 0.1×10^{-1} |
| | #2 | 479.3 | 489.9 \pm 4.3 | 477.0 | 481.1\pm2.3 | 1.9×10^{-9} |
| | #3 | 332.8 | 349.7 \pm 7.7 | 326.3 | 331.7\pm4.0 | 2.6×10^{-10} |
| | #4 | 351.1 | 390.7 \pm 26.3 | 338.4 | 344.8\pm6.1 | 5.1×10^{-11} |
| | #5 | 395.9 | 429.6 \pm 16.2 | 370.2 | 380.0\pm4.4 | 2.7×10^{-11} |
| | #6 | 360.8 | 382.4 \pm 8.1 | 343.8 | 350.6\pm3.8 | 2.6×10^{-11} |
| Montevideo | #1 | 168.4 | 168.4 \pm 0.0 | 168.4 | 168.4 \pm 0.0 | 1.0 |
| | #2 | 319.3 | 331.2 \pm 3.8 | 324.9 | 328.6\pm3.2 | 5.6×10^{-6} |
| | #3 | 266.7 | 269.1 \pm 2.3 | 266.7 | 266.7\pm0.0 | 3.1×10^{-7} |
| | #4 | 303.2 | 304.7 \pm 0.5 | 304.1 | 304.5 \pm 0.4 | 0.1 |

Evolución del costo a lo largo de la ejecución

$p\mu EA$ alcanza mejores soluciones que $seqEA$ en menos tiempo. En el mejor caso la aceleración es de 7,5x (4,6x en promedio).



Entorno de ejecución

- La evaluación experimental fue realizada en el Cluster FING.
- **p μ MOEA/D**: HP Proliant DL585, **24 núcleos** de AMD Opteron 2.09GHz, 48GB RAM.
- **NSGA-II**: HP Proliant DL385 G7, **1 núcleo** de AMD Opteron 6172 2.10GHz, 72GB RAM.

Configuración paramétrica

- **p μ MOEA/D**: 30 ejecuciones de 20000 generaciones sobre 4 instancias.
 $P = 15$; $p_C \in \{0,6, 0,75, 0,95\}$; $p_M \in \{0,001, 0,01, 0,1\}$; operador de migración cada 1000 generaciones.
- **NSGA-II**: 30 ejecuciones de 5000 generaciones sobre 4 instancias.
 $P = 80$; $p_C \in \{0,6, 0,75, 0,95\}$; $p_M \in \{0,001, 0,01, 0,1\}$.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea**
- 7 Conclusiones y trabajo futuro

Planificador de viajes compartidos en línea

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

Conclusiones

- Se relevó la literatura relacionada (CPP, DARP, TPP) y se presentaron dos variantes del problema.
- Se implementaron **cuatro** AE: dos para cada variante del problema.
- El análisis experimental se realizó sobre **instancias realistas**.
- Los AE implementados fueron comparados contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** ($p\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** ($p\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis, disponible públicamente en www.mepaseaste.uy.
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería de Muestra 2014” .

Conclusiones

- Se relevó la literatura relacionada (CPP, DARP, TPP) y se presentaron dos variantes del problema.
- Se implementaron **cuatro** AE: dos para cada variante del problema.
- El análisis experimental se realizó sobre **instancias realistas**.
- Los AE implementados fueron comparados contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** ($p\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** ($p\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis, disponible públicamente en www.mepaseaste.uy.
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

Conclusiones

- Se relevó la literatura relacionada (CPP, DARP, TPP) y se presentaron dos variantes del problema.
- Se implementaron **cuatro** AE: dos para cada variante del problema.
- El análisis experimental se realizó sobre **instancias realistas**.
- Los AE implementados fueron comparados contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** ($p\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** ($p\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis, disponible públicamente en www.mepaseaste.uy.
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

Conclusiones

- Se relevó la literatura relacionada (CPP, DARP, TPP) y se presentaron dos variantes del problema.
- Se implementaron **cuatro** AE: dos para cada variante del problema.
- El análisis experimental se realizó sobre **instancias realistas**.
- Los AE implementados fueron comparados contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p μ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p μ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis, disponible públicamente en www.mepaseaste.uy.
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

Conclusiones

- Se relevó la literatura relacionada (CPP, DARP, TPP) y se presentaron dos variantes del problema.
- Se implementaron **cuatro** AE: dos para cada variante del problema.
- El análisis experimental se realizó sobre **instancias realistas**.
- Los AE implementados fueron comparados contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p μ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p μ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis, disponible públicamente en www.mepaseaste.uy.
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

Conclusiones

- Se relevó la literatura relacionada (CPP, DARP, TPP) y se presentaron dos variantes del problema.
- Se implementaron **cuatro** AE: dos para cada variante del problema.
- El análisis experimental se realizó sobre **instancias realistas**.
- Los AE implementados fueron comparados contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p μ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p μ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis, disponible públicamente en www.mepaseaste.uy.
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

Conclusiones

- Se relevó la literatura relacionada (CPP, DARP, TPP) y se presentaron dos variantes del problema.
- Se implementaron **cuatro** AE: dos para cada variante del problema.
- El análisis experimental se realizó sobre **instancias realistas**.
- Los AE implementados fueron comparados contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p μ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p μ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis, disponible públicamente en www.mepaseaste.uy.
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

Conclusiones

- Se relevó la literatura relacionada (CPP, DARP, TPP) y se presentaron dos variantes del problema.
- Se implementaron **cuatro** AE: dos para cada variante del problema.
- El análisis experimental se realizó sobre **instancias realistas**.
- Los AE implementados fueron comparados contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p μ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p μ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis, disponible públicamente en www.mepaseaste.uy.
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería de Muestra 2014” .

Conclusiones

- Se relevó la literatura relacionada (CPP, DARP, TPP) y se presentaron dos variantes del problema.
- Se implementaron **cuatro** AE: dos para cada variante del problema.
- El análisis experimental se realizó sobre **instancias realistas**.
- Los AE implementados fueron comparados contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p μ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p μ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis, disponible públicamente en www.mepaseaste.uy.
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

- Variante de NSGA-II que utilice el modelo de subpoblaciones distribuidas.
- Incorporar datos realistas del tráfico para considerar rutas alternativas.
- Incorporar datos en tiempo real de la disponibilidad de los taxis.
- Mejorar la experiencia de los usuarios en el planificador de viajes compartidos.
- Desarrollar versiones para dispositivos móviles Android y Windows Phone.
- Soportar la variante multiobjetivo en el planificador de viajes compartidos.
- Estudiar la aplicabilidad de los AE a otros escenarios.
- Estudiar otras variantes del problema (e.g., many-to-one, many-to-many).