

# Optimización de viajes compartidos en taxis utilizando algoritmos evolutivos

Gabriel Fagúndez de los Reyes    Renzo Massobrio

Facultad de Ingeniería,  
Universidad de la República,  
Montevideo, Uruguay



- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

## Los viajes compartidos (*Car Pooling*)

- Beneficios en el plano ecológico y económico, individuales y colectivos.
- Iniciativas para atender el interés del público: carriles exclusivos, campañas para compartir los viajes al trabajo y aplicaciones para encontrar compañeros de viaje.

## Los viajes compartidos en taxis (*Taxi Pooling*)

- Los taxis son un medio de transporte rápido y confiable, especialmente en ciudades donde el transporte público es poco eficiente.
- Los taxis raramente viajan a capacidad completa, impactando en la congestión del tráfico y en la contaminación de las ciudades.
- Tarifas altas desalientan a los usuarios.
- 15 % de los accidentes fatales en Uruguay involucran a un conductor alcoholizado (UNASEV).

## Los viajes compartidos (*Car Pooling*)

- Beneficios en el plano ecológico y económico, individuales y colectivos.
- Iniciativas para atender el interés del público: carriles exclusivos, campañas para compartir los viajes al trabajo y aplicaciones para encontrar compañeros de viaje.

## Los viajes compartidos en taxis (*Taxi Pooling*)

- Los taxis son un medio de transporte rápido y confiable, especialmente en ciudades donde el transporte público es poco eficiente.
- Los taxis raramente viajan a capacidad completa, impactando en la congestión del tráfico y en la contaminación de las ciudades.
- Tarifas altas desalientan a los usuarios.
- **15 %** de los accidentes fatales en Uruguay involucran a un conductor alcoholizado (UNASEV).

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

# Descripción del problema

## Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas ubicadas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Se busca determinar la cantidad de taxis, la asignación de pasajeros y las rutas a seguir, de forma de **minimizar el costo total del grupo de pasajeros**.

## Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- El número máximo de taxis para  $N$  pasajeros es  $N$ .
- Costo de un taxi = **costo inicial** (“bajada de bandera”) + **costo determinado por la distancia**.
- No se consideran otros posibles costos (e.g. esperas, propinas, peajes).

# Descripción del problema

## Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas ubicadas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Se busca determinar la cantidad de taxis, la asignación de pasajeros y las rutas a seguir, de forma de **minimizar el costo total del grupo de pasajeros**.

## Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- El número máximo de taxis para  $N$  pasajeros es  $N$ .
- Costo de un taxi = **costo inicial** (“bajada de bandera”) + **costo determinado por la distancia**.
- No se consideran otros posibles costos (e.g. esperas, propinas, peajes).



# Descripción del problema

## Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas ubicadas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Se busca determinar la cantidad de taxis, la asignación de pasajeros y las rutas a seguir, de forma de **minimizar el costo total del grupo de pasajeros**.

## Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- El número máximo de taxis para  $N$  pasajeros es  $N$ .
- Costo de un taxi = **costo inicial** (“bajada de bandera”) + **costo determinado por la distancia**.
- No se consideran otros posibles costos (e.g. esperas, propinas, peajes).

# Descripción del problema

## Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas ubicadas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Se busca determinar la cantidad de taxis, la asignación de pasajeros y las rutas a seguir, de forma de **minimizar el costo total del grupo de pasajeros**.

## Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- El número máximo de taxis para  $N$  pasajeros es  $N$ .
- Costo de un taxi = **costo inicial** (“bajada de bandera”) + **costo determinado por la distancia**.
- No se consideran otros posibles costos (e.g. esperas, propinas, peajes).

# Descripción del problema

## Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas ubicadas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Se busca determinar la cantidad de taxis, la asignación de pasajeros y las rutas a seguir, de forma de **minimizar el costo total del grupo de pasajeros**.

## Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- El número máximo de taxis para  $N$  pasajeros es  $N$ .
- Costo de un taxi = **costo inicial** (“bajada de bandera”) + **costo determinado por la distancia**.
- No se consideran otros posibles costos (e.g. esperas, propinas, peajes).

# Formulación del problema

- Un conjunto de pasajeros  $P = \{p_1, p_2, \dots, p_N\}$  que viajan desde un origen común  $O$  a un conjunto de destinos  $D = \{d_1, d_2, \dots, d_N\}$ .
- Un conjunto de taxis  $T = \{t_1, t_2, \dots, t_M\}$ ; con  $M \leq N$ ; y una función  $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$  que indica la cantidad de pasajeros en un taxi.  $C_{MAX}$  es la capacidad máxima permitida en un mismo taxi.
- Una constante  $B$  indica el costo inicial del taxi (“bajada de bandera”).
- Una función de distancia,  $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$ .
- Una función de costo asociado a la distancia recorrida por cada taxi,  $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$ .

Se desea hallar la planificación  $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$  que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \underbrace{cost \left( dist \left( dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right]$$

# Formulación del problema

- Un conjunto de pasajeros  $P = \{p_1, p_2, \dots, p_N\}$  que viajan desde un origen común  $O$  a un conjunto de destinos  $D = \{d_1, d_2, \dots, d_N\}$ .
- Un conjunto de taxis  $T = \{t_1, t_2, \dots, t_M\}$ ; con  $M \leq N$ ; y una función  $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$  que indica la cantidad de pasajeros en un taxi.  $C_{MAX}$  es la capacidad máxima permitida en un mismo taxi.
- Una constante  $B$  indica el costo inicial del taxi (“bajada de bandera”).
- Una función de distancia,  $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$ .
- Una función de costo asociado a la distancia recorrida por cada taxi,  $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$ .

Se desea hallar la planificación  $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$  que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \underbrace{cost \left( dist \left( dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right]$$

# Formulación del problema

- Un conjunto de pasajeros  $P = \{p_1, p_2, \dots, p_N\}$  que viajan desde un origen común  $O$  a un conjunto de destinos  $D = \{d_1, d_2, \dots, d_N\}$ .
- Un conjunto de taxis  $T = \{t_1, t_2, \dots, t_M\}$ ; con  $M \leq N$ ; y una función  $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$  que indica la cantidad de pasajeros en un taxi.  $C_{MAX}$  es la capacidad máxima permitida en un mismo taxi.
- Una constante  $B$  indica el costo inicial del taxi (“bajada de bandera”).
- Una función de distancia,  $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$ .
- Una función de costo asociado a la distancia recorrida por cada taxi,  $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$ .

Se desea hallar la planificación  $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$  que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \underbrace{cost \left( dist \left( dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right]$$

# Formulación del problema

- Un conjunto de pasajeros  $P = \{p_1, p_2, \dots, p_N\}$  que viajan desde un origen común  $O$  a un conjunto de destinos  $D = \{d_1, d_2, \dots, d_N\}$ .
- Un conjunto de taxis  $T = \{t_1, t_2, \dots, t_M\}$ ; con  $M \leq N$ ; y una función  $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$  que indica la cantidad de pasajeros en un taxi.  $C_{MAX}$  es la capacidad máxima permitida en un mismo taxi.
- Una constante  $B$  indica el costo inicial del taxi (“bajada de bandera”).
- Una función de distancia,  $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$ .
- Una función de costo asociado a la distancia recorrida por cada taxi,  $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$ .

Se desea hallar la planificación  $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$  que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \underbrace{cost \left( dist \left( dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right]$$

# Formulación del problema

- Un conjunto de pasajeros  $P = \{p_1, p_2, \dots, p_N\}$  que viajan desde un origen común  $O$  a un conjunto de destinos  $D = \{d_1, d_2, \dots, d_N\}$ .
- Un conjunto de taxis  $T = \{t_1, t_2, \dots, t_M\}$ ; con  $M \leq N$ ; y una función  $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$  que indica la cantidad de pasajeros en un taxi.  $C_{MAX}$  es la capacidad máxima permitida en un mismo taxi.
- Una constante  $B$  indica el costo inicial del taxi (“bajada de bandera”).
- Una función de distancia,  $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$ .
- Una función de costo asociado a la distancia recorrida por cada taxi,  $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$ .

Se desea hallar la planificación  $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$  que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \underbrace{cost \left( dist \left( dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right]$$



# Formulación del problema

- Un conjunto de pasajeros  $P = \{p_1, p_2, \dots, p_N\}$  que viajan desde un origen común  $O$  a un conjunto de destinos  $D = \{d_1, d_2, \dots, d_N\}$ .
- Un conjunto de taxis  $T = \{t_1, t_2, \dots, t_M\}$ ; con  $M \leq N$ ; y una función  $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$  que indica la cantidad de pasajeros en un taxi.  $C_{MAX}$  es la capacidad máxima permitida en un mismo taxi.
- Una constante  $B$  indica el costo inicial del taxi (“bajada de bandera”).
- Una función de distancia,  $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$ .
- Una función de costo asociado a la distancia recorrida por cada taxi,  $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$ .

Se desea hallar la planificación  $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$  que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} cost \left( \underbrace{dist \left( dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

# Variante multiobjetivo del PVCT: formulación matemática

Se busca minimizar simultáneamente el **costo total** y la **demora total**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \text{cost} \left( \overbrace{\text{dist} \left( \text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[ \sum_{j=1}^{C(t_i)} \left[ \overbrace{\sum_{h=1}^j \text{time} \left( \text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}^{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} \right. \right. \\ \left. \left. - \underbrace{\text{tol}(f^{-1}(t_i, j)) + \text{time} \left( O, \text{dest}(f^{-1}(t_i, j)) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

- $\text{time} : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$  indica el tiempo de recorrido.
- $\text{tol} : P \rightarrow \mathbb{R}_0^+$  indica el tiempo adicional tolerado por cada pasajero.

# Variante multiobjetivo del PVCT: formulación matemática

Se busca minimizar simultáneamente el **costo total** y la **demora total**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \text{cost} \left( \overbrace{\text{dist} \left( \text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[ \sum_{j=1}^{C(t_i)} \left[ \overbrace{\sum_{h=1}^j \text{time} \left( \text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}^{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} \right. \right. \\ \left. \left. - \underbrace{\text{tol}(f^{-1}(t_i, j)) + \text{time} \left( O, \text{dest}(f^{-1}(t_i, j)) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

- $\text{time} : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$  indica el tiempo de recorrido.
- $\text{tol} : P \rightarrow \mathbb{R}_0^+$  indica el tiempo adicional tolerado por cada pasajero.

# Variante multiobjetivo del PVCT: formulación matemática

Se busca minimizar simultáneamente el **costo total** y la **demora total**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \text{cost} \left( \overbrace{\text{dist} \left( \text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[ \sum_{j=1}^{C(t_i)} \left[ \overbrace{\sum_{h=1}^j \text{time} \left( \text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}^{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} \right. \right. \\ \left. \left. - \underbrace{\text{tol}(f^{-1}(t_i, j)) + \text{time} \left( O, \text{dest}(f^{-1}(t_i, j)) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

- $\text{time} : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$  indica el tiempo de recorrido.
- $\text{tol} : P \rightarrow \mathbb{R}_0^+$  indica el tiempo adicional tolerado por cada pasajero.

## Complejidad

Baldacci et al. (2004) estudiaron una variante del *Car Pooling Problem* (CPP) donde trabajadores desean compartir vehículos hacia y desde el lugar de trabajo.

Esta variante es un caso particular del *Vehicle Routing Problem* (VRP) con demanda unitaria, el cual es  $\mathcal{NP}$ -difícil [Letchford et al. (2002)].

## Estrategias de resolución

Cuando se utilizan instancias de tamaños realistas, los algoritmos exactos tradicionales no resultan útiles para una planificación eficiente.

Heurísticas y metaheurísticas permiten calcular soluciones de calidad aceptable en tiempos razonables.

## Complejidad

Baldacci et al. (2004) estudiaron una variante del *Car Pooling Problem* (CPP) donde trabajadores desean compartir vehículos hacia y desde el lugar de trabajo.

Esta variante es un caso particular del *Vehicle Routing Problem* (VRP) con demanda unitaria, el cual es  $\mathcal{NP}$ -difícil [Letchford et al. (2002)].

## Estrategias de resolución

Cuando se utilizan instancias de tamaños realistas, los algoritmos exactos tradicionales no resultan útiles para una planificación eficiente.

**Heurísticas** y **metaheurísticas** permiten calcular soluciones de calidad aceptable en tiempos razonables.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado**
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

# Trabajo relacionado

## Car pooling problem (CPP)

Yan et al. (2011) **CPP con histórico de viajes** (relajación lagrangeana).

## Dial-a-ride problem (DARP)

Cordeau et al. (2003) **DARP estático con ventanas de tiempo.**

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

## Taxi pooling problem (TPP)

Tao et al. (2007) Heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013) TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas.**

## Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo.**



# Trabajo relacionado

## Car pooling problem (CPP)

Yan et al. (2011) **CPP con histórico de viajes** (relajación lagrangeana).

## Dial-a-ride problem (DARP)

Cordeau et al. (2003) **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

## Taxi pooling problem (TPP)

Tao et al. (2007) Heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013) TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

## Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

# Trabajo relacionado

## Car pooling problem (CPP)

Yan et al. (2011) **CPP con histórico de viajes** (relajación lagrangeana).

## Dial-a-ride problem (DARP)

Cordeau et al. (2003) **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

## Taxi pooling problem (TPP)

Tao et al. (2007) Heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013) TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

## Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

# Trabajo relacionado

## Car pooling problem (CPP)

Yan et al. (2011) **CPP con histórico de viajes** (relajación lagrangeana).

## Dial-a-ride problem (DARP)

Cordeau et al. (2003) **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

## Taxi pooling problem (TPP)

Tao et al. (2007) Heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013) TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

## Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación**
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

## Definición

- Los *algoritmos evolutivos* (AE) son técnicas estocásticas que emulan el proceso de evolución natural de las especies para resolver problemas de optimización, búsqueda y aprendizaje.
- Un AE es una técnica iterativa (cada iteración se denomina **generación**) que aplica operadores estocásticos sobre un conjunto de individuos (la **población**).
- Cada individuo en la población codifica una solución tentativa al problema y tiene un valor de **fitness**, dado por una función de evaluación que determina su adecuación para resolver el problema.
- El propósito del AE es mejorar el fitness de los individuos en la población mediante la aplicación iterativa de **operadores evolutivos** a individuos seleccionados según su fitness, guiando al AE hacia soluciones tentativas de mayor calidad.

## Definición

- Los *algoritmos evolutivos* (AE) son técnicas estocásticas que emulan el proceso de evolución natural de las especies para resolver problemas de optimización, búsqueda y aprendizaje.
- Un AE es una técnica iterativa (cada iteración se denomina **generación**) que aplica operadores estocásticos sobre un conjunto de individuos (la **población**).
- Cada individuo en la población codifica una solución tentativa al problema y tiene un valor de **fitness**, dado por una función de evaluación que determina su adecuación para resolver el problema.
- El propósito del AE es mejorar el fitness de los individuos en la población mediante la aplicación iterativa de **operadores evolutivos** a individuos seleccionados según su fitness, guiando al AE hacia soluciones tentativas de mayor calidad.

## Definición

- Los *algoritmos evolutivos* (AE) son técnicas estocásticas que emulan el proceso de evolución natural de las especies para resolver problemas de optimización, búsqueda y aprendizaje.
- Un AE es una técnica iterativa (cada iteración se denomina **generación**) que aplica operadores estocásticos sobre un conjunto de individuos (la **población**).
- Cada individuo en la población codifica una solución tentativa al problema y tiene un valor de **fitness**, dado por una función de evaluación que determina su adecuación para resolver el problema.
- El propósito del AE es mejorar el fitness de los individuos en la población mediante la aplicación iterativa de **operadores evolutivos** a individuos seleccionados según su fitness, guiando al AE hacia soluciones tentativas de mayor calidad.

## Definición


- Los *algoritmos evolutivos* (AE) son técnicas estocásticas que emulan el proceso de evolución natural de las especies para resolver problemas de optimización, búsqueda y aprendizaje.
- Un AE es una técnica iterativa (cada iteración se denomina **generación**) que aplica operadores estocásticos sobre un conjunto de individuos (la **población**).
- Cada individuo en la población codifica una solución tentativa al problema y tiene un valor de **fitness**, dado por una función de evaluación que determina su adecuación para resolver el problema.
- El propósito del AE es mejorar el fitness de los individuos en la población mediante la aplicación iterativa de **operadores evolutivos** a individuos seleccionados según su fitness, guiando al AE hacia soluciones tentativas de mayor calidad.



# AE para el PVCT monoobjetivo

## Aspectos comunes


- Tuplas de largo  $2N - 1$   
 $N = \text{\#pasajeros}$ .
- Inicialización:  
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:  
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



# AE para el PVCT monoobjetivo

## Aspectos comunes

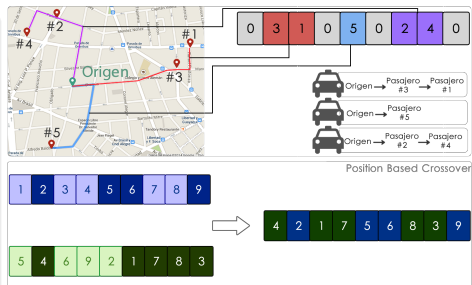
- Tuplas de largo  $2N - 1$   
 $N = \# \text{pasajeros}$ .
- Inicialización:  
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:  
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



# AE para el PVCT monoobjetivo

## Aspectos comunes

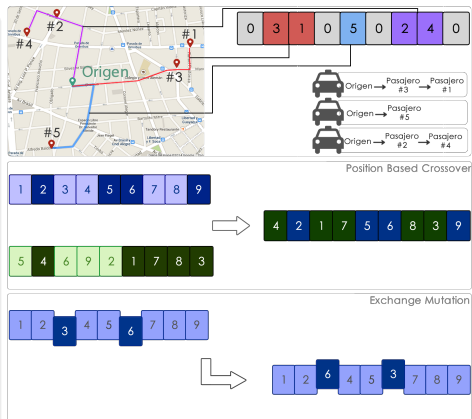
- Tuplas de largo  $2N - 1$   
 $N = \text{\#pasajeros}$ .
- Inicialización:  
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:  
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



# AE para el PVCT monoobjetivo

## Aspectos comunes


- Tuplas de largo  $2N - 1$   
 $N = \text{\#pasajeros}$ .
- Inicialización:  
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:  
desplaza ceros para  
romper secuencias de  
dígitos inválidas.
- Implementados en Malva.



# AE para el PVCT monoobjetivo

## Aspectos comunes

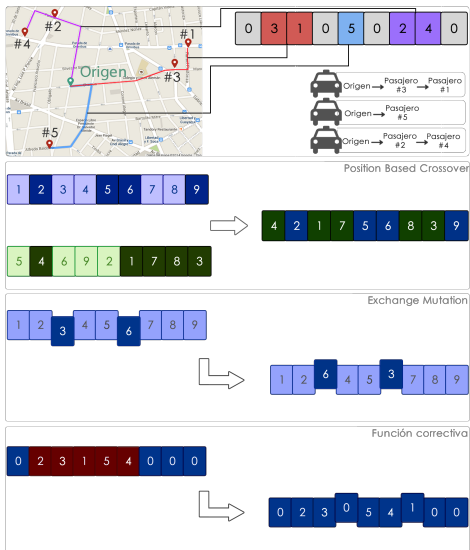
- Tuplas de largo  $2N - 1$   
 $N = \# \text{pasajeros}$ .
- Inicialización:  
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:  
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



# AE para el PVCT monoobjetivo

## Aspectos comunes

- Tuplas de largo  $2N - 1$   
 $N = \text{\#pasajeros}$ .
- Inicialización:  
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:  
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



# AE para el PVCT monoobjetivo

## *seqEA*

AE **secuencial**. Utiliza selección proporcional.

## Modelos paralelos en AE

Buscan **mejorar el desempeño** de los AE.

**Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.

## AE paralelo con micro-población ( $p\mu EA$ )

- Poblaciones pequeñas.
- Selección por torneo  $(m, k)$ .
- Migración asíncrona.
- Topología de anillo unidireccional.

# AE para el PVCT monoobjetivo

## *seqEA*

AE **secuencial**. Utiliza selección proporcional.

## Modelos paralelos en AE

Buscan **mejorar el desempeño** de los AE.

**Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.

## AE paralelo con micro-población ( $p\mu EA$ )

- Poblaciones pequeñas.
- Selección por torneo ( $m, k$ ).
- Migración asíncrona.
- Topología de anillo unidireccional.



# AE para el PVCT monoobjetivo

## *seqEA*

AE **secuencial**. Utiliza selección proporcional.


## Modelos paralelos en AE

Buscan **mejorar el desempeño** de los AE.

**Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.

## AE paralelo con micro-población ( $p\mu EA$ )

- Poblaciones pequeñas.
- Selección por torneo ( $m, k$ ).
- Migración asíncrona.
- Topología de anillo unidireccional.



# AE para el PVCT multiobjetivo

## Propósitos en AE multiobjetivos (MOEA)

Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).

$p\mu$ MOEA/D

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$

NSGA-II

Ordenamiento no-dominado (elitista) y *crowding* para preservar diversidad.

Aspectos comunes

Función correctiva considera vehículos de distintas capacidades.

Inicialización de la población ávida y selección por torneo.

# AE para el PVCT multiobjetivo


## Propósitos en AE multiobjetivos (MOEA)

Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).

### $p\mu$ MOEA/D

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$



## NSGA-II

Ordenamiento no-dominado (elitista) y *crowding* para preservar diversidad.

## Aspectos comunes

Función correctiva considera vehículos de distintas capacidades.

Inicialización de la población ávida y selección por torneo.

# AE para el PVCT multiobjetivo


## Propósitos en AE multiobjetivos (MOEA)

Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).

### $p\mu$ MOEA/D

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$



## NSGA-II

Ordenamiento no-dominado (elitista) y *crowding* para preservar diversidad.

## Aspectos comunes

Función correctiva considera vehículos de distintas capacidades.

Inicialización de la población ávida y selección por torneo.

# AE para el PVCT multiobjetivo


## Propósitos en AE multiobjetivos (MOEA)

Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).

### $p\mu$ MOEA/D

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$



## NSGA-II

Ordenamiento no-dominado (elitista) y *crowding* para preservar diversidad.

## Aspectos comunes

Función correctiva considera vehículos de distintas capacidades.

Inicialización de la población ávida y selección por torneo.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación
- 5 Evaluación experimental**
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

# Generación de instancias

## Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- Instancias en Montevideo generadas manualmente.
- API para obtener tarifas TaxiFareFinder (TFF).

## Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 para el multiobjetivo, considerando distintas capacidades y tolerancias.

# Generación de instancias

## Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- Instancias en Montevideo generadas manualmente.
- API para obtener tarifas TaxiFareFinder (TFF).

## Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 para el multiobjetivo, considerando distintas capacidades y tolerancias.



# Generación de instancias

## Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- Instancias en Montevideo generadas manualmente.
- API para obtener tarifas TaxiFareFinder (TFF).

## Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 para el multiobjetivo, considerando distintas capacidades y tolerancias.

# Generación de instancias

## Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- Instancias en Montevideo generadas manualmente.
- API para obtener tarifas TaxiFareFinder (TFF).

## Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 para el multiobjetivo, considerando distintas capacidades y tolerancias.

# Generación de instancias

## Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- Instancias en Montevideo generadas manualmente.
- API para obtener tarifas TaxiFareFinder (TFF).

## Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 para el multiobjetivo, considerando distintas capacidades y tolerancias.

## Entorno de ejecución

- La evaluación experimental fue realizada en el Cluster FING.
- **seqEA**: Dell Power Edge 2950, **1 núcleo** de Intel Xeon E5430 2.66GHz, 8GB RAM.
- **pμEA**: HP Proliant DL585, **24 núcleos** de AMD Opteron 2.09GHz, 48GB RAM.

## Configuración paramétrica

- **seqEA**: 20 ejecuciones de 2000 generaciones sobre 3 instancias.  
 $\#P \in \{150, 200, 250\}$ ;  $p_C \in \{0,6, 0,75, 0,95\}$ ;  $p_M \in \{0,001, 0,01, 0,1\}$ .
- **pμEA**: micro-población de 15 individuos, torneo ( $m = 2$ ,  $k = 1$ ), migración cada 500 generaciones.  
20 ejecuciones de 100.000 generaciones sobre 5 instancias.  
 $p_C \in \{0,6, 0,75, 0,95\}$ ;  $p_M \in \{0,001, 0,01, 0,1\}$ .

## Entorno de ejecución

- La evaluación experimental fue realizada en el Cluster FING.
- **seqEA**: Dell Power Edge 2950, **1 núcleo** de Intel Xeon E5430 2.66GHz, 8GB RAM.
- **p $\mu$ EA**: HP Proliant DL585, **24 núcleos** de AMD Opteron 2.09GHz, 48GB RAM.

## Configuración paramétrica

- **seqEA**: 20 ejecuciones de 2000 generaciones sobre 3 instancias.  
 $\#P \in \{150, 200, 250\}$ ;  $p_C \in \{0,6, 0,75, 0,95\}$ ;  $p_M \in \{0,001, 0,01, 0,1\}$ .
- **p $\mu$ EA**: micro-población de 15 individuos, torneo ( $m = 2$ ,  $k = 1$ ), migración cada 500 generaciones.  
20 ejecuciones de 100.000 generaciones sobre 5 instancias.  
 $p_C \in \{0,6, 0,75, 0,95\}$ ;  $p_M \in \{0,001, 0,01, 0,1\}$ .

## Entorno de ejecución

- La evaluación experimental fue realizada en el Cluster FING.
- **seqEA**: Dell Power Edge 2950, **1 núcleo** de Intel Xeon E5430 2.66GHz, 8GB RAM.
- **p $\mu$ EA**: HP Proliant DL585, **24 núcleos** de AMD Opteron 2.09GHz, 48GB RAM.

## Configuración paramétrica

- **seqEA**: 20 ejecuciones de 2000 generaciones sobre 3 instancias.  
 $\#P \in \{150, 200, 250\}$ ;  $p_C \in \{0,6, 0,75, 0,95\}$ ;  $p_M \in \{0,001, 0,01, 0,1\}$ .
- **p $\mu$ EA**: micro-población de 15 individuos, torneo ( $m = 2$ ,  $k = 1$ ), migración cada 500 generaciones.  
20 ejecuciones de 100.000 generaciones sobre 5 instancias.  
 $p_C \in \{0,6, 0,75, 0,95\}$ ;  $p_M \in \{0,001, 0,01, 0,1\}$ .


# Algoritmo ávido

Utiliza ideas de los trabajos relacionados. Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos.



# Algoritmo ávido

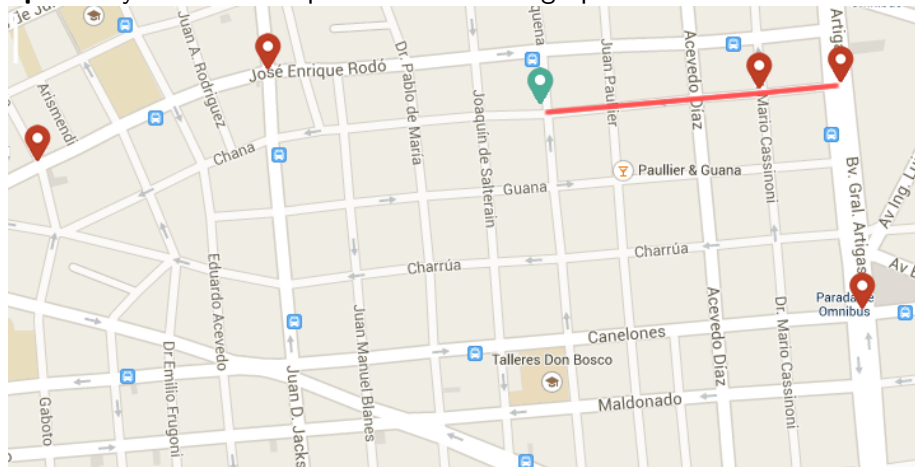
Utiliza ideas de los trabajos relacionados. Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos.






# Algoritmo ávido

Utiliza ideas de los trabajos relacionados. Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos.



# Algoritmo ávido

Utiliza ideas de los trabajos relacionados. Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos.










# Algoritmo ávido

Utiliza ideas de los trabajos relacionados. Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos.



# Comparativa de métodos de inicialización

## Metodología

- 30 ejecuciones independientes de 10.000 generaciones cada una.
- Los resultados no siguen una distribución normal (Shapiro–Wilk,  $\alpha = 0,05$ ).
- Se utilizó Kruskal–Wallis para comparar ambas inicializaciones.

## *seqEA*: inicialización aleatoria vs. inicialización ávida





La inicialización ávida supera a la inicialización aleatoria en 10 instancias de prueba, mientras que la inicialización aleatoria lo hace en tan solo 2.

## *pμEA*: inicialización aleatoria vs. inicialización ávida

La inicialización ávida supera la inicialización aleatoria en 11 instancias de prueba. No hay instancias en las que se pueda afirmar que la inicialización aleatoria alcance mejores soluciones.

# Mejoras *seqEA* sobre algoritmo ávido





Se alcanzaron mejoras en **todas** las instancias. En el mejor caso se superó el costo del algoritmo ávido en un **35.9 %**.





# Mejoras $p\mu EA$ sobre algoritmo ávido

Se alcanzaron mejoras en **todas** las instancias. En el mejor caso se superó el costo del algoritmo ávido en un **41.0 %**.







# Comparativa $seqEA$ vs. $p\mu EA$

$p\mu EA$  supera a  $seqEA$  en **17 de 22** instancias. Únicamente en **1** instancia  $seqEA$  supera a  $p\mu EA$  (Kruskal–Wallis,  $\alpha = 0,05$ ).

instancia		$seqEA$		$p\mu EA$		$p_{vK-W}$
		$min(c)$	$\bar{c} \pm std$	$min(c)$	$\bar{c} \pm std$	
chicas	#1	164.4	165.6 $\pm$ 2.0	164.4	<b>164.4<math>\pm</math>0.0</b>	$0.2 \times 10^{-3}$
	#2	220.7	225.7 $\pm$ 5.0	220.7	<b>220.7<math>\pm</math>0.0</b>	$9.7 \times 10^{-6}$
	#3	160.4	160.4 $\pm$ 0.0	160.4	160.4 $\pm$ 0.0	1.0
	#4	181.3	181.3 $\pm$ 0.1	181.3	182.4 $\pm$ 1.9	$0.5 \times 10^{-1}$
	#5	152.1	155.6 $\pm$ 4.5	152.1	<b>152.1<math>\pm</math>0.0</b>	$5.1 \times 10^{-6}$
	#6	118.4	119.6 $\pm$ 2.5	118.4	<b>118.4<math>\pm</math>0.0</b>	$0.1 \times 10^{-1}$
medianas	#1	211.9	216.0 $\pm$ 4.2	211.9	<b>211.9<math>\pm</math>0.0</b>	$5.2 \times 10^{-11}$
	#2	428.6	444.1 $\pm$ 11.7	427.9	<b>429.4<math>\pm</math>1.6</b>	$7.0 \times 10^{-10}$
	#3	361.7	378.7 $\pm$ 6.5	364.5	<b>370.4<math>\pm</math>4.5</b>	$1.6 \times 10^{-6}$
	#4	267.5	279.8 $\pm$ 5.5	266.8	<b>266.8<math>\pm</math>0.0</b>	$7.6 \times 10^{-12}$
	#5	479.3	487.1 $\pm$ 6.5	479.6	<b>479.8<math>\pm</math>0.2</b>	$5.1 \times 10^{-7}$
	#6	306.0	321.2 $\pm$ 7.7	306.0	<b>307.7<math>\pm</math>3.4</b>	$2.0 \times 10^{-9}$
grandes	#1	421.9	<b>435.1<math>\pm</math>5.0</b>	425.9	437.7 $\pm$ 3.2	$0.1 \times 10^{-1}$
	#2	479.3	489.9 $\pm$ 4.3	477.0	<b>481.1<math>\pm</math>2.3</b>	$1.9 \times 10^{-9}$
	#3	332.8	349.7 $\pm$ 7.7	326.3	<b>331.7<math>\pm</math>4.0</b>	$2.6 \times 10^{-10}$
	#4	351.1	390.7 $\pm$ 26.3	338.4	<b>344.8<math>\pm</math>6.1</b>	$5.1 \times 10^{-11}$
	#5	395.9	429.6 $\pm$ 16.2	370.2	<b>380.0<math>\pm</math>4.4</b>	$2.7 \times 10^{-11}$
	#6	360.8	382.4 $\pm$ 8.1	343.8	<b>350.6<math>\pm</math>3.8</b>	$2.6 \times 10^{-11}$
Montevideo	#1	168.4	168.4 $\pm$ 0.0	168.4	168.4 $\pm$ 0.0	1.0
	#2	319.3	331.2 $\pm$ 3.8	324.9	<b>328.6<math>\pm</math>3.2</b>	$5.6 \times 10^{-6}$
	#3	266.7	269.1 $\pm$ 2.3	266.7	<b>266.7<math>\pm</math>0.0</b>	$3.1 \times 10^{-7}$
	#4	303.2	304.7 $\pm$ 0.5	304.1	304.5 $\pm$ 0.4	0.1

# Evolución del costo a lo largo de una ejecución

$p\mu EA$  alcanza mejores soluciones que  $seqEA$  en menos tiempo. En el mejor caso alcanza una **aceleración de 7,5x** (4,6x en promedio).



## Entorno de ejecución

- La evaluación experimental fue realizada en Cluster FING.
- **p $\mu$ MOEA/D**: HP Proliant DL585, **24 núcleos** de AMD Opteron 2.09GHz, 48GB RAM.
- **NSGA-II**: HP Proliant DL385 G7, **1 núcleo** de AMD Opteron 6172 2.10GHz, 72GB RAM.

## Configuración paramétrica

- **p $\mu$ MOEA/D**: 30 ejecuciones de 20000 generaciones sobre 4 instancias.  
 $P = 15$ ;  $p_C \in \{0,6, 0,75, 0,95\}$ ;  $p_M \in \{0,001, 0,01, 0,1\}$ ; migración cada 1000 generaciones con selección por torneo ( $m = 2, k = 1$ ).
- **NSGA-II**: 30 ejecuciones de 5000 generaciones sobre 4 instancias.  
 $P = 80$ ;  $p_C \in \{0,6, 0,75, 0,95\}$ ;  $p_M \in \{0,001, 0,01, 0,1\}$ .

## Entorno de ejecución

- La evaluación experimental fue realizada en Cluster FING.
- **p $\mu$ MOEA/D**: HP Proliant DL585, **24 núcleos** de AMD Opteron 2.09GHz, 48GB RAM.
- **NSGA-II**: HP Proliant DL385 G7, **1 núcleo** de AMD Opteron 6172 2.10GHz, 72GB RAM.

## Configuración paramétrica

- **p $\mu$ MOEA/D**: 30 ejecuciones de 20000 generaciones sobre 4 instancias.  
 $P = 15$ ;  $p_C \in \{0,6, 0,75, 0,95\}$ ;  $p_M \in \{0,001, 0,01, 0,1\}$ ; migración cada 1000 generaciones con selección por torneo ( $m = 2, k = 1$ ).
- **NSGA-II**: 30 ejecuciones de 5000 generaciones sobre 4 instancias.  
 $P = 80$ ;  $p_C \in \{0,6, 0,75, 0,95\}$ ;  $p_M \in \{0,001, 0,01, 0,1\}$ .

## Algoritmo ávido para minimizar el costo

Se utilizó el mismo algoritmo detallado previamente, tomando en cuenta las distintas capacidades de los vehículos y su disponibilidad.

## Algoritmo ávido para minimizar la demora

- Se crea un taxi vacío para cada pasajero con nivel máximo de apuro y se los ubica en la primera posición.
- Luego, se recorre la lista de pasajeros no asignados en orden de apuro, colocándolos en el taxi que minimice su demora.
- Si el taxi alcanza la máxima capacidad disponible, se lo considera *completo* y no acepta más pasajeros.

## Algoritmo ávido para minimizar el costo

Se utilizó el mismo algoritmo detallado previamente, tomando en cuenta las distintas capacidades de los vehículos y su disponibilidad.

## Algoritmo ávido para minimizar la demora

- Se crea un taxi vacío para cada pasajero con nivel máximo de apuro y se los ubica en la primera posición.
- Luego, se recorre la lista de pasajeros no asignados en orden de apuro, colocándolos en el taxi que minimice su demora.
- Si el taxi alcanza la máxima capacidad disponible, se lo considera *completo* y no acepta más pasajeros.

# Métricas multiobjetivo

## $p\mu$ MOEA/D

Buena convergencia y diversidad. La cantidad de soluciones no dominadas es baja.

	#ND	DG	spacing	spread	RHV
chicas	8.5±2.1 (16.0)	3.1±2.5 (0.0)	740.2±746.3 (58.1)	0.6±0.2 (0.1)	0.9±0.1 (1.0)
medianas	9.1±2.2 (19.0)	5.7±2.5 (0.0)	1448.5±1064.1 (141.6)	0.6±0.1 (0.1)	0.9±0.1 (1.0)
grandes	8.5±2.2 (17.0)	7.9±3.4 (2.0)	2917.2±2041.5 (175.3)	0.6±0.1 (0.0)	0.8±0.1 (1.0)
Montevideo	8.0±2.1 (14.0)	3.0±2.0 (0.0)	663.5±542.4 (61.5)	0.6±0.2 (0.0)	0.9±0.0 (1.0)

## NSGA-II





Mayor cantidad de puntos no dominados (hasta 67/80). Buena convergencia y diversidad en las soluciones encontradas.

	#ND	DG	spacing	spread	RHV
chicas	32.6±9.5 (55.0)	0.3±0.6 (0.0)	236.2±222.7 (43.2)	0.9±0.1 (0.7)	1.0±0.0 (1.0)
medianas	54.5±4.2 (67.0)	1.0±0.7 (0.0)	193.6±202.4 (26.2)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
grandes	55.2±3.5 (67.0)	1.8±1.1 (0.4)	243.6±229.8 (26.4)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
Montevideo	43.9±16.4 (61.0)	0.4±0.5 (0.0)	142.3±143.2 (20.8)	0.8±0.1 (0.5)	1.0±0.0 (1.0)




# Frentes de Pareto: $p\mu$ MOEA/D vs. NSGA-II

**NSGA-II alcanza mejores soluciones:** mayor cantidad de puntos no dominados distribuidos homogéneamente.




# Mejora frente a algoritmos ávidos vs. tiempo de ejecución

*NSGA-II* alcanza mejores soluciones pero requiere de un mayor tiempo de ejecución que *pμMOEA/D*.



*costo*




*demora*

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea**
- 7 Conclusiones y trabajo futuro

# Planificador de viajes compartidos en línea


- Se ingresa el origen, los destinos y la tarifa (diurna/nocturna).




- Se ejecuta el AE y se muestra la planificación calculada.
- Servidor implementado en Ruby on Rails siguiendo MVC.
- Las aplicaciones móviles consumen la API del servidor.
- Aplicaciones móviles: desarrollo híbrido vs. desarrollo nativo.

# Planificador de viajes compartidos en línea

- Se ingresa el origen, los destinos y la tarifa (diurna/nocturna).




- Se ejecuta el AE y se muestra la planificación calculada.





- Servidor implementado en Ruby on Rails siguiendo MVC.
- Las aplicaciones móviles consumen la API del servidor.
- Aplicaciones móviles: desarrollo híbrido vs. desarrollo nativo.

# Planificador de viajes compartidos en línea

- Se ingresa el origen, los destinos y la tarifa (diurna/nocturna).



- Se ejecuta el AE y se muestra la planificación calculada.



- Servidor implementado en Ruby on Rails siguiendo MVC.
- Las aplicaciones móviles consumen la API del servidor.
- Aplicaciones móviles: desarrollo híbrido vs. desarrollo nativo.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajo relacionado
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

# Conclusiones

- Se relevó la literatura relacionada (CPP, DARP, TPP) y se presentaron dos variantes del problema.
- Se implementaron **cuatro** AE: dos para cada variante del problema.
- El análisis experimental se realizó sobre **instancias realistas**.
- Los AE implementados fueron comparados contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** ( $p\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** ( $p\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis, disponible públicamente en [www.mepaseaste.uy](http://www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería de Muestra 2014” .



# Conclusiones

- Se relevó la literatura relacionada (CPP, DARP, TPP) y se presentaron dos variantes del problema.
- Se implementaron **cuatro** AE: dos para cada variante del problema.
- El análisis experimental se realizó sobre **instancias realistas**.
- Los AE implementados fueron comparados contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** ( $p\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** ( $p\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis, disponible públicamente en [www.mepaseaste.uy](http://www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería de Muestra 2014” .

# Conclusiones

- Se relevó la literatura relacionada (CPP, DARP, TPP) y se presentaron dos variantes del problema.
- Se implementaron **cuatro** AE: dos para cada variante del problema.
- El análisis experimental se realizó sobre **instancias realistas**.
- Los AE implementados fueron comparados contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** ( $p\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** ( $p\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis, disponible públicamente en [www.mepaseaste.uy](http://www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería de Muestra 2014” .

# Conclusiones

- Se relevó la literatura relacionada (CPP, DARP, TPP) y se presentaron dos variantes del problema.
- Se implementaron **cuatro** AE: dos para cada variante del problema.
- El análisis experimental se realizó sobre **instancias realistas**.
- Los AE implementados fueron comparados contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p $\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p $\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis, disponible públicamente en [www.mepaseaste.uy](http://www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

# Conclusiones

- Se relevó la literatura relacionada (CPP, DARP, TPP) y se presentaron dos variantes del problema.
- Se implementaron **cuatro** AE: dos para cada variante del problema.
- El análisis experimental se realizó sobre **instancias realistas**.
- Los AE implementados fueron comparados contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p $\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p $\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis, disponible públicamente en [www.mepaseaste.uy](http://www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería de Muestra 2014” .

# Conclusiones

- Se relevó la literatura relacionada (CPP, DARP, TPP) y se presentaron dos variantes del problema.
- Se implementaron **cuatro** AE: dos para cada variante del problema.
- El análisis experimental se realizó sobre **instancias realistas**.
- Los AE implementados fueron comparados contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p $\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p $\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis, disponible públicamente en [www.mepaseaste.uy](http://www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería de Muestra 2014” .

# Conclusiones

- Se relevó la literatura relacionada (CPP, DARP, TPP) y se presentaron dos variantes del problema.
- Se implementaron **cuatro** AE: dos para cada variante del problema.
- El análisis experimental se realizó sobre **instancias realistas**.
- Los AE implementados fueron comparados contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p $\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p $\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis, disponible públicamente en [www.mepaseaste.uy](http://www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

# Conclusiones

- Se relevó la literatura relacionada (CPP, DARP, TPP) y se presentaron dos variantes del problema.
- Se implementaron **cuatro** AE: dos para cada variante del problema.
- El análisis experimental se realizó sobre **instancias realistas**.
- Los AE implementados fueron comparados contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p $\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p $\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis, disponible públicamente en [www.mepaseaste.uy](http://www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

# Conclusiones

- Se relevó la literatura relacionada (CPP, DARP, TPP) y se presentaron dos variantes del problema.
- Se implementaron **cuatro** AE: dos para cada variante del problema.
- El análisis experimental se realizó sobre **instancias realistas**.
- Los AE implementados fueron comparados contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p $\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p $\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis, disponible públicamente en [www.mepaseaste.uy](http://www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .



# Trabajo futuro

## Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico** para considerar rutas alternativas.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

## Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de los usuarios.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

## Problemas relacionados

- Estudiar la aplicabilidad de los AE a otros escenarios.
- Estudiar otras variantes del problema (many-to-one, many-to-many).

# Trabajo futuro

## Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico** para considerar rutas alternativas.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

## Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de los usuarios.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

## Problemas relacionados

- Estudiar la aplicabilidad de los AE a otros escenarios.
- Estudiar otras variantes del problema (many-to-one, many-to-many).

# Trabajo futuro

## Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico** para considerar rutas alternativas.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

## Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de los usuarios.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

## Problemas relacionados

- Estudiar la aplicabilidad de los AE a otros escenarios.
- Estudiar otras variantes del problema (many-to-one, many-to-many).

# Trabajo futuro

## Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico** para considerar rutas alternativas.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

## Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de los usuarios.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

## Problemas relacionados

- Estudiar la aplicabilidad de los AE a otros escenarios.
- Estudiar otras variantes del problema (many-to-one, many-to-many).

# Trabajo futuro

## Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico** para considerar rutas alternativas.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

## Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de los usuarios.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

## Problemas relacionados

- Estudiar la aplicabilidad de los AE a otros escenarios.
- Estudiar otras variantes del problema (many-to-one, many-to-many).

# Trabajo futuro

## Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico** para considerar rutas alternativas.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

## Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de los usuarios.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

## Problemas relacionados

- Estudiar la aplicabilidad de los AE a otros escenarios.
- Estudiar otras variantes del problema (many-to-one, many-to-many).

# Trabajo futuro

## Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico** para considerar rutas alternativas.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

## Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de los usuarios.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

## Problemas relacionados

- Estudiar la aplicabilidad de los AE a otros escenarios.
- Estudiar otras variantes del problema (many-to-one, many-to-many).

# Trabajo futuro

## Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico** para considerar rutas alternativas.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

## Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de los usuarios.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

## Problemas relacionados

- Estudiar la aplicabilidad de los AE a otros escenarios.
- Estudiar otras variantes del problema (many-to-one, many-to-many).