

# Optimización de viajes compartidos en taxis utilizando algoritmos evolutivos

Gabriel Fagúndez de los Reyes    Renzo Massobrio

Facultad de Ingeniería,  
Universidad de la República,  
Montevideo, Uruguay



# Contenido

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

## Los viajes compartidos (*Car Pooling*)

- Beneficios ecológicos y económicos, individuales y colectivos.
- Iniciativas:
  - carriles exclusivos
  - campañas para compartir los viajes al trabajo
  - aplicaciones para encontrar compañeros de viaje

## Los viajes compartidos en taxis (*Taxi Pooling*)

- Medio de transporte rápido y confiable.
- Raramente viajan a capacidad completa.
- Tarifas altas desalientan a los usuarios.
- Impactan en la congestión del tráfico y en la contaminación.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

# Descripción del problema

## Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Hallar la cantidad de taxis y la asignación de pasajeros para minimizar el **costo total**.

## Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- El número máximo de taxis para  $N$  pasajeros es  $N$ .
- Costo de un taxi = **costo inicial** + **costo por trayectos**.
- No se consideran otros costos (e.g. esperas, propinas, peajes).

# Formulación del problema

- Un conjunto de pasajeros  $P$  que viajan desde un origen  $O$  a un conjunto de destinos  $D$ .
- Un conjunto de taxis  $T$  y una función  $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$  con  $C_{MAX}$  máxima capacidad de un taxi.
- Una constante  $B$ : costo inicial del taxi (“bajada de bandera”).
- Una función de distancia,  $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$ .
- Una función de costo asociado a la distancia,  $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$ .

Se busca una planificación  $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$  que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \underbrace{cost \left( dist \left( dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right]$$

# Formulación del problema

- Un conjunto de pasajeros  $P$  que viajan desde un origen  $O$  a un conjunto de destinos  $D$ .
- Un conjunto de taxis  $T$  y una función  $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$  con  $C_{MAX}$  máxima capacidad de un taxi.
- Una constante  $B$ : costo inicial del taxi (“bajada de bandera”).
- Una función de distancia,  $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$ .
- Una función de costo asociado a la distancia,  $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$ .

Se busca una planificación  $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$  que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} cost \left( \underbrace{dist \left( dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$



# Variante multiobjetivo del PVCT: formulación matemática

- Se busca minimizar el **costo total** y la **demora total**.
- Cada pasajero tiene un **nivel de apuro** asociado.
- Se consideran vehículos con **diferentes capacidades**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \text{cost} \left( \overbrace{\text{dist} \left( \text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[ \sum_{j=1}^{C(t_i)} \left[ \underbrace{\sum_{h=1}^j \text{time} \left( \text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}_{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} - \underbrace{\left( \text{tol}(f^{-1}(t_i, j)) + \text{time} \left( O, \text{dest}(f^{-1}(t_i, j)) \right) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

# Variante multiobjetivo del PVCT: formulación matemática

- Se busca minimizar el **costo total** y la **demora total**.
- Cada pasajero tiene un **nivel de apuro** asociado.
- Se consideran vehículos con **diferentes capacidades**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \text{cost} \left( \overbrace{\text{dist} \left( \text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[ \sum_{j=1}^{C(t_i)} \left[ \underbrace{\sum_{h=1}^j \text{time} \left( \text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}_{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} \right. \right. \\ \left. \left. - \underbrace{\left( \text{tol}(f^{-1}(t_i, j)) + \text{time} \left( O, \text{dest}(f^{-1}(t_i, j)) \right) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

# Variante multiobjetivo del PVCT: formulación matemática

- Se busca minimizar el **costo total** y la **demora total**.
- Cada pasajero tiene un **nivel de apuro** asociado.
- Se consideran vehículos con **diferentes capacidades**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \text{cost} \left( \overbrace{\text{dist} \left( \text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

tiempo efectivo de traslado del pasajero en la posición  $j$  del taxi  $t_i$

$$DT = \sum_{t_i} \left[ \sum_{j=1}^{C(t_i)} \left[ \sum_{h=1}^j \text{time} \left( \text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right) \right. \right. \\ \left. \left. - \underbrace{\left( \text{tol}(f^{-1}(t_i, j)) + \text{time} \left( O, \text{dest}(f^{-1}(t_i, j)) \right) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

# Variante multiobjetivo del PVCT: formulación matemática

- Se busca minimizar el **costo total** y la **demora total**.
- Cada pasajero tiene un **nivel de apuro** asociado.
- Se consideran vehículos con **diferentes capacidades**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[ B + \sum_{j=1}^{C(t_i)} \text{cost} \left( \overbrace{\text{dist} \left( \text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[ \sum_{j=1}^{C(t_i)} \left[ \underbrace{\sum_{h=1}^j \text{time} \left( \text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}_{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} \right. \right. \\ \left. \left. - \underbrace{\left( \text{tol}(f^{-1}(t_i, j)) + \text{time} \left( O, \text{dest}(f^{-1}(t_i, j)) \right) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

## Complejidad

- Baldacci et al. (2004):
  - Variante del *Car Pooling Problem (CPP)*.
  - Solución al problema de compartir vehículos en el trabajo.
- Caso especial del *Vehicle Routing Problem (VRP)* con demanda unitaria:  $\mathcal{NP}$ -difícil [Letchford et al. (2002)].
- El PVCT tiene grandes similitudes con el CPP.

## Estrategias de resolución

- Con instancias de tamaños realistas los algoritmos exactos tradicionales no resultan útiles para una planificación eficiente.
- **Heurísticas** y **metaheurísticas** son necesarias para calcular soluciones de calidad aceptable en tiempos razonables.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados**
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

# Trabajos relacionados

## Car pooling problem (CPP)

Yan et al. (2011): **CPP con histórico de viajes** (relajación lagrangeana).

## Dial-a-ride problem (DARP)

Cordeau et al. (2003): **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

## Taxi pooling problem (TPP)

Tao et al. (2007): heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013): TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

## Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

# Trabajos relacionados

## Car pooling problem (CPP)

Yan et al. (2011): **CPP con histórico de viajes** (relajación lagrangeana).

## Dial-a-ride problem (DARP)

Cordeau et al. (2003): **DARP estático con ventanas de tiempo.**

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

## Taxi pooling problem (TPP)

Tao et al. (2007): heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013): TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas.**

## Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo.**



# Trabajos relacionados

## Car pooling problem (CPP)

Yan et al. (2011): **CPP con histórico de viajes** (relajación lagrangeana).

## Dial-a-ride problem (DARP)

Cordeau et al. (2003): **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

## Taxi pooling problem (TPP)

Tao et al. (2007): heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013): TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

## Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

# Trabajos relacionados

## Car pooling problem (CPP)

Yan et al. (2011): **CPP con histórico de viajes** (relajación lagrangeana).

## Dial-a-ride problem (DARP)

Cordeau et al. (2003): **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

## Taxi pooling problem (TPP)

Tao et al. (2007): heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013): TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

## Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación**
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

## Definición

- Técnicas estocásticas que emulan el proceso de evolución natural de las especies.
- Aplicadas a problemas de **optimización**, búsqueda y aprendizaje.
- Técnica iterativa (**generación**) que aplica operadores estocásticos sobre un conjunto de individuos (**población**).
- Cada individuo codifica una solución tentativa al problema y tiene un valor de **fitness**.
- El propósito es mejorar el fitness de los individuos en la población mediante la aplicación de **operadores evolutivos**.
- Los operadores guían al algoritmo evolutivo hacia soluciones tentativas de mayor calidad.

## Definición

- Técnicas estocásticas que emulan el proceso de evolución natural de las especies.
- Aplicadas a problemas de **optimización**, búsqueda y aprendizaje.
- Técnica iterativa (**generación**) que aplica operadores estocásticos sobre un conjunto de individuos (**población**).
- Cada individuo codifica una solución tentativa al problema y tiene un valor de **fitness**.
- El propósito es mejorar el fitness de los individuos en la población mediante la aplicación de **operadores evolutivos**.
- Los operadores guían al algoritmo evolutivo hacia soluciones tentativas de mayor calidad.

## Definición

- Técnicas estocásticas que emulan el proceso de evolución natural de las especies.
- Aplicadas a problemas de **optimización**, búsqueda y aprendizaje.
- Técnica iterativa (**generación**) que aplica operadores estocásticos sobre un conjunto de individuos (**población**).
- Cada individuo codifica una solución tentativa al problema y tiene un valor de **fitness**.
- El propósito es mejorar el fitness de los individuos en la población mediante la aplicación de **operadores evolutivos**.
- Los operadores guían al algoritmo evolutivo hacia soluciones tentativas de mayor calidad.

## Definición

- Técnicas estocásticas que emulan el proceso de evolución natural de las especies.
- Aplicadas a problemas de **optimización**, búsqueda y aprendizaje.
- Técnica iterativa (**generación**) que aplica operadores estocásticos sobre un conjunto de individuos (**población**).
- Cada individuo codifica una solución tentativa al problema y tiene un valor de **fitness**.
- El propósito es mejorar el fitness de los individuos en la población mediante la aplicación de **operadores evolutivos**.
- Los operadores guían al algoritmo evolutivo hacia soluciones tentativas de mayor calidad.

## Definición

- Técnicas estocásticas que emulan el proceso de evolución natural de las especies.
- Aplicadas a problemas de **optimización**, búsqueda y aprendizaje.
- Técnica iterativa (**generación**) que aplica operadores estocásticos sobre un conjunto de individuos (**población**).
- Cada individuo codifica una solución tentativa al problema y tiene un valor de **fitness**.
- El propósito es mejorar el fitness de los individuos en la población mediante la aplicación de **operadores evolutivos**.
- Los operadores guían al algoritmo evolutivo hacia soluciones tentativas de mayor calidad.



## Definición

- Técnicas estocásticas que emulan el proceso de evolución natural de las especies.
- Aplicadas a problemas de **optimización**, búsqueda y aprendizaje.
- Técnica iterativa (**generación**) que aplica operadores estocásticos sobre un conjunto de individuos (**población**).
- Cada individuo codifica una solución tentativa al problema y tiene un valor de **fitness**.
- El propósito es mejorar el fitness de los individuos en la población mediante la aplicación de **operadores evolutivos**.
- Los operadores guían al algoritmo evolutivo hacia soluciones tentativas de mayor calidad.

## Aspectos comunes

- Inicialización:
  - basada en técnica aleatoria
  - basada en técnica ávida + permutaciones
- Implementados en Malva.
- Función correctiva:  
desplaza ceros para romper secuencias de dígitos inválidas

## Aspectos comunes

- Inicialización:
  - basada en técnica aleatoria
  - basada en técnica ávida + permutaciones
- Implementados en Malva.
- Función correctiva:  
desplaza ceros para romper secuencias de dígitos inválidas


## Aspectos comunes

- Inicialización:
  - basada en técnica aleatoria
  - basada en técnica ávida + permutaciones
- Implementados en Malva.
- Función correctiva:  
desplaza ceros para romper secuencias de dígitos inválidas

# AE para el PVCT monoobjetivo

## Aspectos comunes

Individuos de largo  $2N - 1$ ,  $N = \#$ pasajeros.



## Aspectos comunes

### Cruzamiento basado en posición (PBX) + función correctiva.

Padre 1

2	0	1	5	4	0	0	3	0
---	---	---	---	---	---	---	---	---

Padre 2

0	3	1	0	2	0	4	0	5
---	---	---	---	---	---	---	---	---

PBX

1) Se sortean  $n$  posiciones en el padre 1

2		1	5	4			3	0
	0				0	0		

2) Se copian en el hijo los valores sorteados en el padre 1

2		1	5	4				0
---	--	---	---	---	--	--	--	---

3) Se seleccionan en el padre 2 los valores no sorteados del padre 1

	3		0		0		0	
0		1		2		4		5

4) Se copian en orden los valores seleccionados del padre 2 en las posiciones vacías del hijo

2	3	1	5	4	0	0	0	0
---	---	---	---	---	---	---	---	---

Función Correctiva

2	3	0	5	4	1	0	0	0
---	---	---	---	---	---	---	---	---

## Aspectos comunes

Mutación por intercambio (EM) + función correctiva.

2	0	1	5	4	3	0	0	0
---	---	---	---	---	---	---	---	---



Se sortean 2 posiciones

2	0	1	5	4	3	0	0	0
---	---	---	---	---	---	---	---	---

Se intercambian posiciones



0	0	1	5	4	3	2	0	0
---	---	---	---	---	---	---	---	---

Función Correctiva

0	4	1	5	0	3	2	0	0
---	---	---	---	---	---	---	---	---

# AE para el PVCT monoobjetivo

## AE secuencial (*seqEA*)

- Selección proporcional.

## Micro AE paralelo (*pμEA*)

- Se busca **mejorar el desempeño** mediante el paralelismo.
- **Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.
- Poblaciones pequeñas.
- Selección por torneo ( $m, k$ ).
- Migración asíncrona, con topología de anillo unidireccional.




# AE para el PVCT monoobjetivo

## AE secuencial (*seqEA*)

- Selección proporcional.

## Micro AE paralelo (*pμEA*)

- Se busca **mejorar el desempeño** mediante el paralelismo.
- **Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.



- Poblaciones pequeñas.
- Selección por torneo ( $m, k$ ).
- Migración asíncrona, con topología de anillo unidireccional.

# AE para el PVCT multiobjetivo

## Aspectos comunes

- MOEA: acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).
- Función correctiva considera vehículos de distintas capacidades.
- Inicialización ávida y selección por torneo.

## Micro MOEA paralelo con descomposición de dominio ( $p\mu$ MOEA/D)

Agregación lineal de los objetivos:

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$

## MOEA explícito (*NSGA-II*)

Ordenamiento no-dominado (elitista), *crowding* para preservar diversidad.

# AE para el PVCT multiobjetivo

## Aspectos comunes


- MOEA: acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).
- Función correctiva considera vehículos de distintas capacidades.
- Inicialización ávida y selección por torneo.

## Micro MOEA paralelo con descomposición de dominio ( $p\mu$ MOEA/D)

Agregación lineal de los objetivos:

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$



## MOEA explícito ( $NSGA-II$ )

Ordenamiento no-dominado (elitista), *crowding* para preservar diversidad.

# AE para el PVCT multiobjetivo

## Aspectos comunes


- MOEA: acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).
- Función correctiva considera vehículos de distintas capacidades.
- Inicialización ávida y selección por torneo.

## Micro MOEA paralelo con descomposición de dominio ( $p\mu$ MOEA/D)

Agregación lineal de los objetivos:

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$



## MOEA explícito ( $NSGA-II$ )

Ordenamiento no-dominado (elitista), *crowding* para preservar diversidad.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación
- 5 Evaluación experimental**
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

# Generación de instancias

## Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- API para obtener tarifas TaxiFareFinder (TFF).
- Instancias en Montevideo generadas manualmente.

## Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 instancias para el PVCT multiobjetivo, variando capacidades y tolerancias.

# Generación de instancias

## Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- API para obtener tarifas TaxiFareFinder (TFF).
- Instancias en Montevideo generadas manualmente.

## Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 instancias para el PVCT multiobjetivo, variando capacidades y tolerancias.

# Generación de instancias

## Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- API para obtener tarifas TaxiFareFinder (TFF).
- Instancias en Montevideo generadas manualmente.

## Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 instancias para el PVCT multiobjetivo, variando capacidades y tolerancias.



# Generación de instancias

## Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- API para obtener tarifas TaxiFareFinder (TFF).
- Instancias en Montevideo generadas manualmente.

## Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 instancias para el PVCT multiobjetivo, variando capacidades y tolerancias.

# Generación de instancias

## Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- API para obtener tarifas TaxiFareFinder (TFF).
- Instancias en Montevideo generadas manualmente.

## Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 instancias para el PVCT multiobjetivo, variando capacidades y tolerancias.

## Entorno de ejecución

- Evaluación experimental realizada en el Cluster FING.
- Sin compartir recursos para evitar interferencias.



## Ejecuciones

- 30 ejecuciones independientes de cada algoritmo sobre cada instancia.
- Criterio de parada: 10.000 generaciones (planificación en línea).

## Comparación de resultados

- Tests estadísticos sobre las distribuciones de resultados:
  - Shapiro–Wilk sobre cada muestra para contrastar normalidad.
  - Kruskal–Wallis para comparar las muestras entre sí.
- En ambos tests se utiliza un nivel de confianza del 95 % ( $\alpha = 0,05$ ).

## Entorno de ejecución

- Evaluación experimental realizada en el Cluster FING.
- Sin compartir recursos para evitar interferencias.



## Ejecuciones

- **30 ejecuciones independientes** de cada algoritmo sobre cada instancia.
- Criterio de parada: **10.000 generaciones** (planificación en línea).

## Comparación de resultados

- Tests estadísticos sobre las distribuciones de resultados:
  - Shapiro–Wilk sobre cada muestra para contrastar normalidad.
  - Kruskal–Wallis para comparar las muestras entre sí.
- En ambos tests se utiliza un nivel de confianza del 95 % ( $\alpha = 0,05$ ).

## Entorno de ejecución

- Evaluación experimental realizada en el Cluster FING.
- Sin compartir recursos para evitar interferencias.



## Ejecuciones

- **30 ejecuciones independientes** de cada algoritmo sobre cada instancia.
- Criterio de parada: **10.000 generaciones** (planificación en línea).

## Comparación de resultados

- Tests estadísticos sobre las distribuciones de resultados:
  - Shapiro–Wilk sobre cada muestra para contrastar normalidad.
  - Kruskal–Wallis para comparar las muestras entre sí.
- En ambos tests se utiliza un nivel de confianza del 95 % ( $\alpha = 0,05$ ).

## Configuración paramétrica

- **seqEA**:  $\#P \in \{150; 200; 250\}$ ;  $p_C \in \{0,6; 0,75; 0,95\}$ ;  
 $p_M \in \{0,001; 0,01; 0,1\}$ .
- **p $\mu$ EA**: micro-población de 15 individuos, torneo ( $m = 2$ ,  $k = 1$ ),  
migración cada 500 generaciones.  
 $p_C \in \{0,6; 0,75; 0,95\}$ ;  $p_M \in \{0,001; 0,01; 0,1\}$ .

## Configuración paramétrica

- **seqEA**:  $\#P \in \{150; 200; 250\}$ ;  $p_C \in \{0,6; 0,75; 0,95\}$ ;  
 $p_M \in \{0,001; 0,01; 0,1\}$ .
- **p $\mu$ EA**: micro-población de 15 individuos, torneo ( $m = 2$ ,  $k = 1$ ),  
migración cada 500 generaciones.  
 $p_C \in \{0,6; 0,75; 0,95\}$ ;  $p_M \in \{0,001; 0,01; 0,1\}$ .

# Algoritmo ávido

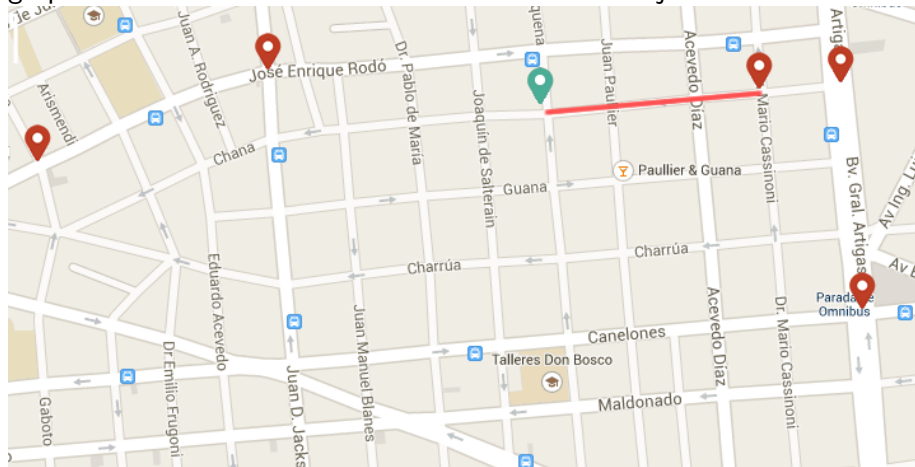
Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.





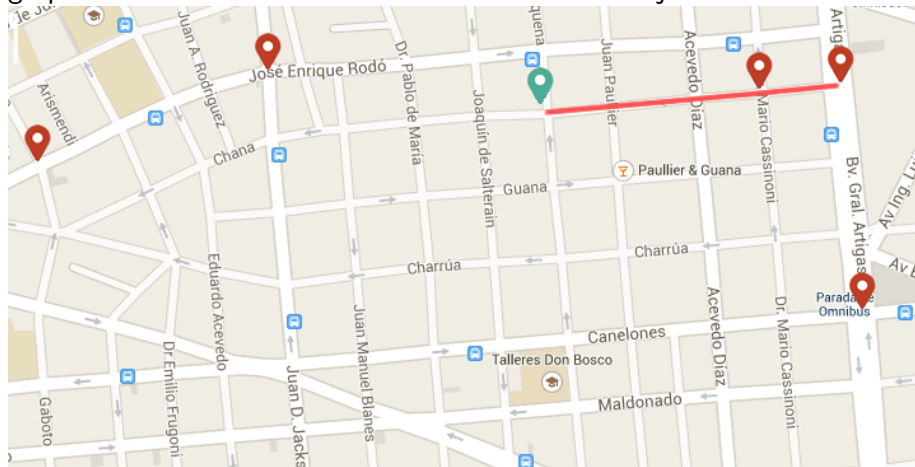
# Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.




# Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.




# Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.




# Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.




# Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.




# Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.



# Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.



# Comparativa de métodos de inicialización

## Resultados *seqEA*

- Inicialización ávida supera a inicialización aleatoria en 10 instancias.
- Inicialización aleatoria supera a inicialización ávida en 2 instancias.
- No hay diferencias estadísticamente significativas en 10 instancias.

## Resultados *pμEA*

- Inicialización ávida supera a inicialización aleatoria en 11 instancias.
- No hay instancias en las que la inicialización aleatoria supere a la inicialización ávida.
- No hay diferencias estadísticamente significativas en 11 instancias.

## Conclusión

Se utiliza la **inicialización ávida** para el resto de la evaluación experimental.



# Comparativa de métodos de inicialización

## Resultados *seqEA*

- Inicialización ávida supera a inicialización aleatoria en 10 instancias.
- Inicialización aleatoria supera a inicialización ávida en 2 instancias.
- No hay diferencias estadísticamente significativas en 10 instancias.

## Resultados *pμEA*

- Inicialización ávida supera a inicialización aleatoria en 11 instancias.
- No hay instancias en las que la inicialización aleatoria supere a la inicialización ávida.
- No hay diferencias estadísticamente significativas en 11 instancias.

## Conclusión

Se utiliza la inicialización ávida para el resto de la evaluación experimental.

# Comparativa de métodos de inicialización

## Resultados *seqEA*

- Inicialización ávida supera a inicialización aleatoria en 10 instancias.
- Inicialización aleatoria supera a inicialización ávida en 2 instancias.
- No hay diferencias estadísticamente significativas en 10 instancias.





## Resultados *pμEA*

- Inicialización ávida supera a inicialización aleatoria en 11 instancias.
- No hay instancias en las que la inicialización aleatoria supere a la inicialización ávida.
- No hay diferencias estadísticamente significativas en 11 instancias.

## Conclusión





Se utiliza la **inicialización ávida** para el resto de la evaluación experimental.

# Mejoras *seqEA* sobre algoritmo ávido



Mejoras en **todas** las instancias sobre el algoritmo ávido (hasta 35.9%).  
“Online taxi sharing optimization using evolutionary algorithms” (CLEI)

# Mejoras $p\mu EA$ sobre algoritmo ávido







Mejoras en **todas** las instancias sobre el algoritmo ávido (hasta 41.0%).  
"A parallel micro evolutionary algorithm for taxi sharing optimization" (ALIO)

# Comparativa $seqEA$ vs. $p\mu EA$

instancia		$seqEA$		$p\mu EA$		$pvK-W$
		$min(c)$	$\bar{c} \pm std$	$min(c)$	$\bar{c} \pm std$	
chicas	#1	164.4	165.6 $\pm$ 2.0	164.4	164.4 $\pm$ 0.0	0.2 $\times 10^{-3}$
	#2	220.7	225.7 $\pm$ 5.0	220.7	220.7 $\pm$ 0.0	9.7 $\times 10^{-6}$
	#3	160.4	160.4 $\pm$ 0.0	160.4	160.4 $\pm$ 0.0	1.0
	#4	181.3	181.3 $\pm$ 0.1	181.3	182.4 $\pm$ 1.9	0.5 $\times 10^{-1}$
	#5	152.1	155.6 $\pm$ 4.5	152.1	152.1 $\pm$ 0.0	5.1 $\times 10^{-6}$
	#6	118.4	119.6 $\pm$ 2.5	118.4	118.4 $\pm$ 0.0	0.1 $\times 10^{-1}$
medianas	#1	211.9	216.0 $\pm$ 4.2	211.9	211.9 $\pm$ 0.0	5.2 $\times 10^{-11}$
	#2	428.6	444.1 $\pm$ 11.7	427.9	429.4 $\pm$ 1.6	7.0 $\times 10^{-10}$
	#3	361.7	378.7 $\pm$ 6.5	364.5	370.4 $\pm$ 4.5	1.6 $\times 10^{-6}$
	#4	267.5	279.8 $\pm$ 5.5	266.8	266.8 $\pm$ 0.0	7.6 $\times 10^{-12}$
	#5	479.3	487.1 $\pm$ 6.5	479.6	479.8 $\pm$ 0.2	5.1 $\times 10^{-7}$
	#6	306.0	321.2 $\pm$ 7.7	306.0	307.7 $\pm$ 3.4	2.0 $\times 10^{-9}$
grandes	#1	421.9	435.1 $\pm$ 5.0	425.9	437.7 $\pm$ 3.2	0.1 $\times 10^{-1}$
	#2	479.3	489.9 $\pm$ 4.3	477.0	481.1 $\pm$ 2.3	1.9 $\times 10^{-9}$
	#3	332.8	349.7 $\pm$ 7.7	326.3	331.7 $\pm$ 4.0	2.6 $\times 10^{-10}$
	#4	351.1	390.7 $\pm$ 26.3	338.4	344.8 $\pm$ 6.1	5.1 $\times 10^{-11}$
	#5	395.9	429.6 $\pm$ 16.2	370.2	380.0 $\pm$ 4.4	2.7 $\times 10^{-11}$
	#6	360.8	382.4 $\pm$ 8.1	343.8	350.6 $\pm$ 3.8	2.6 $\times 10^{-11}$
Montevideo	#1	168.4	168.4 $\pm$ 0.0	168.4	168.4 $\pm$ 0.0	1.0
	#2	319.3	331.2 $\pm$ 3.8	324.9	328.6 $\pm$ 3.2	5.6 $\times 10^{-6}$
	#3	266.7	269.1 $\pm$ 2.3	266.7	266.7 $\pm$ 0.0	3.1 $\times 10^{-7}$
	#4	303.2	304.7 $\pm$ 0.5	304.1	304.5 $\pm$ 0.4	0.1

$p\mu EA$  supera a  $seqEA$  en 17 de 22 instancias.  
Únicamente en 1 instancia  $seqEA$  supera a  $p\mu EA$ .

# Evolución del costo a lo largo de una ejecución



$p\mu EA$  alcanza mejores soluciones que  $seqEA$  en menos tiempo.  
En el mejor caso alcanza una **aceleración de 7,5x** (4,6x en promedio).

## Configuración paramétrica

- **p $\mu$ MOEA/D**:  $\#P = 15$ ; selección por torneo ( $m = 2, k = 1$ ); migración cada 1000 generaciones reemplazando a los peores individuos  
 $p_C \in \{0,6; 0,75; 0,95\}$ ;  $p_M \in \{0,001; 0,01; 0,1\}$
- **NSGA-II**:  $\#P = 80$ ; selección por torneo ( $m = 2, k = 1$ );  
 $p_C \in \{0,6; 0,75; 0,95\}$ ;  $p_M \in \{0,001; 0,01; 0,1\}$ .

## Configuración paramétrica

- **p $\mu$ MOEA/D**:  $\#P = 15$ ; selección por torneo ( $m = 2, k = 1$ ); migración cada 1000 generaciones reemplazando a los peores individuos  
 $p_C \in \{0,6; 0,75; 0,95\}$ ;  $p_M \in \{0,001; 0,01; 0,1\}$
- **NSGA-II**:  $\#P = 80$ ; selección por torneo ( $m = 2, k = 1$ );  
 $p_C \in \{0,6; 0,75; 0,95\}$ ;  $p_M \in \{0,001; 0,01; 0,1\}$ .



## Algoritmo ávido para minimizar el costo

Similar al de la variante monoobjetivo pero considerando las distintas capacidades de los vehículos.

## Algoritmo ávido para minimizar la demora

- Se crea un taxi vacío para cada pasajero con nivel máximo de apuro y se los ubica en la primera posición.
- Luego, se recorre la lista de pasajeros no asignados en orden de apuro, colocándolos en el taxi que minimice su demora.
- Si el taxi alcanza la máxima capacidad disponible, se lo considera *completo* y no acepta más pasajeros.

## Algoritmo ávido para minimizar el costo

Similar al de la variante monoobjetivo pero considerando las distintas capacidades de los vehículos.

## Algoritmo ávido para minimizar la demora

- Se crea un taxi vacío para cada pasajero con nivel máximo de apuro y se los ubica en la primera posición.
- Luego, se recorre la lista de pasajeros no asignados en orden de apuro, colocándolos en el taxi que minimice su demora.
- Si el taxi alcanza la máxima capacidad disponible, se lo considera *completo* y no acepta más pasajeros.

# Resultados numéricos

*$\mu$ MOEA/D: "Planificación multiobjetivo de viajes compartidos en taxis utilizando un micro algoritmo evolutivo paralelo" (MAEB)*

Hasta **101.2 %** de mejora en demora y **72.8 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	8.5±2.1 (16.0)	3.1±2.5 (0.0)	740.2±746.3 (58.1)	0.6±0.2 (0.1)	0.9±0.1 (1.0)
medianas	9.1±2.2 (19.0)	5.7±2.5 (0.0)	1448.5±1064.1 (141.6)	0.6±0.1 (0.1)	0.9±0.1 (1.0)
grandes	8.5±2.2 (17.0)	7.9±3.4 (2.0)	2917.2±2041.5 (175.3)	0.6±0.1 (0.0)	0.8±0.1 (1.0)
Montevideo	8.0±2.1 (14.0)	3.0±2.0 (0.0)	663.5±542.4 (61.5)	0.6±0.2 (0.0)	0.9±0.0 (1.0)

Buena convergencia y diversidad. Pocas soluciones no dominadas.

*NSGA-II: "Multiobjective taxi sharing optimization using the NSGA-II evolutionary algorithm" (MIC)*

Hasta **105.2 %** de mejora en demora y **75.1 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	32.6±9.5 (55.0)	0.3±0.6 (0.0)	236.2±222.7 (43.2)	0.9±0.1 (0.7)	1.0±0.0 (1.0)
medianas	54.5±4.2 (67.0)	1.0±0.7 (0.0)	193.6±202.4 (26.2)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
grandes	55.2±3.5 (67.0)	1.8±1.1 (0.4)	243.6±229.8 (26.4)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
Montevideo	43.9±16.4 (61.0)	0.4±0.5 (0.0)	142.3±143.2 (20.8)	0.8±0.1 (0.5)	1.0±0.0 (1.0)

Mayor cantidad de puntos no dominados (hasta 67/80).

Buena convergencia y diversidad en las soluciones encontradas.

# Resultados numéricos

$\mu$ MOEA/D: "Planificación multiobjetivo de viajes compartidos en taxis utilizando un micro algoritmo evolutivo paralelo" (MAEB)

Hasta **101.2 %** de mejora en demora y **72.8 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	8.5±2.1 (16.0)	3.1±2.5 (0.0)	740.2±746.3 (58.1)	0.6±0.2 (0.1)	0.9±0.1 (1.0)
medianas	9.1±2.2 (19.0)	5.7±2.5 (0.0)	1448.5±1064.1 (141.6)	0.6±0.1 (0.1)	0.9±0.1 (1.0)
grandes	8.5±2.2 (17.0)	7.9±3.4 (2.0)	2917.2±2041.5 (175.3)	0.6±0.1 (0.0)	0.8±0.1 (1.0)
Montevideo	8.0±2.1 (14.0)	3.0±2.0 (0.0)	663.5±542.4 (61.5)	0.6±0.2 (0.0)	0.9±0.0 (1.0)

Buena convergencia y diversidad. Pocas soluciones no dominadas.

NSGA-II: "Multiobjective taxi sharing optimization using the NSGA-II evolutionary algorithm" (MIC)

Hasta **105.2 %** de mejora en demora y **75.1 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	32.6±9.5 (55.0)	0.3±0.6 (0.0)	236.2±222.7 (43.2)	0.9±0.1 (0.7)	1.0±0.0 (1.0)
medianas	54.5±4.2 (67.0)	1.0±0.7 (0.0)	193.6±202.4 (26.2)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
grandes	55.2±3.5 (67.0)	1.8±1.1 (0.4)	243.6±229.8 (26.4)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
Montevideo	43.9±16.4 (61.0)	0.4±0.5 (0.0)	142.3±143.2 (20.8)	0.8±0.1 (0.5)	1.0±0.0 (1.0)

Mayor cantidad de puntos no dominados (hasta 67/80).

Buena convergencia y diversidad en las soluciones encontradas.

# Resultados numéricos

$\rho\mu$ MOEA/D: "Planificación multiobjetivo de viajes compartidos en taxis utilizando un micro algoritmo evolutivo paralelo" (MAEB)

Hasta **101.2 %** de mejora en demora y **72.8 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	8.5±2.1 (16.0)	3.1±2.5 (0.0)	740.2±746.3 (58.1)	0.6±0.2 (0.1)	0.9±0.1 (1.0)
medianas	9.1±2.2 (19.0)	5.7±2.5 (0.0)	1448.5±1064.1 (141.6)	0.6±0.1 (0.1)	0.9±0.1 (1.0)
grandes	8.5±2.2 (17.0)	7.9±3.4 (2.0)	2917.2±2041.5 (175.3)	0.6±0.1 (0.0)	0.8±0.1 (1.0)
Montevideo	8.0±2.1 (14.0)	3.0±2.0 (0.0)	663.5±542.4 (61.5)	0.6±0.2 (0.0)	0.9±0.0 (1.0)

Buena convergencia y diversidad. Pocas soluciones no dominadas.

NSGA-II: "Multiobjective taxi sharing optimization using the NSGA-II evolutionary algorithm" (MIC)

Hasta **105.2 %** de mejora en demora y **75.1 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	32.6±9.5 (55.0)	0.3±0.6 (0.0)	236.2±222.7 (43.2)	0.9±0.1 (0.7)	1.0±0.0 (1.0)
medianas	54.5±4.2 (67.0)	1.0±0.7 (0.0)	193.6±202.4 (26.2)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
grandes	55.2±3.5 (67.0)	1.8±1.1 (0.4)	243.6±229.8 (26.4)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
Montevideo	43.9±16.4 (61.0)	0.4±0.5 (0.0)	142.3±143.2 (20.8)	0.8±0.1 (0.5)	1.0±0.0 (1.0)

Mayor cantidad de puntos no dominados (hasta 67/80).

Buena convergencia y diversidad en las soluciones encontradas.

# Resultados numéricos

*$\mu$ MOEA/D: "Planificación multiobjetivo de viajes compartidos en taxis utilizando un micro algoritmo evolutivo paralelo" (MAEB)*

Hasta **101.2 %** de mejora en demora y **72.8 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	8.5±2.1 (16.0)	3.1±2.5 (0.0)	740.2±746.3 (58.1)	0.6±0.2 (0.1)	0.9±0.1 (1.0)
medianas	9.1±2.2 (19.0)	5.7±2.5 (0.0)	1448.5±1064.1 (141.6)	0.6±0.1 (0.1)	0.9±0.1 (1.0)
grandes	8.5±2.2 (17.0)	7.9±3.4 (2.0)	2917.2±2041.5 (175.3)	0.6±0.1 (0.0)	0.8±0.1 (1.0)
Montevideo	8.0±2.1 (14.0)	3.0±2.0 (0.0)	663.5±542.4 (61.5)	0.6±0.2 (0.0)	0.9±0.0 (1.0)

Buena convergencia y diversidad. Pocas soluciones no dominadas.

*NSGA-II: "Multiobjective taxi sharing optimization using the NSGA-II evolutionary algorithm" (MIC)*





Hasta **105.2 %** de mejora en demora y **75.1 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	32.6±9.5 (55.0)	0.3±0.6 (0.0)	236.2±222.7 (43.2)	0.9±0.1 (0.7)	1.0±0.0 (1.0)
medianas	54.5±4.2 (67.0)	1.0±0.7 (0.0)	193.6±202.4 (26.2)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
grandes	55.2±3.5 (67.0)	1.8±1.1 (0.4)	243.6±229.8 (26.4)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
Montevideo	43.9±16.4 (61.0)	0.4±0.5 (0.0)	142.3±143.2 (20.8)	0.8±0.1 (0.5)	1.0±0.0 (1.0)

Mayor cantidad de puntos no dominados (hasta 67/80).


Buena convergencia y diversidad en las soluciones encontradas.

# Frentes de Pareto: $p\mu$ MOEA/D vs. NSGA-II



**NSGA-II alcanza mejores soluciones:** mayor cantidad de puntos no dominados distribuidos homogéneamente a lo largo del frente.

# Mejora frente a algoritmos ávidos vs. tiempo de ejecución






- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea**
- 7 Conclusiones y trabajo futuro

# Planificador de viajes compartidos en línea


- Se ingresa el origen, los destinos y la tarifa (diurna/nocturna).

- Se ejecuta el AE y se muestra la planificación calculada.




# Planificador de viajes compartidos en línea

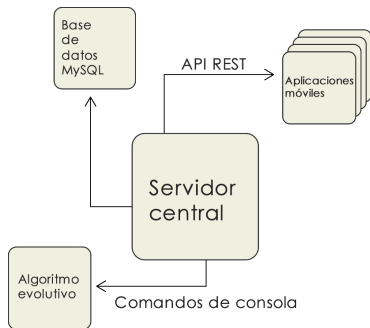
- Se ingresa el origen, los destinos y la tarifa (diurna/nocturna).



- Se ejecuta el AE y se muestra la planificación calculada.



# Arquitectura del planificador de viajes compartidos en línea



- Servidor implementado en Ruby on Rails siguiendo MVC.
- Las aplicaciones móviles consumen la API del servidor.
- Aplicaciones móviles: desarrollo híbrido vs. desarrollo nativo.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p $\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p $\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis ([www.mepaseaste.uy](http://www.mepaseaste.uy)).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p $\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p $\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis ([www.mepaseaste.uy](http://www.mepaseaste.uy)).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p $\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p $\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis ([www.mepaseaste.uy](http://www.mepaseaste.uy)).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .



- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p $\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p $\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis ([www.mepaseaste.uy](http://www.mepaseaste.uy)).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p $\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p $\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis ([www.mepaseaste.uy](http://www.mepaseaste.uy)).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p $\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p $\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis ([www.mepaseaste.uy](http://www.mepaseaste.uy)).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería de Muestra 2014” .

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p $\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p $\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis ([www.mepaseaste.uy](http://www.mepaseaste.uy)).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

# Trabajo futuro

## Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico**.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

## Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de usuario.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

## Problemas relacionados

- Estudiar otras variantes del problema (many-to-one, many-to-many).
- Estudiar la aplicabilidad de los AE a otros escenarios.

# Trabajo futuro

## Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico**.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

## Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de usuario.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

## Problemas relacionados

- Estudiar otras variantes del problema (many-to-one, many-to-many).
- Estudiar la aplicabilidad de los AE a otros escenarios.

# Trabajo futuro

## Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico**.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

## Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de usuario.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

## Problemas relacionados

- Estudiar otras variantes del problema (many-to-one, many-to-many).
- Estudiar la aplicabilidad de los AE a otros escenarios.

# Gracias

Sitio web del proyecto:

[www.fing.edu.uy/inco/grupos/cecal/hpc/AG-Taxi/](http://www.fing.edu.uy/inco/grupos/cecal/hpc/AG-Taxi/)