

Optimización de viajes compartidos en taxis utilizando algoritmos evolutivos

Gabriel Fagúndez de los Reyes Renzo Massobrio

Facultad de Ingeniería,
Universidad de la República,
Montevideo, Uruguay



- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

Los viajes compartidos (*Car Pooling*)

- Beneficios ecológicos y económicos, individuales y colectivos.
- Iniciativas:
 - Carriles exclusivos
 - Campañas para compartir los viajes al trabajo
 - Aplicaciones para encontrar compañeros de viaje

Los viajes compartidos en taxis (*Taxi Pooling*)

- Taxis, medio de transporte rápido y confiable.
- Raramente viajan a capacidad completa.
- Tarifas altas desalientan a los usuarios.
- Impactan en la congestión del tráfico y en la contaminación.

Los viajes compartidos (*Car Pooling*)

- Beneficios ecológicos y económicos, individuales y colectivos.
- Iniciativas:
 - Carriles exclusivos
 - Campañas para compartir los viajes al trabajo
 - Aplicaciones para encontrar compañeros de viaje

Los viajes compartidos en taxis (*Taxi Pooling*)

- Taxis, medio de transporte rápido y confiable.
- Raramente viajan a capacidad completa.
- Tarifas altas desalientan a los usuarios.
- Impactan en la congestión del tráfico y en la contaminación.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

Descripción del problema

Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Hallar la cantidad de taxis y la asignación de pasajeros para minimizar el **costo total**.

Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- El número máximo de taxis para N pasajeros es N .
- Costo de un taxi = **costo inicial** + **costo por trayectos**.
- No se consideran otros costos (e.g. esperas, propinas, peajes).

Descripción del problema

Problema de viajes compartidos en taxis (PVCT)

Un grupo de personas en un **mismo lugar de origen**, desean viajar hacia **diferentes destinos** utilizando taxis de forma compartida. Hallar la cantidad de taxis y la asignación de pasajeros para minimizar el **costo total**.

Consideraciones

- Cada taxi puede trasladar a un número limitado de pasajeros.
- El número máximo de taxis para N pasajeros es N .
- Costo de un taxi = **costo inicial** + **costo por trayectos**.
- No se consideran otros costos (e.g. esperas, propinas, peajes).

Formulación del problema

- Un conjunto de pasajeros P que viajan desde un origen O a un conjunto de destinos D .
- Un conjunto de taxis T y una función $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$ con C_{MAX} máxima capacidad permitida en un taxi.
- Una constante B que determina el costo inicial del taxi.
- Una función de distancia, $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$, y una función de costo asociado a la distancia recorrida por cada taxi, $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$.

Se busca una planificación $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$ que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \underbrace{cost \left(dist \left(dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right]$$

Formulación del problema

- Un conjunto de pasajeros P que viajan desde un origen O a un conjunto de destinos D .
- Un conjunto de taxis T y una función $C : T \rightarrow \{0, 1, \dots, C_{MAX}\}$ con C_{MAX} máxima capacidad permitida en un taxi.
- Una constante B que determina el costo inicial del taxi.
- Una función de distancia, $dist : \{\{O\} \cup D\} \times D \rightarrow \mathbb{R}_0^+$, y una función de costo asociado a la distancia recorrida por cada taxi, $cost : \mathbb{R}_0^+ \rightarrow \mathbb{R}_0^+$.

Se busca una planificación $f : P \rightarrow T \times \{1, \dots, C_{MAX}\}$ que **minimice la función de costo total (CT)**.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} cost \left(\underbrace{dist \left(dest(f^{-1}(t_i, j-1)), dest(f^{-1}(t_i, j)) \right)}_{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

Variante multiobjetivo del PVCT: formulación matemática

- Se busca minimizar el **costo total** y la **demora total**.
- Se incorporan dos variables:
 - Se consideran vehículos con **diferentes capacidades**.
 - Cada pasajero tiene un **nivel de apuro** asociado.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \text{cost} \left(\overbrace{\text{dist} \left(\text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[\sum_{j=1}^{C(t_i)} \left[\underbrace{\sum_{h=1}^j \text{time} \left(\text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}_{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} - \underbrace{\left(\text{tol}(f^{-1}(t_i, j)) + \text{time} \left(O, \text{dest}(f^{-1}(t_i, j)) \right) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

Variante multiobjetivo del PVCT: formulación matemática

- Se busca minimizar el **costo total** y la **demora total**.
- Se incorporan dos variables:
 - Se consideran vehículos con **diferentes capacidades**.
 - Cada pasajero tiene un **nivel de apuro** asociado.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \text{cost} \left(\overbrace{\text{dist} \left(\text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[\sum_{j=1}^{C(t_i)} \left[\underbrace{\sum_{h=1}^j \text{time} \left(\text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}_{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} - \underbrace{\left(\text{tol}(f^{-1}(t_i, j)) + \text{time} \left(O, \text{dest}(f^{-1}(t_i, j)) \right) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

Variante multiobjetivo del PVCT: formulación matemática

- Se busca minimizar el **costo total** y la **demora total**.
- Se incorporan dos variables:
 - Se consideran vehículos con **diferentes capacidades**.
 - Cada pasajero tiene un **nivel de apuro** asociado.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \text{cost} \left(\overbrace{\text{dist} \left(\text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[\sum_{j=1}^{C(t_i)} \left[\underbrace{\sum_{h=1}^j \text{time} \left(\text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}_{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} - \underbrace{\left(\text{tol}(f^{-1}(t_i, j)) + \text{time} \left(O, \text{dest}(f^{-1}(t_i, j)) \right) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

Variante multiobjetivo del PVCT: formulación matemática

- Se busca minimizar el **costo total** y la **demora total**.
- Se incorporan dos variables:
 - Se consideran vehículos con **diferentes capacidades**.
 - Cada pasajero tiene un **nivel de apuro** asociado.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \text{cost} \left(\overbrace{\text{dist} \left(\text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

tiempo efectivo de traslado del pasajero en la posición j del taxi t_i

$$DT = \sum_{t_i} \left[\sum_{j=1}^{C(t_i)} \left[\sum_{h=1}^j \text{time} \left(\text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right) \right. \right. \\ \left. \left. - \underbrace{\left(\text{tol}(f^{-1}(t_i, j)) + \text{time}(O, \text{dest}(f^{-1}(t_i, j))) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

tiempo tolerado por el pasajero en la posición j del taxi t_i

Variante multiobjetivo del PVCT: formulación matemática

- Se busca minimizar el **costo total** y la **demora total**.
- Se incorporan dos variables:
 - Se consideran vehículos con **diferentes capacidades**.
 - Cada pasajero tiene un **nivel de apuro** asociado.

$$CT = \sum_{t_i, C(t_i) \neq 0} \left[B + \sum_{j=1}^{C(t_i)} \text{cost} \left(\overbrace{\text{dist} \left(\text{dest}(f^{-1}(t_i, j-1)), \text{dest}(f^{-1}(t_i, j)) \right)}^{\text{destinos consecutivos en el recorrido del taxi } t_i} \right) \right]$$

$$DT = \sum_{t_i} \left[\sum_{j=1}^{C(t_i)} \left[\underbrace{\sum_{h=1}^j \text{time} \left(\text{dest}(f^{-1}(t_i, h-1)), \text{dest}(f^{-1}(t_i, h)) \right)}_{\text{tiempo efectivo de traslado del pasajero en la posición } j \text{ del taxi } t_i} - \underbrace{\left(\text{tol}(f^{-1}(t_i, j)) + \text{time} \left(O, \text{dest}(f^{-1}(t_i, j)) \right) \right)}_{\text{tiempo tolerado por el pasajero en la posición } j \text{ del taxi } t_i} \right] \right]$$

Complejidad

- Baldacci et al. (2004):
 - Variante del *Car Pooling Problem (CPP)*.
 - Solución al problema de compartir vehículos en el trabajo.
- Caso especial del *Vehicle Routing Problem (VRP)* con demanda unitaria:
 - Letcheford et al. (2002) demostró que es \mathcal{NP} -difícil.
- Similitudes determinan que nuestro problema también es \mathcal{NP} -difícil.

Estrategias de resolución

- Con instancias de tamaños realistas los algoritmos exactos tradicionales no resultan útiles para una planificación eficiente.
- **Heurísticas** y **metaheurísticas** son necesarias para calcular soluciones de calidad aceptable en tiempos razonables.

Complejidad

- Baldacci et al. (2004):
 - Variante del *Car Pooling Problem (CPP)*.
 - Solución al problema de compartir vehículos en el trabajo.
- Caso especial del *Vehicle Routing Problem (VRP)* con demanda unitaria:
 - Letchford et al. (2002) demostró que es \mathcal{NP} -difícil.
- Similitudes determinan que nuestro problema también es \mathcal{NP} -difícil.

Estrategias de resolución

- Con instancias de tamaños realistas los algoritmos exactos tradicionales no resultan útiles para una planificación eficiente.
- **Heurísticas** y **metaheurísticas** son necesarias para calcular soluciones de calidad aceptable en tiempos razonables.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados**
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

Trabajo relacionado

Car pooling problem (CPP)

Yan et al. (2011): **CPP con histórico de viajes** (relajación lagrangeana).

Dial-a-ride problem (DARP)

Cordeau et al. (2003): **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

Taxi pooling problem (TPP)

Tao et al. (2007): heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013): TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

Trabajo relacionado

Car pooling problem (CPP)

Yan et al. (2011): **CPP con histórico de viajes** (relajación lagrangeana).

Dial-a-ride problem (DARP)

Cordeau et al. (2003): **DARP estático con ventanas de tiempo.**

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

Taxi pooling problem (TPP)

Tao et al. (2007): heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013): TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas.**

Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo.**

Trabajo relacionado

Car pooling problem (CPP)

Yan et al. (2011): **CPP con histórico de viajes** (relajación lagrangeana).

Dial-a-ride problem (DARP)

Cordeau et al. (2003): **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

Taxi pooling problem (TPP)

Tao et al. (2007): heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013): TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

Trabajo relacionado

Car pooling problem (CPP)

Yan et al. (2011): **CPP con histórico de viajes** (relajación lagrangeana).

Dial-a-ride problem (DARP)

Cordeau et al. (2003): **DARP estático con ventanas de tiempo**.

Búsqueda tabú con tiempos de ejecución de hasta 90 minutos.

Taxi pooling problem (TPP)

Tao et al. (2007): heurísticas ávidas para **one-to-many** y many-to-one.

Las mejoras se reportan en términos absolutos.

Ma et al. (2013): TPP dinámico con pedidos en tiempo real.

13 % de ahorro en distancia con un algoritmo ávido en **instancias realistas**.

Resumen

Pocos trabajos **centrados en el usuario** y con un enfoque **multiobjetivo**.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación**
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

Definición

- Técnicas estocásticas que emulan el proceso de evolución natural de las especies.
- Aplicadas a problemas de **optimización**, búsqueda y aprendizaje.
- Técnica iterativa (**generación**) que aplica operadores estocásticos sobre un conjunto de individuos (**población**).
- Cada individuo codifica una solución tentativa al problema y tiene un valor de **fitness**.
- El propósito es mejorar el fitness de los individuos en la población mediante la aplicación de **operadores evolutivos**.
- Los operadores guían al algoritmo evolutivo hacia soluciones tentativas de mayor calidad.

Definición

- Técnicas estocásticas que emulan el proceso de evolución natural de las especies.
- Aplicadas a problemas de **optimización**, búsqueda y aprendizaje.
- Técnica iterativa (**generación**) que aplica operadores estocásticos sobre un conjunto de individuos (**población**).
- Cada individuo codifica una solución tentativa al problema y tiene un valor de **fitness**.
- El propósito es mejorar el fitness de los individuos en la población mediante la aplicación de **operadores evolutivos**.
- Los operadores guían al algoritmo evolutivo hacia soluciones tentativas de mayor calidad.

Definición

- Técnicas estocásticas que emulan el proceso de evolución natural de las especies.
- Aplicadas a problemas de **optimización**, búsqueda y aprendizaje.
- Técnica iterativa (**generación**) que aplica operadores estocásticos sobre un conjunto de individuos (**población**).
- Cada individuo codifica una solución tentativa al problema y tiene un valor de **fitness**.
- El propósito es mejorar el fitness de los individuos en la población mediante la aplicación de **operadores evolutivos**.
- Los operadores guían al algoritmo evolutivo hacia soluciones tentativas de mayor calidad.

Definición

- Técnicas estocásticas que emulan el proceso de evolución natural de las especies.
- Aplicadas a problemas de **optimización**, búsqueda y aprendizaje.
- Técnica iterativa (**generación**) que aplica operadores estocásticos sobre un conjunto de individuos (**población**).
- Cada individuo codifica una solución tentativa al problema y tiene un valor de **fitness**.
- El propósito es mejorar el fitness de los individuos en la población mediante la aplicación de **operadores evolutivos**.
- Los operadores guían al algoritmo evolutivo hacia soluciones tentativas de mayor calidad.

Definición

- Técnicas estocásticas que emulan el proceso de evolución natural de las especies.
- Aplicadas a problemas de **optimización**, búsqueda y aprendizaje.
- Técnica iterativa (**generación**) que aplica operadores estocásticos sobre un conjunto de individuos (**población**).
- Cada individuo codifica una solución tentativa al problema y tiene un valor de **fitness**.
- El propósito es mejorar el fitness de los individuos en la población mediante la aplicación de **operadores evolutivos**.
- Los operadores guían al algoritmo evolutivo hacia soluciones tentativas de mayor calidad.


Definición

- Técnicas estocásticas que emulan el proceso de evolución natural de las especies.
- Aplicadas a problemas de **optimización**, búsqueda y aprendizaje.
- Técnica iterativa (**generación**) que aplica operadores estocásticos sobre un conjunto de individuos (**población**).
- Cada individuo codifica una solución tentativa al problema y tiene un valor de **fitness**.
- El propósito es mejorar el fitness de los individuos en la población mediante la aplicación de **operadores evolutivos**.
- Los operadores guían al algoritmo evolutivo hacia soluciones tentativas de mayor calidad.

AE para el PVCT monoobjetivo

Aspectos comunes


- Tuplas de largo $2N - 1$
 $N = \text{\#pasajeros}$.
- Inicialización:
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



AE para el PVCT monoobjetivo

Aspectos comunes


- Tuplas de largo $2N - 1$
 $N = \text{\#pasajeros}$.
- Inicialización:
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



AE para el PVCT monoobjetivo

Aspectos comunes


- Tuplas de largo $2N - 1$
 $N = \text{\#pasajeros}$.
- Inicialización:
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



AE para el PVCT monoobjetivo

Aspectos comunes


- Tuplas de largo $2N - 1$
 $N = \text{\#pasajeros}$.
- Inicialización:
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:
desplaza ceros para
romper secuencias de
dígitos inválidas.
- Implementados en Malva.



AE para el PVCT monoobjetivo

Aspectos comunes


- Tuplas de largo $2N - 1$
 $N = \text{\#pasajeros}$.
- Inicialización:
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



AE para el PVCT monoobjetivo

Aspectos comunes

- Tuplas de largo $2N - 1$
 $N = \# \text{pasajeros}$.
- Inicialización:
aleatoria y ávida.
- Cruzamiento basado en posición (PBX).
- Mutación por intercambio (EM).
- Función correctiva:
desplaza ceros para romper secuencias de dígitos inválidas.
- Implementados en Malva.



AE para el PVCT monoobjetivo

AE secuencial (*seqEA*)

- Selección proporcional.

Micro AE paralelo (*pμEA*)

- Se busca **mejorar el desempeño** mediante el paralelismo.
- **Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.
- Poblaciones pequeñas.
- Selección por torneo (m, k).
- Migración asíncrona, con topología de anillo unidireccional.

AE para el PVCT monoobjetivo

AE secuencial (*seqEA*)

- Selección proporcional.

Micro AE paralelo (*pμEA*)

- Se busca **mejorar el desempeño** mediante el paralelismo.
- **Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.
- Poblaciones pequeñas.
- Selección por torneo (m, k).
- Migración asíncrona, con topología de anillo unidireccional.


AE para el PVCT monoobjetivo

AE secuencial (*seqEA*)

- Selección proporcional.

Micro AE paralelo (*pμEA*)

- Se busca **mejorar el desempeño** mediante el paralelismo.
- **Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.



- Poblaciones pequeñas.
- Selección por torneo (m, k).
- Migración asíncrona, con topología de anillo unidireccional.


AE para el PVCT monoobjetivo

AE secuencial (*seqEA*)

- Selección proporcional.

Micro AE paralelo (*pμEA*)

- Se busca **mejorar el desempeño** mediante el paralelismo.
- **Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.



- Poblaciones pequeñas.
- Selección por torneo (m, k).
- Migración asíncrona, con topología de anillo unidireccional.


AE para el PVCT monoobjetivo

AE secuencial (*seqEA*)

- Selección proporcional.

Micro AE paralelo (*pμEA*)

- Se busca **mejorar el desempeño** mediante el paralelismo.
- **Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.



- Poblaciones pequeñas.
- Selección por torneo (m, k).
- Migración asíncrona, con topología de anillo unidireccional.


AE para el PVCT monoobjetivo

AE secuencial (*seqEA*)

- Selección proporcional.

Micro AE paralelo (*pμEA*)

- Se busca **mejorar el desempeño** mediante el paralelismo.
- **Modelo de subpoblaciones distribuidas**: divide la población en **islas** que intercambian individuos mediante **migración**.



- Poblaciones pequeñas.
- Selección por torneo (m, k).
- Migración asíncrona, con topología de anillo unidireccional.

AE para el PVCT multiobjetivo

Aspectos comunes

- MOEA: Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).
- Función correctiva considera vehículos de distintas capacidades.
- Inicialización de la población ávida y selección por torneo.

MOEA paralelo con micro-población y descomposición de dominio ($p\mu$ MOEA/D)

Agregación lineal de los objetivos:

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$

MOEA explícito (NSGA-II)

Ordenamiento no-dominado (elitista), *crowding* para preservar diversidad.

AE para el PVCT multiobjetivo

Aspectos comunes

- MOEA: Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).
- Función correctiva considera vehículos de distintas capacidades.
- Inicialización de la población ávida y selección por torneo.

MOEA paralelo con micro-población y descomposición de dominio ($p\mu$ MOEA/D)

Agregación lineal de los objetivos:

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$

MOEA explícito (*NSGA-II*)

Ordenamiento no-dominado (elitista), *crowding* para preservar diversidad.

AE para el PVCT multiobjetivo

Aspectos comunes

- MOEA: Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).
- Función correctiva considera vehículos de distintas capacidades.
- Inicialización de la población ávida y selección por torneo.

MOEA paralelo con micro-población y descomposición de dominio ($p\mu\text{MOEA}/D$)

Agregación lineal de los objetivos:

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\# \text{islas}} : 1], w_D = 1 - w_C.$$

MOEA explícito (*NSGA-II*)

Ordenamiento no-dominado (elitista), *crowding* para preservar diversidad.

AE para el PVCT multiobjetivo

Aspectos comunes


- MOEA: Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).
- Función correctiva considera vehículos de distintas capacidades.
- Inicialización de la población ávida y selección por torneo.

MOEA paralelo con micro-población y descomposición de dominio ($p\mu$ MOEA/D)

Agregación lineal de los objetivos:

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$



MOEA explícito (*NSGA-II*)

Ordenamiento no-dominado (elitista), *crowding* para preservar diversidad.

AE para el PVCT multiobjetivo

Aspectos comunes


- MOEA: Acercarse al frente de Pareto del problema (**convergencia**) y muestrear adecuadamente el frente de soluciones (**diversidad**).
- Función correctiva considera vehículos de distintas capacidades.
- Inicialización de la población ávida y selección por torneo.

MOEA paralelo con micro-población y descomposición de dominio ($p\mu$ MOEA/D)

Agregación lineal de los objetivos:

$$F = w_C \times CT + w_D \times DT,$$

$$w_C = [0 : \frac{1}{\#islas} : 1], w_D = 1 - w_C.$$



MOEA explícito (*NSGA-II*)

Ordenamiento no-dominado (elitista), *crowding* para preservar diversidad.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación
- 5 Evaluación experimental**
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

Generación de instancias

Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- API para obtener tarifas TaxiFareFinder (TFF).
- Instancias en Montevideo generadas manualmente.

Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 instancias para el PVCT multiobjetivo, variando capacidades y tolerancias.

Generación de instancias

Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- API para obtener tarifas TaxiFareFinder (TFF).
- Instancias en Montevideo generadas manualmente.

Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 instancias para el PVCT multiobjetivo, variando capacidades y tolerancias.

Generación de instancias

Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- API para obtener tarifas TaxiFareFinder (TFF).
- Instancias en Montevideo generadas manualmente.

Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 instancias para el PVCT multiobjetivo, variando capacidades y tolerancias.

Generación de instancias

Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- API para obtener tarifas TaxiFareFinder (TFF).
- Instancias en Montevideo generadas manualmente.

Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 instancias para el PVCT multiobjetivo, variando capacidades y tolerancias.

Generación de instancias

Generación de puntos realistas en el mapa

- Generador de Pedidos de Taxis (TQG) con datos de GPS de taxis de Beijing (Ma et al., 2013).
- Script para obtener instancias de un origen a muchos destinos.
- API para obtener tarifas TaxiFareFinder (TFF).
- Instancias en Montevideo generadas manualmente.

Instancias generadas

- **6 chicas:** 10 y 15 pasajeros (Beijing).
- **6 medianas:** 15 y 25 pasajeros (Beijing).
- **6 grandes:** 25 y 45 pasajeros (Beijing).
- **4 en Montevideo:** 8 y 17 pasajeros (Montevideo).

22 instancias para el PVCT monoobjetivo y 88 instancias para el PVCT multiobjetivo, variando capacidades y tolerancias.

Entorno de ejecución

- Evaluación experimental realizada en el Cluster FING.
- Sin compartir recursos para evitar interferencias.



Ejecuciones

- 30 ejecuciones independientes de cada algoritmo sobre cada instancia.
- Criterio de parada: 10.000 generaciones (planificación en línea).

Comparación de resultados

- Tests estadísticos sobre las distribuciones de resultados:
 - Shapiro–Wilk sobre cada muestra para contrastar normalidad.
 - Kruskal–Wallis para comparar las muestras entre sí.
- En ambos tests se utiliza un nivel de confianza del 95 % ($\alpha = 0,05$).

Entorno de ejecución

- Evaluación experimental realizada en el Cluster FING.
- Sin compartir recursos para evitar interferencias.



Ejecuciones

- **30 ejecuciones independientes** de cada algoritmo sobre cada instancia.
- Criterio de parada: **10.000 generaciones** (planificación en línea).

Comparación de resultados

- Tests estadísticos sobre las distribuciones de resultados:
 - Shapiro–Wilk sobre cada muestra para contrastar normalidad.
 - Kruskal–Wallis para comparar las muestras entre sí.
- En ambos tests se utiliza un nivel de confianza del 95 % ($\alpha = 0,05$).

Entorno de ejecución

- Evaluación experimental realizada en el Cluster FING.
- Sin compartir recursos para evitar interferencias.



Ejecuciones

- **30 ejecuciones independientes** de cada algoritmo sobre cada instancia.
- Criterio de parada: **10.000 generaciones** (planificación en línea).

Comparación de resultados

- Tests estadísticos sobre las distribuciones de resultados:
 - Shapiro–Wilk sobre cada muestra para contrastar normalidad.
 - Kruskal–Wallis para comparar las muestras entre sí.
- En ambos tests se utiliza un nivel de confianza del 95 % ($\alpha = 0,05$).

Configuración paramétrica

- **seqEA**: $\#P \in \{150; 200; 250\}$; $p_C \in \{0,6; 0,75; 0,95\}$;
 $p_M \in \{0,001; 0,01; 0,1\}$.
- **p μ EA**: micro-población de 15 individuos, torneo ($m = 2$, $k = 1$),
migración cada 500 generaciones.
 $p_C \in \{0,6; 0,75; 0,95\}$; $p_M \in \{0,001; 0,01; 0,1\}$.

Configuración paramétrica

- **seqEA**: $\#P \in \{150; 200; 250\}$; $p_C \in \{0,6; 0,75; 0,95\}$;
 $p_M \in \{0,001; 0,01; 0,1\}$.
- **p μ EA**: micro-población de 15 individuos, torneo ($m = 2$, $k = 1$),
migración cada 500 generaciones.
 $p_C \in \{0,6; 0,75; 0,95\}$; $p_M \in \{0,001; 0,01; 0,1\}$.


Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.




Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.




Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.




Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.



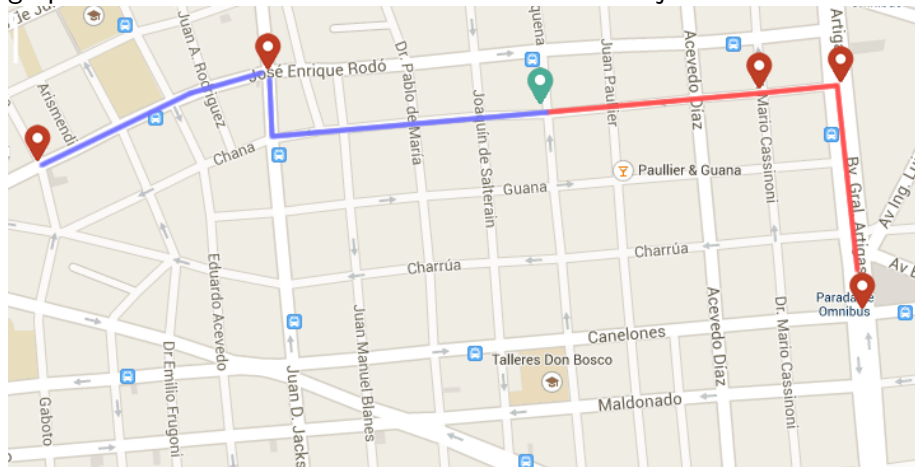
Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.



Algoritmo ávido

Toma **decisiones localmente óptimas** y emula el comportamiento de un grupo de usuarios humanos. Utiliza ideas de los trabajos relacionados.



Comparativa de métodos de inicialización

Resultados *seqEA*

- Inicialización ávida supera a inicialización aleatoria en 10 instancias.
- Inicialización aleatoria supera a inicialización ávida en 2 instancias.
- No hay diferencias estadísticamente significativas en 10 instancias.

Resultados *pμEA*

- Inicialización ávida supera a inicialización aleatoria en 11 instancias.
- No hay instancias en las que la inicialización aleatoria supere a la inicialización ávida.
- No hay diferencias estadísticamente significativas en 11 instancias.

Conclusión

Se utiliza la **inicialización ávida** para el resto de la evaluación experimental.

Comparativa de métodos de inicialización

Resultados *seqEA*

- Inicialización ávida supera a inicialización aleatoria en 10 instancias.
- Inicialización aleatoria supera a inicialización ávida en 2 instancias.
- No hay diferencias estadísticamente significativas en 10 instancias.

Resultados *pμEA*

- Inicialización ávida supera a inicialización aleatoria en 11 instancias.
- No hay instancias en las que la inicialización aleatoria supere a la inicialización ávida.
- No hay diferencias estadísticamente significativas en 11 instancias.

Conclusión

Se utiliza la **inicialización ávida** para el resto de la evaluación experimental.

Comparativa de métodos de inicialización

Resultados *seqEA*

- Inicialización ávida supera a inicialización aleatoria en 10 instancias.
- Inicialización aleatoria supera a inicialización ávida en 2 instancias.
- No hay diferencias estadísticamente significativas en 10 instancias.





Resultados *pμEA*

- Inicialización ávida supera a inicialización aleatoria en 11 instancias.
- No hay instancias en las que la inicialización aleatoria supere a la inicialización ávida.
- No hay diferencias estadísticamente significativas en 11 instancias.

Conclusión





Se utiliza la **inicialización ávida** para el resto de la evaluación experimental.

Mejoras *seqEA* sobre algoritmo ávido



Mejoras en **todas** las instancias sobre el algoritmo ávido (hasta 35.9%).
“Online taxi sharing optimization using evolutionary algorithms, CLEI, 2014”

Mejoras $p\mu EA$ sobre algoritmo ávido







Mejoras en **todas** las instancias sobre el algoritmo ávido (hasta 41.0%).
“A parallel micro evolutionary algorithm for taxi sharing optimization, ALIO”

Comparativa $seqEA$ vs. $p\mu EA$

instancia		$seqEA$		$p\mu EA$		$pvK-W$
		$min(c)$	$\bar{c} \pm std$	$min(c)$	$\bar{c} \pm std$	
chicas	#1	164.4	165.6 \pm 2.0	164.4	164.4 \pm 0.0	0.2 $\times 10^{-3}$
	#2	220.7	225.7 \pm 5.0	220.7	220.7 \pm 0.0	9.7 $\times 10^{-6}$
	#3	160.4	160.4 \pm 0.0	160.4	160.4 \pm 0.0	1.0
	#4	181.3	181.3 \pm 0.1	181.3	182.4 \pm 1.9	0.5 $\times 10^{-1}$
	#5	152.1	155.6 \pm 4.5	152.1	152.1 \pm 0.0	5.1 $\times 10^{-6}$
	#6	118.4	119.6 \pm 2.5	118.4	118.4 \pm 0.0	0.1 $\times 10^{-1}$
medianas	#1	211.9	216.0 \pm 4.2	211.9	211.9 \pm 0.0	5.2 $\times 10^{-11}$
	#2	428.6	444.1 \pm 11.7	427.9	429.4 \pm 1.6	7.0 $\times 10^{-10}$
	#3	361.7	378.7 \pm 6.5	364.5	370.4 \pm 4.5	1.6 $\times 10^{-6}$
	#4	267.5	279.8 \pm 5.5	266.8	266.8 \pm 0.0	7.6 $\times 10^{-12}$
	#5	479.3	487.1 \pm 6.5	479.6	479.8 \pm 0.2	5.1 $\times 10^{-7}$
	#6	306.0	321.2 \pm 7.7	306.0	307.7 \pm 3.4	2.0 $\times 10^{-9}$
grandes	#1	421.9	435.1 \pm 5.0	425.9	437.7 \pm 3.2	0.1 $\times 10^{-1}$
	#2	479.3	489.9 \pm 4.3	477.0	481.1 \pm 2.3	1.9 $\times 10^{-9}$
	#3	332.8	349.7 \pm 7.7	326.3	331.7 \pm 4.0	2.6 $\times 10^{-10}$
	#4	351.1	390.7 \pm 26.3	338.4	344.8 \pm 6.1	5.1 $\times 10^{-11}$
	#5	395.9	429.6 \pm 16.2	370.2	380.0 \pm 4.4	2.7 $\times 10^{-11}$
	#6	360.8	382.4 \pm 8.1	343.8	350.6 \pm 3.8	2.6 $\times 10^{-11}$
Montevideo	#1	168.4	168.4 \pm 0.0	168.4	168.4 \pm 0.0	1.0
	#2	319.3	331.2 \pm 3.8	324.9	328.6 \pm 3.2	5.6 $\times 10^{-6}$
	#3	266.7	269.1 \pm 2.3	266.7	266.7 \pm 0.0	3.1 $\times 10^{-7}$
	#4	303.2	304.7 \pm 0.5	304.1	304.5 \pm 0.4	0.1

$p\mu EA$ supera a $seqEA$ en 17 de 22 instancias.
Únicamente en 1 instancia $seqEA$ supera a $p\mu EA$.

Evolución del costo a lo largo de una ejecución



pμEA alcanza mejores soluciones que *seqEA* en menos tiempo.
En el mejor caso alcanza una **aceleración de 7,5x** (4,6x en promedio).

Configuración paramétrica

- **p μ MOEA/D**: $\#P = 15$; selección por torneo ($m = 2, k = 1$); migración cada 1000 generaciones reemplazando a los peores individuos
 $p_C \in \{0,6; 0,75; 0,95\}$; $p_M \in \{0,001; 0,01; 0,1\}$
- **NSGA-II**: $\#P = 80$; selección por torneo ($m = 2, k = 1$);
 $p_C \in \{0,6; 0,75; 0,95\}$; $p_M \in \{0,001; 0,01; 0,1\}$.

Configuración paramétrica

- **p μ MOEA/D**: $\#P = 15$; selección por torneo ($m = 2, k = 1$); migración cada 1000 generaciones reemplazando a los peores individuos
 $p_C \in \{0,6; 0,75; 0,95\}$; $p_M \in \{0,001; 0,01; 0,1\}$
- **NSGA-II**: $\#P = 80$; selección por torneo ($m = 2, k = 1$);
 $p_C \in \{0,6; 0,75; 0,95\}$; $p_M \in \{0,001; 0,01; 0,1\}$.

Algoritmo ávido para minimizar el costo

Similar al de la variante monoobjetivo pero considerando las distintas capacidades de los vehículos.

Algoritmo ávido para minimizar la demora

- Se crea un taxi vacío para cada pasajero con nivel máximo de apuro y se los ubica en la primera posición.
- Luego, se recorre la lista de pasajeros no asignados en orden de apuro, colocándolos en el taxi que minimice su demora.
- Si el taxi alcanza la máxima capacidad disponible, se lo considera *completo* y no acepta más pasajeros.

Algoritmo ávido para minimizar el costo

Similar al de la variante monoobjetivo pero considerando las distintas capacidades de los vehículos.

Algoritmo ávido para minimizar la demora

- Se crea un taxi vacío para cada pasajero con nivel máximo de apuro y se los ubica en la primera posición.
- Luego, se recorre la lista de pasajeros no asignados en orden de apuro, colocándolos en el taxi que minimice su demora.
- Si el taxi alcanza la máxima capacidad disponible, se lo considera *completo* y no acepta más pasajeros.

Resultados numéricos

μ MOEA/D: "Planificación multiobjetivo de viajes compartidos en taxis utilizando un micro algoritmo evolutivo paralelo" (MAEB)

Hasta **101.2 %** de mejora en demora y **72.8 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	8.5±2.1 (16.0)	3.1±2.5 (0.0)	740.2±746.3 (58.1)	0.6±0.2 (0.1)	0.9±0.1 (1.0)
medianas	9.1±2.2 (19.0)	5.7±2.5 (0.0)	1448.5±1064.1 (141.6)	0.6±0.1 (0.1)	0.9±0.1 (1.0)
grandes	8.5±2.2 (17.0)	7.9±3.4 (2.0)	2917.2±2041.5 (175.3)	0.6±0.1 (0.0)	0.8±0.1 (1.0)
Montevideo	8.0±2.1 (14.0)	3.0±2.0 (0.0)	663.5±542.4 (61.5)	0.6±0.2 (0.0)	0.9±0.0 (1.0)

Buena convergencia y diversidad. Pocas soluciones no dominadas.

NSGA-II: "Multiobjective taxi sharing optimization using the NSGA-II evolutionary algorithm" (MIC)

Hasta **105.2 %** de mejora en demora y **75.1 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	32.6±9.5 (55.0)	0.3±0.6 (0.0)	236.2±222.7 (43.2)	0.9±0.1 (0.7)	1.0±0.0 (1.0)
medianas	54.5±4.2 (67.0)	1.0±0.7 (0.0)	193.6±202.4 (26.2)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
grandes	55.2±3.5 (67.0)	1.8±1.1 (0.4)	243.6±229.8 (26.4)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
Montevideo	43.9±16.4 (61.0)	0.4±0.5 (0.0)	142.3±143.2 (20.8)	0.8±0.1 (0.5)	1.0±0.0 (1.0)

Mayor cantidad de puntos no dominados (hasta 67/80).

Buena convergencia y diversidad en las soluciones encontradas.

Resultados numéricos

μ MOEA/D: "Planificación multiobjetivo de viajes compartidos en taxis utilizando un micro algoritmo evolutivo paralelo" (MAEB)

Hasta **101.2 %** de mejora en demora y **72.8 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	8.5±2.1 (16.0)	3.1±2.5 (0.0)	740.2±746.3 (58.1)	0.6±0.2 (0.1)	0.9±0.1 (1.0)
medianas	9.1±2.2 (19.0)	5.7±2.5 (0.0)	1448.5±1064.1 (141.6)	0.6±0.1 (0.1)	0.9±0.1 (1.0)
grandes	8.5±2.2 (17.0)	7.9±3.4 (2.0)	2917.2±2041.5 (175.3)	0.6±0.1 (0.0)	0.8±0.1 (1.0)
Montevideo	8.0±2.1 (14.0)	3.0±2.0 (0.0)	663.5±542.4 (61.5)	0.6±0.2 (0.0)	0.9±0.0 (1.0)

Buena convergencia y diversidad. Pocas soluciones no dominadas.

NSGA-II: "Multiobjective taxi sharing optimization using the NSGA-II evolutionary algorithm" (MIC)

Hasta **105.2 %** de mejora en demora y **75.1 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	32.6±9.5 (55.0)	0.3±0.6 (0.0)	236.2±222.7 (43.2)	0.9±0.1 (0.7)	1.0±0.0 (1.0)
medianas	54.5±4.2 (67.0)	1.0±0.7 (0.0)	193.6±202.4 (26.2)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
grandes	55.2±3.5 (67.0)	1.8±1.1 (0.4)	243.6±229.8 (26.4)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
Montevideo	43.9±16.4 (61.0)	0.4±0.5 (0.0)	142.3±143.2 (20.8)	0.8±0.1 (0.5)	1.0±0.0 (1.0)

Mayor cantidad de puntos no dominados (hasta 67/80).

Buena convergencia y diversidad en las soluciones encontradas.

Resultados numéricos

$\rho\mu$ MOEA/D: "Planificación multiobjetivo de viajes compartidos en taxis utilizando un micro algoritmo evolutivo paralelo" (MAEB)

Hasta **101.2 %** de mejora en demora y **72.8 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	8.5±2.1 (16.0)	3.1±2.5 (0.0)	740.2±746.3 (58.1)	0.6±0.2 (0.1)	0.9±0.1 (1.0)
medianas	9.1±2.2 (19.0)	5.7±2.5 (0.0)	1448.5±1064.1 (141.6)	0.6±0.1 (0.1)	0.9±0.1 (1.0)
grandes	8.5±2.2 (17.0)	7.9±3.4 (2.0)	2917.2±2041.5 (175.3)	0.6±0.1 (0.0)	0.8±0.1 (1.0)
Montevideo	8.0±2.1 (14.0)	3.0±2.0 (0.0)	663.5±542.4 (61.5)	0.6±0.2 (0.0)	0.9±0.0 (1.0)

Buena convergencia y diversidad. Pocas soluciones no dominadas.

NSGA-II: "Multiobjective taxi sharing optimization using the NSGA-II evolutionary algorithm" (MIC)

Hasta **105.2 %** de mejora en demora y **75.1 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	32.6±9.5 (55.0)	0.3±0.6 (0.0)	236.2±222.7 (43.2)	0.9±0.1 (0.7)	1.0±0.0 (1.0)
medianas	54.5±4.2 (67.0)	1.0±0.7 (0.0)	193.6±202.4 (26.2)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
grandes	55.2±3.5 (67.0)	1.8±1.1 (0.4)	243.6±229.8 (26.4)	0.7±0.2 (0.4)	1.0±0.0 (1.0)
Montevideo	43.9±16.4 (61.0)	0.4±0.5 (0.0)	142.3±143.2 (20.8)	0.8±0.1 (0.5)	1.0±0.0 (1.0)

Mayor cantidad de puntos no dominados (hasta 67/80).

Buena convergencia y diversidad en las soluciones encontradas.

Resultados numéricos

μ MOEA/D: "Planificación multiobjetivo de viajes compartidos en taxis utilizando un micro algoritmo evolutivo paralelo" (MAEB)

Hasta **101.2 %** de mejora en demora y **72.8 %** en costo sobre ávidos.

	#ND	DG	spacing	spread	RHV
chicas	8.5 \pm 2.1 (16.0)	3.1 \pm 2.5 (0.0)	740.2 \pm 746.3 (58.1)	0.6 \pm 0.2 (0.1)	0.9 \pm 0.1 (1.0)
medianas	9.1 \pm 2.2 (19.0)	5.7 \pm 2.5 (0.0)	1448.5 \pm 1064.1 (141.6)	0.6 \pm 0.1 (0.1)	0.9 \pm 0.1 (1.0)
grandes	8.5 \pm 2.2 (17.0)	7.9 \pm 3.4 (2.0)	2917.2 \pm 2041.5 (175.3)	0.6 \pm 0.1 (0.0)	0.8 \pm 0.1 (1.0)
Montevideo	8.0 \pm 2.1 (14.0)	3.0 \pm 2.0 (0.0)	663.5 \pm 542.4 (61.5)	0.6 \pm 0.2 (0.0)	0.9 \pm 0.0 (1.0)

Buena convergencia y diversidad. Pocas soluciones no dominadas.

NSGA-II: "Multiobjective taxi sharing optimization using the NSGA-II evolutionary algorithm" (MIC)

Hasta **105.2 %** de mejora en demora y **75.1 %** en costo sobre ávidos.


	#ND	DG	spacing	spread	RHV
chicas	32.6 \pm 9.5 (55.0)	0.3 \pm 0.6 (0.0)	236.2 \pm 222.7 (43.2)	0.9 \pm 0.1 (0.7)	1.0 \pm 0.0 (1.0)
medianas	54.5 \pm 4.2 (67.0)	1.0 \pm 0.7 (0.0)	193.6 \pm 202.4 (26.2)	0.7 \pm 0.2 (0.4)	1.0 \pm 0.0 (1.0)
grandes	55.2 \pm 3.5 (67.0)	1.8 \pm 1.1 (0.4)	243.6 \pm 229.8 (26.4)	0.7 \pm 0.2 (0.4)	1.0 \pm 0.0 (1.0)
Montevideo	43.9 \pm 16.4 (61.0)	0.4 \pm 0.5 (0.0)	142.3 \pm 143.2 (20.8)	0.8 \pm 0.1 (0.5)	1.0 \pm 0.0 (1.0)

Mayor cantidad de puntos no dominados (hasta 67/80).


Buena convergencia y diversidad en las soluciones encontradas.

Frentes de Pareto: $p\mu$ MOEA/D vs. NSGA-II


Chicas 6




Grandes 5



Medianas 5




Montevideo 4




NSGA-II alcanza mejores soluciones: mayor cantidad de puntos no dominados distribuidos homogéneamente a lo largo del frente.

Mejora frente a algoritmos ávidos vs. tiempo de ejecución



costo



demora


NSGA-II alcanza mejores soluciones pero requiere de un mayor tiempo de ejecución que *pμMOEA/D*.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea**
- 7 Conclusiones y trabajo futuro

Planificador de viajes compartidos en línea


- Se ingresa el origen, los destinos y la tarifa (diurna/nocturna).

- Se ejecuta el AE y se muestra la planificación calculada.




Planificador de viajes compartidos en línea


- Se ingresa el origen, los destinos y la tarifa (diurna/nocturna).



- Se ejecuta el AE y se muestra la planificación calculada.



Arquitectura del planificador de viajes compartidos en línea



- Servidor implementado en Ruby on Rails siguiendo MVC.
- Las aplicaciones móviles consumen la API del servidor.
- Aplicaciones móviles: desarrollo híbrido vs. desarrollo nativo.

- 1 Introducción
- 2 Definición del problema
- 3 Trabajos relacionados
- 4 Implementación
- 5 Evaluación experimental
- 6 Planificador de viajes compartidos en línea
- 7 Conclusiones y trabajo futuro

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** ($p\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** ($p\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis (www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p μ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p μ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis (www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** ($p\mu$ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** ($p\mu$ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis (www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p μ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p μ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis (www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p μ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p μ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis (www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p μ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p μ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis (www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

- Se relevó la literatura relacionada, se presentaron **dos** variantes del problema y se implementaron **cuatro** AE.
- El análisis experimental se realizó sobre **instancias realistas** comparando contra algoritmos ávidos.
- Variante monoobjetivo: mejoras en costo de hasta **35.9 %** (seqEA) y **41.0 %** (p μ EA) sobre algoritmo ávido.
- Variante multiobjetivo: mejoras de hasta **72.8 %** y **101.2 %** (p μ MOEA/D); **75.1 %** y **105.2 %** (NSGA-II) en costo y demora sobre algoritmos ávidos.
- Planificador de viajes compartidos en taxis (www.mepaseaste.uy).
- **Cuatro** artículos en conferencias internacionales.
- **Primer premio** del jurado en “Ingeniería deMuestra 2014” .

Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico**.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de usuario.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

Problemas relacionados

- Estudiar otras variantes del problema (many-to-one, many-to-many).
- Estudiar la aplicabilidad de los AE a otros escenarios.

Trabajo futuro

Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico**.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de usuario.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

Problemas relacionados

- Estudiar otras variantes del problema (many-to-one, many-to-many).
- Estudiar la aplicabilidad de los AE a otros escenarios.

Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico**.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de usuario.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

Problemas relacionados

- Estudiar otras variantes del problema (many-to-one, many-to-many).
- Estudiar la aplicabilidad de los AE a otros escenarios.

Trabajo futuro

Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico**.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de usuario.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

Problemas relacionados

- Estudiar otras variantes del problema (many-to-one, many-to-many).
- Estudiar la aplicabilidad de los AE a otros escenarios.

Trabajo futuro

Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico**.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de usuario.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

Problemas relacionados

- Estudiar otras variantes del problema (many-to-one, many-to-many).
- Estudiar la aplicabilidad de los AE a otros escenarios.

Trabajo futuro

Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico**.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de usuario.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

Problemas relacionados

- Estudiar otras variantes del problema (many-to-one, many-to-many).
- Estudiar la aplicabilidad de los AE a otros escenarios.

Trabajo futuro

Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico**.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de usuario.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

Problemas relacionados

- Estudiar otras variantes del problema (many-to-one, many-to-many).
- Estudiar la aplicabilidad de los AE a otros escenarios.

Trabajo futuro

Mejoras en los AE

- Implementar NSGA-II con subpoblaciones distribuidas.
- Incorporar **datos realistas del tráfico**.
- Incorporar datos de la **disponibilidad de los taxis** en tiempo real.

Mejoras en el planificador de viajes compartidos

- Mejorar la experiencia de usuario.
- Desarrollar versiones para Android y Windows Phone.
- Soportar la variante multiobjetivo.

Problemas relacionados

- Estudiar otras variantes del problema (many-to-one, many-to-many).
- Estudiar la aplicabilidad de los AE a otros escenarios.

Gracias

Sitio web del proyecto:

www.fing.edu.uy/inco/grupos/cecal/hpc/AG-Taxi/